

面向垂直领域知识图谱构建的高质量可控知识抽取方法 研究

姓名： 敖意欣
学号： 3220231197
学院： 计算机学院

2026 年 6 月



面向垂直领域知识图谱构建的高质量可控知识抽取方法研究
敖意欣
北京理工大学

中图分类号：TQ028.1

UDC 分类号：540

学校代码：10007

- ★ 学生类型
- ☐ 工程硕博士专项
- ☐ 交叉研究方向
- ☐ 政府项目留学生

面向垂直领域知识图谱构建的高质量可控知识抽取方法
研究

作 者 姓 名	<u>敖意欣</u>
二 级 培 养 单 位	<u>计算机学院</u>
指 导 教 师	<u>高春晓讲师</u>
申 请 类 别	<u>电子信息</u>
学 位 领 域	<u>计算机技术</u>
学位授予单位	<u>北京理工大学</u>
论文提交日期	<u>2026 年 6 月</u>

Research on High-Quality and Controllable Knowledge Extraction for Vertical-Domain Knowledge Graph Construction

Candidate Name:	<u>Ao Yixin</u>
School or Department:	<u>School of Computer Science</u>
Faculty Mentor:	<u>Lecturer, Gao Chunxiao</u>
Degree Applied:	<u>Electronic and Information Engineering</u>
Major:	<u>Computer Technology</u>
Degree by:	<u>Beijing Institute of Technology</u>
Submission date of the paper:	<u>June, 2026</u>

研究成果声明

本人郑重声明：所提交的学位论文是我本人在指导教师的指导下独立完成的研究成果。文中所撰写内容符合以下学术规范（请勾选）：

☒ 论文综述遵循“适当引用”的规范，全部引用的内容不超过 50%。

☒ 论文中的研究数据及结果不存在篡改、剽窃、抄袭、伪造等学术不端行为，并愿意承担因学术不端行为所带来的一切后果和法律责任。

☒ 文中依法引用他人的成果，均已做出明确标注或得到许可。

☒ 论文内容未包含法律意义上已属于他人的任何形式的研究成果，也不包含本人已用于其他学位申请的论文或成果。

☒ 与本人一同工作的合作者对此研究工作所做的任何贡献均已在学位论文中作了明确的说明并表示了谢意。

特此声明。

签 名：

日 期：

关于学位论文使用权的说明

本人完全了解北京理工大学有关保管、使用学位论文的规定，其中包括：

① 学校有权保管、并向有关部门送交学位论文的原件与复印件；

② 学校可以采用影印、缩印或其它复制手段复制并保存学位论文；

③ 学校可允许学位论文被查阅或借阅；

④ 学校可以学术交流为目的，复制赠送和交换学位论文；

⑤ 学校可以公布学位论文的全部或部分内容（保密学位论文在解密后遵守此规定）。

签 名：

日 期：

导师签名：

日 期：

致谢

本论文的工作是在导师.....

对学位论文的编写或相关工作的开展等给予帮助的组织和个人宜致谢，包括：

——国家科学基金，资助研究工作的奖学金基金，合同单位，资助或支持的企业、组织或个人；

——协助完成研究工作和提供便利条件的组织或个人；

——在研究工作中提出建议和提供帮助的人；

——给予转载和引用权的资料、图片、文献、研究思想和设想的所有者；

——其他应感谢的组织和个人。

面向垂直领域知识图谱构建的高质量可控知识抽取方法研究

摘要：面向垂直领域知识图谱构建的知识抽取任务，既要解决领域标注数据稀缺、自动标注噪声较高的问题，又要兼顾抽取结果的结构可控性与本地部署可行性。针对这一需求，本文以军事新闻领域为实例，围绕“数据构建—可控抽取—图谱应用”三条链路开展研究，提出了一套面向领域知识图谱构建的高质量可控知识抽取方法。首先，面向高质量训练数据获取困难的问题，构建了基于 SO-CoT 自优化与多模型事实评估的银标数据生成流程，通过少量种子样本、自反馈提示优化、事实评估与回流重抽，提升自动标注结果的可解析性、事实性与合规性，最终形成包含 10647 份军事新闻报道和 40565 个实体关系三元组的领域银标数据集。其次，面向轻量化本地部署场景，提出参数高效的本体约束知识抽取方法，以小参数开源模型为基座，结合 QLoRA 完成领域适配，并在推理阶段引入本体约束与多候选结果评分机制，提高抽取结果的结构合法性与稳定性。在 1000 条测试样本上的实验表明，完整方法的 F1 值达到 74.95%，优于同等规模大语言模型提示式抽取、QLoRA-only 及若干主流实体关系抽取基线，且新增开销主要集中在推理后处理阶段，具备较好的工程可行性。最后，基于上述方法设计并实现了军事新闻领域知识图谱构建与问答原型系统，完成了从文本导入、知识抽取、结果修订、图谱入库到基础查询与简单问答的全流程验证。系统在 1000 条输入文本上构建出 4546 个节点、6017 条关系的知识图谱，验证了本文方法在稳定入库与下游应用中的有效性。研究表明，本文方法能够较好地兼顾训练数据质量、抽取结果可控性与本地部署需求，为面向新闻领域知识图谱构建的知识抽取研究提供了一条较完整、可落地的技术路径。

关键词：知识抽取；知识图谱；大语言模型；参数高效微调；本体约束

Research on High-Quality and Controllable Knowledge Extraction for Vertical-Domain Knowledge Graph Construction

Abstract: Knowledge extraction for vertical-domain knowledge graph construction must address not only the scarcity of domain-specific annotated data and the noise in automatic annotation, but also the controllability of extracted structures and the feasibility of local deployment. To this end, this thesis takes military news as a case study and investigates the problem along three linked stages: data construction, controllable extraction, and knowledge graph application. A high-quality and controllable knowledge extraction method for domain knowledge graph construction is proposed. First, to address the difficulty of obtaining high-quality training data, a silver-standard data construction pipeline based on SO-CoT self-optimization and multi-model factual evaluation is designed. Through a small set of seed samples, self-feedback prompt optimization, factual assessment, and iterative re-extraction, the proposed method improves the parsability, factual consistency, and schema compliance of automatically generated annotations, and finally builds a domain silver-standard dataset containing 10,647 military news reports and 40,565 entity-relation triples. Second, for lightweight local deployment, a parameter-efficient ontology-constrained knowledge extraction method is proposed. A small open-source model is adapted to the target domain with QLoRA, and ontology constraints together with a multi-candidate scoring mechanism are introduced at inference time to improve the structural validity and stability of extracted results. Experiments on 1,000 test samples show that the complete method achieves an F1 score of 74.95, outperforming the same-scale LLM prompt-based extraction baseline, the QLoRA-only baseline without constraints, and several mainstream entity-relation extraction baselines, while the additional cost is mainly introduced in the post-inference stage, indicating good engineering feasibility. Finally, based on the proposed methods, a military news domain knowledge graph construction and question-answering prototype system is designed and implemented, completing the full workflow from text import, knowledge extraction, and result revision to graph storage, basic query, and simple question answering. On 1,000 input texts, the system

constructs a knowledge graph containing 4,546 nodes and 6,017 relations, which verifies the effectiveness of the proposed method in stable graph insertion and downstream application. The results show that the proposed approach can effectively balance training data quality, extraction controllability, and local deployment requirements, and provides a relatively complete and practical technical path for knowledge extraction in news-domain knowledge graph construction.

Key Words: knowledge extraction; knowledge graph; large language model; parameter-efficient fine-tuning; ontology constraint

目录

1	绪论	1
1.1	研究背景、目的与意义	1
1.2	国内外研究现状	4
1.2.1	领域知识图谱构建研究现状	4
1.2.2	知识抽取方法研究现状	5
1.2.3	高质量可控知识抽取研究进展	6
1.3	本文研究内容、创新点与技术路线	8
1.4	本章小结	9
2	相关理论与关键技术	10
2.1	知识图谱相关理论	10
2.1.1	知识图谱基本概念	10
2.1.2	知识图谱构建流程	11
2.2	知识抽取相关技术	15
2.2.1	命名实体识别	15
2.2.2	关系抽取	20
2.2.3	实体关系联合抽取	22
2.3	大语言模型相关技术	24
2.3.1	大语言模型基础	24
2.3.2	提示学习与思维链	26
2.3.3	参数高效微调方法	30
2.4	本章小结	33
3	面向垂直领域知识图谱构建的高质量可控知识抽取框架	34
3.1	任务定义	34
3.2	高质量可控知识抽取框架设计	35
3.2.1	框架总体结构	35
3.2.2	技术路线说明	38

3.3	以军事新闻为例的垂直领域本体模型设计	38
3.3.1	本体结构	39
3.3.2	军事新闻领域实体类型	39
3.3.3	军事新闻领域关系类型	40
3.4	本章小结	41
4	基于 SO-CoT 自优化与多模型事实评估的银标数据构建方法	42
4.1	问题描述	42
4.2	数据获取与预处理策略	42
4.2.1	数据来源与采集原则	42
4.2.2	采集方法与处理策略	43
4.3	银标数据构建方法流程	45
4.3.1	基于错误反馈的自优化思维链提示方法	46
4.3.2	基于 SO-CoT 的实体关系联合抽取	51
4.3.3	多模型协同事实评估	52
4.4	实验设计与结果	55
4.4.1	数据集与实验设置	55
4.4.2	对比实验、消融实验与评价指标	57
4.4.3	实验结果与分析	62
4.4.4	结果讨论	66
4.5	本章小结	67
5	面向轻量化本地部署的参数高效本体约束知识抽取方法	68
5.1	问题描述	68
5.2	参数高效的本体约束知识抽取流程	69
5.2.1	基于 QLoRA 的领域适配	70
5.2.2	领域本体模型约束	74
5.2.3	多候选结果生成与评分	76
5.3	实验设计与结果	80
5.3.1	数据集与实验设置	80
5.3.2	对比实验、消融实验与评价指标	82

5.3.3	实验结果与分析	85
5.3.4	结果讨论	91
5.4	本章小结	91
6	领域知识图谱构建与问答系统设计与实现	93
6.1	知识图谱构建与原型实现	93
6.1.1	图谱模式与知识抽取	94
6.1.2	知识入库、存储与系统实现	94
6.1.3	图谱存储与检索	98
6.2	应用验证与结果分析	100
6.2.1	知识抽取结果分析	100
6.2.2	图谱构建结果分析	100
6.2.3	基础查询与简单问答验证	102
6.3	本章小结	103
	结论	104
	参考文献	106

插图

图 1.1	知识图谱的应用，包括个性化推荐、智能问答与辅助决策等场景	3
图 2.1	知识图谱示例	11
图 2.2	知识图谱构建流程	11
图 2.3	以新闻文本为例的垂直领域知识图谱构建示意	13
图 2.4	BiLSTM-CRF 模型示意图	16
图 2.5	Transformer 模型结构图	18
图 2.6	BERT 模型架构	19
图 2.7	GPT 模型架构	20
图 2.8	基于依存分析的模式流程	21
图 2.9	LoRA 方法结构示意图	31
图 3.1	面向垂直领域知识图谱构建的高质量可控知识抽取框架	36
图 3.2	本体模型的作用	36
图 3.3	核心问题—对应机制—技术路线映射图	38
图 4.1	从新闻网站获取数据的流程示意图	44
图 4.2	数据获取与处理策略	45
图 4.3	基于 SO-CoT 自优化与多模型事实评估的银标数据构建方法框架	46
图 4.4	基于错误反馈的自优化思维链提示生成流程图	47
图 4.5	基于 SO-CoT 的实体关系联合抽取流程图	51
图 4.6	多模型协同事实评估方法流程图	52
图 5.1	参数高效的本体约束知识抽取流程	69
图 5.2	不同的微调方法对比	74
图 5.3	top- p 采样示意图	77
图 5.4	不同方法在 Precision、Recall 和 F1 上的对比	86
图 5.5	消融实验中不同方法在 Precision、Recall 和 F1 上的对比	87
图 5.6	候选数 (K) 与 F1、平均推理时延的关系	89
图 6.1	前文方法在领域知识图谱构建与问答系统中的作用示意图	93
图 6.2	系统主界面	95

图 6.3	导入文件与批次进度页面	97
图 6.4	文本记录页面	97
图 6.5	抽取结果展示与三元组编辑页面	98
图 6.6	类型维护与图谱导入页面	99
图 6.7	知识图谱导入日志页面	99
图 6.8	Neo4j Browser 中的知识图谱展示	101
图 6.9	图谱问答页面示例一	102
图 6.10	图谱问答页面示例二	103

表格

表 2.1	知识图谱构建示例，将非结构化文本转化为结构化三元组	22
表 2.2	未加入 Zero-Shot-CoT 的回答示例	28
表 2.3	加入 Zero-Shot-CoT 的回答示例	28
表 2.4	普通 Few-Shot 提示示例	29
表 2.5	加入 Few-Shot-CoT 的提示示例	30
表 3.1	总体框架主要模块及功能说明	37
表 3.2	军事新闻领域实体类型的定义	39
表 3.3	军事新闻领域实体关系约束定义	40
表 4.1	军事新闻语料主要来源及数据形态说明	43
表 4.2	实验数据集及其评测职责说明	56
表 4.3	实验模型设置	56
表 4.4	横向对比方法设置说明	58
表 4.5	消融实验设置说明	58
表 4.6	评价指标及其统计口径	61
表 4.7	不同模型在 CMeIE-V2 数据集上的实验结果比较	62
表 4.8	不同模型在 SciER 数据集上的实验结果比较	63
表 4.9	自建军事新闻语料上的银标数据可用性评估结果	66
表 5.1	DeepSeek-R1 与 DeepSeek-R1-Distill-Qwen-32B 特性对比	73
表 5.2	军事新闻领域实体关系联合抽取数据集关系数量统计	80
表 5.3	实验环境配置	81
表 5.4	模型训练的参数设置	81
表 5.5	多候选评分函数及生成阶段主要参数设置	82
表 5.6	横向对比模型的主要训练参数	83
表 5.7	不同主流方法在测试集上的实体关系联合抽取结果比较	85
表 5.8	不同方法在测试集上的消融结果比较	86
表 5.9	不同方法的部署成本比较	88
表 5.10	候选数 (K) 对完整方法性能的影响 ($\text{top-}p = 0.80$)	88

表 5.11	不同 $\text{top-}p$ 设置对完整方法性能的影响 ($K = 3$)	90
表 5.12	不同基座模型下完整流程的实验结果比较	90
表 6.1	系统主要功能模块	95
表 6.2	存储层设计与主要数据对象	96
表 6.3	抽取与构图统计结果	100

1 绪论

1.1 研究背景、目的与意义

截至 2024 年底，我国网民规模达 11.08 亿人，互联网普及率为 78.6%，其中手机网民占 11.05 亿人；同期建成的 5G 基站超过 419 万个，这些数据来自中国互联网络信息中心发布的第 55 次统计报告¹。另据《中国网络视听发展研究报告（2025）》²，短视频用户规模已突破 10 亿，使用率达 93.8%。这些数据共同向我们说明，网络，尤其是移动端平台，已构成现代社会最基础的信息接入入口。从早间手机推送，到通勤途中浏览社交平台，再到工作间隙阅读新闻客户端或微信公众号，网络资讯由此成为公众认知社会变化、理解专业问题、形成日常判断的重要知识来源。

在这一过程中，医学、金融、科技等领域的专业资讯逐步走出专业群体，进入大众视野，并在健康管理、消费决策、投资行为、职业发展乃至社会风险感知等方面产生直接影响。然而，信息渠道的扩张也带来了资讯环境的复杂化。一项覆盖全国 31 个省（区、市）的调查显示，网络新闻用户获取新闻的主要渠道依次为短视频平台（74.4%）、微信（73.5%）和新闻客户端（63.1%），另有相当比例用户还通过新闻网站、生活资讯平台或微博获取信息。值得注意的是，60.8% 的用户会主动区分所接触的新闻究竟来自官方媒体还是“自媒体”账号³。这说明，当前的问题已不再是如何“接触”信息，而是如何在多源、异构、快速更新的资讯流中识别、整合并利用真正有价值的知识。

内容供给侧的压力进一步放大了这一挑战。国家广播电视总局发布的统计公报显示，截至 2024 年底，全国广播电视节目制作经营机构超过 4.9 万家，当年新闻资讯类广播节目制作时间达 135.66 万小时，电视类近 96.5 万小时，短视频上传用户达 8.5 亿⁴。面对如此体量的内容生成，仅靠关键词检索或片段式阅读，虽能定位局部信息，却难以支撑知识关联、语义检索、持续更新与结构化利用等更高层次的需求。

以医学、金融、科技等领域新闻资讯为代表的高专业领域文本，正是上述环境中持续生成、传播与积累的典型知识载体。这类文本既包含大量实体、关系、事件和规

¹<https://www.cnnic.net.cn/n4/2025/0117/c88-11229.html>。

²<https://www.cnnic.net.cn/n4/2025/0328/c326-11272.html>。

³<https://dzrb.dzng.com/general/0/NEWS1999897IRXHRRVHGSHHF>。

⁴https://gbdsj.gd.gov.cn/zwgk/tjzl/content/post_4708463.html。

则类专业知识，又因来源多样、表达方式不一、更新节奏快而呈现显著的碎片化特征。在数字化与智能化应用不断向专业场景延伸的背景下，如何将分散于不同平台、不同文档形态、不同表达层级中的资讯内容，转化为可计算、可关联、可持续维护的知识资源，已成为领域知识组织与利用过程中亟待解决的基础问题。

在数字化与智能化应用逐步渗透专业场景的过程中，业务运行、信息传播等环节持续积累起大量知识数据。这些数据常常混含结构化、半结构化和非结构化内容，来源多、表达方式不统一，术语密集。由于数据形态与来源的差异，知识往往散落在不同平台、不同文档形态和不同表达层级中，难以被统一组织、持续维护和直接利用。知识图谱作为一种面向语义组织的知识表示方式，并不等同于事实三元组的简单堆叠。它整合了模式约束、实体标识、上下文语义与质量管理机制^[1]。相比通用知识图谱，领域知识图谱更依赖于专业概念体系、本体约束与术语规范，其构建过程对知识来源的质量、结构的一致性和持续更新能力提出了更高要求^[2]。在多源异构文本场景下，如何将分散于各类文档中的原始知识转化为可计算、可复用、可追踪的结构化形式，是领域知识图谱构建必须首先面对的基础问题^[3-4]。

作为面向语义组织的知识表示方式，知识图谱的价值并不止于对事实三元组的存储，更在于其能够将分散知识组织为可关联、可计算、可追踪的语义网络，并进一步支撑多种下游服务形态。得益于知识图谱对实体、关系及其语义关联的结构化组织，许多领域已开始将其作为知识底座，为下游应用提供数据支撑与知识服务。图 1.1 展示了领域知识图谱支撑典型应用场景的基本方式。

如图 1.1 所示，知识图谱在下游场景中可以呈现出多种服务形式：在个性化推荐中，它有助于综合用户特征、行为线索与上下文信息，提升内容匹配的针对性；在智能问答中，它能够支持对概念定义、实体关系及其语义关联的结构化响应；在辅助分析与决策场景中，它则为关系发现、线索整合和知识推演提供可计算的基础。需要指出的是，这些应用能力并非来自图谱表示形式本身的简单堆叠，而是建立在上游知识能够被准确抽取、规范组织并持续更新的前提之上。若缺乏稳定的知识获取与质量控制机制，下游应用所依赖的知识底座便难以保持一致性与可用性。

传统的“关键词检索-片段返回”方式在处理简单事实查询时效率尚可，但在高专业场景中面对复杂知识需求时，局限性明显。许多实际问题并非以显式关键词的形式出现，而是隐含在实体之间的关系链条、事件之间的因果规则，以及知识随时间的演化之中。片段式返回虽能提供局部文本证据，却难以支撑面向关系的知识组织、依据

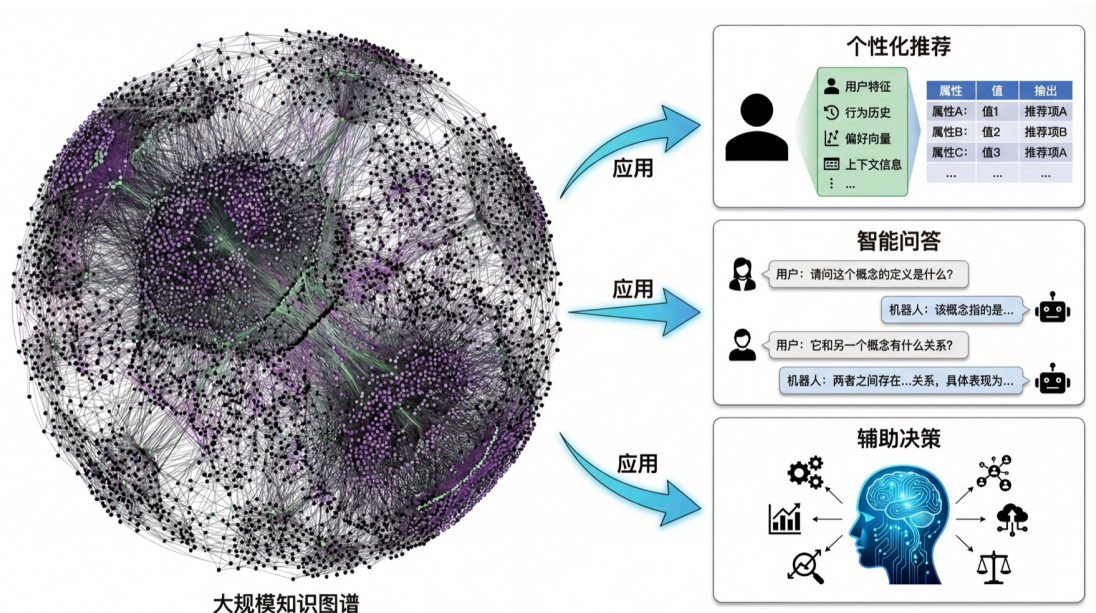


图 1.1 知识图谱的应用，包括个性化推荐、智能问答与辅助决策等场景

追溯和语义级检索。要真正提升领域知识的组织与利用能力，仅靠检索并不充分，还需要将文本中的实体、关系、事件、规则等要素显式抽取出来，组织成可查询、可维护、可持续更新的知识底座。

知识获取是原始文本进入知识图谱的入口^[4]。在获取阶段，知识抽取，尤其是实体识别与关系抽取，直接决定了图谱中节点、关系及语义链路能否被正确建立^[5]。基于规则模板、特征工程和监督学习的传统方法在特定任务中具有一定可解释性，但通常依赖大量人工规则或高质量标注数据。面对领域文本中新概念、新表达的持续出现，这类方法普遍面临开发成本高、维护周期长、跨场景迁移困难等问题^[5-6]。

大语言模型在复杂文本理解、少样本迁移和指令跟随方面展现出明显优势，为领域知识抽取提供了新的技术可能。不过，现有研究也表明，大语言模型在知识图谱构建中的价值更多体现在语义理解增强、流程加速和弱监督支持上，并不天然等同于稳定可靠的端到端知识抽取器^[7]。尤其是在高专业、高合规的场景中，对抽取方法的评价不能仅停留于局部精度，还必须同时考虑成本、吞吐、部署方式、可审计性，以及其与图谱模式的衔接能力。

因此，面向垂直领域知识图谱构建的知识抽取研究，正在从“能否抽取”转向“如何实现高质量、可控且可部署的抽取”。本文讨论的“高质量”，不只是抽取结果在表面上的合理性，更强调训练数据与抽取结果在事实性、完整性、一致性、可利用性上能够满足后续建模需要。“可控”则不仅要求输出格式规整，还要求结果满足本体约束、具

备结构合法性，并能够支持稳定入库与持续更新^[8-9]。在长期运行与本地部署场景下，参数高效微调与小参数模型在资源占用、时延、维护成本等方面具有现实优势^[10-13]。

基于上述分析，本文将研究对象限定为面向垂直领域知识图谱构建的高质量可控知识抽取问题，并以军事新闻领域作为方法设计、实验验证与系统实现的具体实例。具体围绕三个方面展开：一是高质量数据集的自动构建，二是参数高效微调与本体约束下的可控抽取，三是知识图谱构建和问答系统的设计实现。

1.2 国内外研究现状

与本文相关的研究，大致可以沿着三条线索展开：领域知识图谱如何构建，知识抽取方法如何演进，以及面向真实场景的高质量可控知识抽取如何实现。这是三条相互嵌套的关系，领域知识图谱规定了知识组织的框架和约束条件，知识抽取将文本等异构数据转化为结构化知识的核心手段，高质量可控抽取回应了实际部署中的稳定性、准确性与可维护性问题。

1.2.1 领域知识图谱构建研究现状

在领域知识图谱构建这一方向上，现有研究已将其与通用知识图谱做了明确区分。通用图谱追求广度与跨领域连接能力，而领域图谱更强调专业概念体系、本体约束与术语规范，其目标不是规模扩张，而是知识表示能否贴合特定任务的需求^[2]。一个领域图谱是否可用不取决于它存了多少三元组，而在于它的实体划分是否契合业务逻辑、关系定义是否一致、后续能否持续维护和更新^[1]。

从构建流程来看，知识获取、精炼与演化是基本环节^[4]。但对领域图谱而言，这几个环节必须与本体设计、元数据管理、质量控制等绑定在一起，否则即便建起来了，也很难在真实任务中稳定运行。已有研究反复指向同一个结论：领域知识图谱的难点不在存储层，而在于上游，如何从多源异构数据中稳定地识别出关键实体、关系和事件要素，并完成归一、融合与增量更新^[2,4]。换句话说，知识抽取的质量，直接决定了图谱能达到的上限。

这种难点的形成，与领域知识本身的特性密切相关。第一，数据来源高度异构：既有结构化字段，也有半结构化记录和非结构化文本，不同来源在命名方式、粒度划分、表达习惯上差异明显^[3]。第二，术语体系复杂，同一概念常存在多种表述，不同概念又可能在字面上相近但语义不同，这使得实体识别与消歧成本显著上升。第三，

领域知识更新快，新概念、新事件、新规则不断出现，图谱必须具备持续的演化能力。第四，许多领域图谱服务于高专业、高合规场景，对关系定义、命名规范和入库规则的一致性要求远高于通用图谱。以上四个因素叠加在一起，使得“把数据变成图谱”这一过程远没有看上去那么直白。

目前，已有研究在多个高专业场景中开展了领域知识图谱构建的探索，表明自动化知识组织确实存在现实需求^[3,14-15]。但若要进一步提升知识组织的质量，研究视角还需要向上游收束，回到多源异构文本场景中的知识抽取问题上，这恰恰是目前制约领域知识图谱走向深度应用的关键环节。

1.2.2 知识抽取方法研究现状

知识抽取是构建领域知识图谱的基础性工作，涉及实体识别、关系抽取以及实体-关系联合抽取等任务。从方法演进的角度看，这一领域大致经历了三个阶段。早期研究以规则和特征工程为主，代表性工作包括基于词汇-句法模式的关系模板、条件随机场、依存路径特征以及远监督方法^[16-19]。这类方法在类别封闭、语料可控的场景下精度较高，且每一步的决策依据相对清晰。但问题也很直接：规则和特征的设计成本不低，且容易受限于特定领域的表达习惯；一旦换到新领域或遇到跨句关联，覆盖能力就会明显下降。更重要的是，实体识别和关系抽取如果采用流水线方式，前一步的错误会直接传导到后一步，整体召回和精度都容易受限。

深度学习的引入改变了这一局面。以 Lample 等^[20]和 Miwa 等^[21]的工作为代表，基于神经网络的方法开始直接从上下文中学习语义表示，减少了对人工词典和语言学特征的依赖。随后，统一结构生成模型进一步将抽取任务从分类问题转为文本到结构的预测，使实体识别与关系抽取得以在同一框架下联合完成^[22-23]。相比特征工程阶段，这类方法在捕获复杂语境中的局部模式和语义关联上明显更具优势。不过，它们仍然依赖较为固定的 **schema** 设定和一定规模的标注数据。当实体类别体系、关系集合或文本风格发生变化时，往往需要重新训练或微调才能保持稳定。即便在统一生成框架下，长文本场景中的结构完整性、复杂约束条件下的边界识别等，也依然是容易出现偏差的环节。

近年来，大语言模型将知识抽取推进到一个新的阶段。一个核心变化在于，实体识别、关系抽取乃至更复杂的结构预测任务，都可以在自然语言指令的驱动下，以生成式的方式统一完成^[24-26]。这使得模型在处理长文本、跨句推理以及少样本迁移时展

现出更强的适应性，也使得“从文本直接输出结构化结果”在技术上变得更为可行。但需要留意的是，大语言模型并没有自动解决领域知识抽取中的老问题。在低资源场景或面对未见过的类别时，性能仍然会明显下滑^[6]；与此同时，生成式输出的不确定性也在增加，冗余关系、实体边界漂移、类型匹配错误等现象并不少见。再加上大模型在高频批处理、本地化部署和长期运行中的资源消耗，现阶段的研究重点已不再只是追求模型的抽取能力，而是开始更多地关注训练数据的质量、输出结果的结构可控性，以及在真实工程场景中的可用性。

换句话说，面向垂直领域知识图谱构建的知识抽取研究，正面临一个从“模型能不能抽出来”到“抽出来的结果能不能可靠入库”的转变。能否对抽取结果施加有效约束、能否保证其稳定性和可复用性，正在成为决定技术落地的关键。

1.2.3 高质量可控知识抽取研究进展

近年来，领域知识图谱的构建对知识抽取提出了新的要求，研究者开始将目光从单纯的单次抽取准确率，转向更全面的质量保障链条，这涉及训练数据的来源、结果的评估方式以及下游应用的有效利用。这一转变意味着，高质量的“银标”数据不再等同于标签数量的简单累积。本文所称“银标”数据，是指借助大语言模型等自动方式生成，并经事实评估、约束筛选或少量人工复核后形成的高置信度标注数据，其质量通常介于人工金标数据与未经筛选的自动标注结果之间。例如，有学者将大语言模型在数据标注中的角色，定位在“生成-评估-筛选-利用”的整体流程中考察^[8]；而针对真实数据集的标注质量分析也表明，有效的质量控制依赖于一致性标准的设定、复核机制的建立以及验证流程的健全^[9]。由此可见，面向领域的知识图谱构建，其数据基础必须同时满足准确性、完整性、一致性与可靠性这几个相互关联的条件。

为了达成这一目标，现有研究从多个方向进行了探索。在人机协同方面，部分工作尝试将有限的人工精力优先投入到模型难以判断的“不确定样本”上，以期在标注成本与最终质量之间取得平衡^[27]。在模型能力提升上，有研究指出，为使通用模型在特定信息抽取任务上表现稳定，面向任务进行专项对齐往往必不可少^[28]。此外，自验证方法在高专业文本抽取中展示了其价值：通过要求模型在输出结果的同时提供支撑证据并进行自我检查，能够在标注样本不足的情况下提升抽取的可靠性^[29]。这些尝试共同指向一个核心认识：构建高质量训练数据是一个涉及“谁来标、标哪些、如何校”的系统性问题，而非单纯的“自动生成标签”技术。然而，目前的研究多集中于主动学

习、人机协同或自验证等单个环节，尚缺乏一套能将提示优化、抽取生成、事实评估与错误回流整合为一个闭环，并直接服务于领域知识图谱构建需求的完整方案。可以说，如何给 Teacher 端系统性地生产高质量的银标数据，目前还是一个有待解决的核心问题。

与数据质量问题并行的，是面向实际部署场景的模型轻量化研究。LoRA、QLoRA 等方法显著降低了模型适配领域时的显存占用和训练成本^[10-12]，使得在资源有限的环境下构建专用的知识抽取模型成为可能。同时，小语言模型的研究也表明，在需要本地部署、长期运行或应用于终端设备的场景中，小参数模型在响应延迟、资源开销和运维便捷性上具有天然优势^[13]。这为 Student 端采用“小参数模型 + 参数高效微调”的路线提供了技术基础。但一个需要警惕的误区是：参数高效微调解决的是“如何低成本训练与部署”，它本身并不能保证模型输出的结果在语义和结构上是“可控”的。如果缺少对本体约束、关系合法性以及输出结果的选择机制，模型即使完成了抽取任务，其生成的内容也可能难以解析、无法满足图谱的模式要求，甚至无法稳定入库。

因此，对“可控抽取”的探讨，逐渐向如何将结构约束前置到生成过程的方向演进。有研究强调，知识图谱构建中的抽取系统应具备适应动态 schema 的能力，并在生成过程中显式考虑结构约束^[30]；另有研究尝试将领域本体知识引入抽取阶段，以从源头减少非法关系或不合逻辑三元组的产生^[14]。在具体实现上，受限解码和语法约束生成技术进一步表明，与其依赖事后修补，不如在生成阶段就对输出结果的结构合法性进行控制^[31-32]。此外，关于候选结果选择与规范化的研究指出，模型的单次生成结果并非最终可用的知识，对困难样本的重排序、结果的规范化处理，是连接模型输出与稳定入库的关键环节^[15,33]。相应地，面向文本到知识图谱生成的评价体系，也已将本体一致性、事实忠实性以及幻觉的抑制，纳入“可控性”的考察范畴^[34]。不难看出，当前研究为可控抽取提供了多种可借鉴的技术手段，但多数工作还各自聚焦于格式控制、一般 schema 感知或后验筛选，尚未将这些技术与小参数模型、参数高效微调以及具体的领域本体约束进行有机整合。

综合来看，现有研究至少存在三个需要进一步突破的缺口。其一，在数据构建端，缺乏一个围绕垂直领域知识图谱需求设计的、集提示优化、抽取生成、事实评估与错误回流于一体的闭环方法。其二，在模型部署端，虽然证明了小参数模型结合微调的可行性，但“能部署”与“结果可控”之间还存在断层，参数高效微调与结果结构控制还没有被统一设计。其三，现有的 schema 与本体约束研究，在支撑稳定入库方面还有

距离，尤其是在“实体类型-关系类型”的显式匹配、多候选结果的择优与规范化处理等环节，协同性不足。这些缺口的共同指向是：面向垂直领域知识图谱构建的知识抽取，既需要在源头解决高质量银标数据的供给问题，也需要在中间环节建立起一套能兼顾参数高效微调、本体约束与多候选选择的协同可控机制。基于此，本文将从高质量数据构建与面向本地部署的可控抽取模型两个层面展开后续研究。

1.3 本文研究内容、创新点与技术路线

针对垂直领域知识图谱构建中的知识抽取问题，本文围绕一条贯穿“数据-抽取-应用”的主线展开：从低资源场景下的高质量训练数据构建，到面向本地化部署的参数高效抽取，再到满足本体约束的稳定入库与下游应用验证。具体而言，需要回应三个相互关联的工程性问题：当领域标注数据稀缺时，如何获得高置信度的训练样本并控制其质量；在算力和部署条件受限的情况下，能否以较低的数量实现可用的领域抽取能力；抽取结果如何与领域本体对齐、形成合法三元组，从而支撑稳定入库，而不是仅停留在句子层面的“文本正确”。

围绕上述问题，本文的主要研究内容如下。

1. 在数据构建层面（Teacher 端），以少量种子样本为起点，通过提示自优化、事实评估与回流纠错形成闭环机制，生成高置信、高一致性的银标数据。这一环节的目标是把数据质量控制从事后清洗前移到源头构建阶段。
2. 在模型训练与推理层面（Student 端），首先以参数开源的小模型为基座，结合 QLoRA/PEFT 进行领域微调，在保留抽取能力的同时降低本地化部署与长期运行的门槛；随后在推理阶段引入本体约束与多候选选择机制，利用显式的实体类型与关系类型匹配规则抑制非法三元组，并通过多候选结果的综合评分提升输出一致性和稳定入库能力。
3. 在应用验证层面，将上述抽取结果用于以军事新闻为例的垂直领域知识图谱构建，并通过检索、简单问答等基础应用检验方法能否贯通从原始文本到结构化知识组织再到基础服务的完整流程。这里更关注的是方法在真实工程环节中的可落地性，而非单一评价指标上的增益。

与现有研究相比，本文的差异主要体现在以下三个方面。

1. 将高质量银标数据的构建从“模型训练后清洗”前移为“训练前的核心前提”，通过 Teacher 端的闭环机制将数据质量控制前置。
2. 在 Student 端将参数高效微调与可控抽取统一在一个框架中，强调小参数模型、QLoRA、本体约束与多候选选择的协同设计，而非将模型压缩与控制策略视为两条独立的技术路径。
3. 将知识图谱构建与下游应用验证纳入方法评估的必要环节，使研究目标从追求抽取精度扩展到支撑稳定入库与工程可用性，更贴近领域知识组织在实际部署中的需求。

全文主体共分六章，最后为结论与展望。第一章阐述研究背景与问题；第二章介绍相关理论和关键技术；第三章介绍面向垂直领域知识图谱构建的高质量可控知识抽取框架；第四章聚焦基于 SO-CoT 自优化与多模型事实评估的银标数据构建方法；第五章讨论面向轻量化本地部署的参数高效本体约束知识抽取方法；第六章介绍以军事新闻为例的知识图谱构建与问答系统设计与实现；最后总结研究工作并讨论未来研究方向。

1.4 本章小结

本章从领域知识图谱构建对高质量可控知识抽取的实际需求出发，分析了现有研究在数据闭环构建、参数高效微调与可控抽取协同、以及面向稳定入库的一体化机制等方面的不足。在此基础上，明确了本文的整体研究思路：以 Teacher 端的银标数据构建和 Student 端的本体约束可控抽取为核心，以下游应用验证为支撑，形成贯通“数据-抽取-应用”的技术链条，为后续各章的具体工作奠定框架基础。

2 相关理论与关键技术

2.1 知识图谱相关理论

2.1.1 知识图谱基本概念

在众多可用于增强语义理解与知识组织的辅助信息中，知识图谱因其能够显式表示实体及其关系，逐步成为相关研究中的重要对象。该概念最早由 Google 公司提出，主要用于提升搜索引擎对语义化查询意图的理解和结果组织能力。从本质上看，知识图谱是一种结构化的语义网络，由节点和边组成^[1]。在这一表示框架中，节点通常对应现实世界中的具体对象或抽象概念，边则用于刻画不同实体之间的语义联系。知识图谱中的事实知识一般可被表示为“实体—关系—实体”或“实体—边—实体”的三元组结构，从而使分散知识具备统一的结构化表达形式。通过这种方式，知识图谱能够有效地将用户和物品的属性信息、实体之间的关联信息以及用户与物品的行为信息组织起来，作为推荐系统的重要信息来源，从而提高推荐结果的准确性和多样性，并为推荐结果提供可解释路径。

以电影推荐场景为例，假设用户对影片“霸王别姬”表现出偏好，系统便可以沿着知识图谱中已有的实体关系进行关联扩展。例如，“阿飞正传”可通过主演关系与其建立联系，“末代皇帝”可通过题材关系与其关联，“搜索”则可通过导演关系与其相连。基于这些显式关系路径，推荐系统能够将与用户兴趣相关的候选影片组织起来，并据此生成更具解释性的推荐结果。如图 2.1 所示，图中的圆点代表实体，连线代表实体之间的关系，知识图谱正是通过这种显式关系组织方式，将原本分散的信息连接起来，形成可计算、可检索、可推理的知识网络。

知识图谱的形成通常依赖多个技术环节的协同作用。具体而言，知识抽取负责从开放数据或领域文本中识别实体、属性及实体间关系；知识融合用于处理不同来源知识在命名、指代或语义定义上的不一致；知识推理则能够在已有图谱基础上发现潜在关联或补充隐含知识，从而进一步扩展图谱内容^[4]。随着相关研究和工程实践的推进，知识图谱在语义表达、知识互联和关系组织方面的优势逐渐显现，并已被应用于个性化推荐、知识问答和智能检索等典型场景。就开放领域而言，Freebase、DBpedia 和 YAGO 等知识库是较具代表性的知识图谱资源^[35-37]。除开放领域知识库外，面向专业任务的领域知识图谱也逐渐形成了较多应用实践，如中药领域的 HerbNet、乳腺癌相




图 2.1 知识图谱示例

关知识图谱以及数学知识库 WolframAlpha 等。由此可以看出，知识图谱的应用范围已不再局限于通用知识组织，而是逐步延伸至具有明确任务目标和专业语义约束的领域场景^[2]。

2.1.2 知识图谱构建流程

知识图谱的构建并不是简单地将若干实体和关系拼接在一起，而是一个从原始数据到结构化知识再到下游应用逐步演化的过程。从整体上看，知识图谱构建通常围绕知识获取、知识融合、知识存储和知识推理等环节展开；在具体实现中，又会进一步细化为数据获取、知识建模、知识抽取、融合管理和平台应用等多个阶段^[1,4]。这些环节相互衔接，共同决定了知识图谱的质量、可扩展性以及后续应用效果。




图 2.2 知识图谱构建流程

图 2.2 展示了知识图谱构建的一般流程。该流程通常由知识获取、知识融合、知识存储 and 知识推理等环节构成。其中，知识获取位于流程前端，主要面向书籍、表格、文本语料等不同类型的数据源，通过知识抽取和知识建模等操作，将原始数据逐步转化为可用于图谱构建的结构化知识。知识抽取主要包括实体抽取和关系抽取等任务，用于从原始数据中识别关键对象及其联系；知识建模则进一步对实体、关系和属性进行抽象定义，在一些场景下还会涉及实体本体建模和事件本体建模，以保证后续图谱结构具有稳定的语义约束。

从任务定义角度看，领域知识图谱构建首先需要在给定文本中识别可构成关系的实体对象，并判断不同实体之间是否存在预设的语义联系，进而将抽取结果组织为图谱中的节点与边。该过程并不是简单地对文本中的关键词进行识别，而是要将非结构化文本中隐含的实体、关系及其语义联系转化为结构化三元组，从而为后续知识融合、图谱存储和下游应用提供基础。对于以军事新闻、医学文本、科学文档等为代表的垂直领域语料而言，这一过程尤其重要，因为这类文本通常具有较强的专业性、术语密集性和表达差异性，往往需要通过结构化处理才能被稳定组织和利用。

对于输入的长度为 L 的领域文本序列

$$S = \{s_1, s_2, \dots, s_L\}, \quad (2.1)$$

需要从中抽取若干个三元组，每个三元组包含两个实体和一个关系，即

$$\tau_i = (e_{i1}, r_i, e_{i2}), \quad (2.2)$$

其中，

$$e_{i1} = \{s_j, \dots, s_k\}, \quad 0 < j \leq k \leq L, \quad (2.3)$$

$$e_{i2} = \{s_{j'}, \dots, s_{k'}\}, \quad 0 < j' \leq k' \leq L, \quad (2.4)$$

表示领域文本中蕴含的两个实体，而

$$r_i \in R \quad (2.5)$$

表示预先定义的关系集合中的某一关系。换言之，知识图谱构建的核心任务，就是发现领域文本中包含的所有实体对，并确定它们之间的语义关系，再将其组织为后续可

入库、可查询、可维护的结构化知识单元。




图 2.3 以新闻文本为例的垂直领域知识图谱构建示意

以新闻类领域语料为例，其知识图谱构建流程可参见图 2.3。该流程通常以相关文本采集为起点，即围绕目标主题从新闻网站等来源获取语料；随后通过分句、去重和人工审核等处理步骤完成初步清洗，并形成后续知识抽取与图谱构建所需的数据基础。进一步地，围绕新闻文本中出现的实体及其关系进行分析，将原本分散在自然语言中的知识转化为结构化表示。例如，对于新闻文本中的人物、机构、地点及其行为或属性关系，经过识别、建模与抽取后，可以形成若干“头实体—关系—尾实体”的三元组，并进一步写入知识图谱。通过这种方式，知识图谱构建流程就从“原始文本处理”推进到“结构化知识生成”，进而与后续的融合、存储和应用环节衔接起来。

在获得初步结构化知识后，还需要通过知识融合消除多源数据中的冗余和歧义。该过程通常包括本体融合和实例融合两个方面：前者侧重统一概念层面的模式定义，后者侧重对齐不同来源中的同名异义、异名同义和重复实体。完成冗余消解和实体对齐后，图谱知识可采用资源描述框架（Resource Description Framework, RDF）三元组等标准形式进行表示，并结合 Jena、Neo4j 等工具完成存储、可视化与管理，从而支撑知识库的查询、维护和后续应用。在此基础上，还可以通过预测推理、补全推理等方式进一步挖掘隐含知识，增强图谱的语义表达能力和应用价值。

首先是数据获取阶段。知识图谱构建的数据来源通常具有多源异构特征，既可以来自书籍、表格、数据库等结构化或半结构化数据，也可以来自网页文本、百科词条、

领域文档等非结构化数据。在这一阶段，任务的关键是围绕目标领域筛选可用数据源，并完成数据收集、清洗和预处理，为后续建模和抽取提供输入。对于领域知识图谱而言，数据获取不仅要求覆盖领域核心实体和关系，还要求尽量保证数据的真实性、完整性和时效性，否则后续构建出的图谱容易出现知识缺失或语义偏差。

其次是知识建模与知识抽取阶段。知识建模的作用是从领域需求出发，对实体、关系和属性进行抽象定义，明确图谱中“有哪些对象”“对象之间存在哪些联系”以及“对象具备哪些属性”。在一些场景中，还需要进一步进行实体本体建模和事件本体建模，以形成更稳定的知识表示框架。在建模完成后，需要通过知识抽取将原始数据转化为结构化知识。对于文本数据而言，这一过程通常包括实体抽取和关系抽取两个核心步骤；对于表格、数据库等数据，则需要完成字段映射、语义对齐和结构转换。知识建模决定了知识图谱的结构边界，而知识抽取则决定了图谱中知识内容的具体来源和质量。

在抽取出初步知识之后，还需要进行知识融合。由于多源数据在命名方式、表达粒度和语义范围上往往存在差异，直接将其汇入同一图谱会产生大量重复实体、歧义关系和不一致描述。因此，知识融合通常需要在本体层和实例层两个层面展开：前者关注概念体系、关系模式和属性定义的一致性，后者关注实体对齐、名称归一化和重复实例合并。通过知识融合，可以提升图谱的统一性和可用性，使不同来源的知识能够在同一语义框架下被组织和管理。

完成融合之后，知识图谱需要进入知识存储与管理阶段。常见的表示方式是采用资源描述框架（Resource Description Framework, RDF）三元组对实体及其关系进行表达，并借助图数据库或语义存储工具实现管理和查询。在工程实现中，Jena 常用于 RDF 数据管理与语义处理，Neo4j 则常用于图结构数据的存储、可视化和关系查询。通过这一阶段，原本分散的数据与抽取结果被组织为可维护的知识图谱，为后续检索、分析与服务平台接入提供基础。

最后是知识推理与平台应用阶段。知识推理的目标是在已有知识图谱的基础上发现潜在关联，补全隐含知识，并支持更高层次的语义计算。常见形式包括预测推理和补全推理等。经过推理增强后的知识图谱可以进一步支撑推荐系统、智能问答、知识检索、辅助决策等应用场景。换言之，知识图谱构建流程并不是在图谱生成后结束，而是要通过管理、推理和应用形成闭环，使图谱从“可存储的结构化知识”进一步转化为“可服务的智能基础设施”。这一路径也为本文后续讨论面向领域知识图谱构建的知

识抽取与应用实现提供了流程层面的理论基础。

2.2 知识抽取相关技术

2.2.1 命名实体识别

命名实体识别 (Named Entity Recognition, NER) 是实体抽取任务中的基础环节, 主要用于从自然语言文本中定位并识别具有特定语义类别的实体对象, 如人名、专业名称、职业名称等。在知识图谱构建流程中, 命名实体识别承担着确定图谱节点候选对象的作用, 其结果会进一步影响关系抽取、实体对齐以及知识入库等后续环节。因此, NER 的识别准确性与边界判定质量, 在很大程度上决定了图谱构建结果的可靠性。根据技术路线和方法演进过程, 现有命名实体识别方法大致可归纳为以下四类。

第一类为基于规则和词典的命名实体识别方法。这类方法多见于早期研究, 其基本流程是由领域专家预先构建实体词典、类别定义和匹配规则, 再利用这些规则对文本进行扫描与匹配, 并将命中的实体划分到相应类别中。在语料规模较小、实体类型相对固定的场景下, 该方法通常能够取得较稳定的识别效果; 但由于规则设计、词典维护和类别扩展高度依赖人工经验, 当数据规模扩大或文本表达更加多样时, 其维护成本会显著上升, 适用范围也随之受限。

第二类为基于传统机器学习的命名实体识别方法。与规则词典方法相比, 这类方法通常将 NER 建模为监督学习或序列标注问题: 首先在训练语料中人工标注实体边界和类别, 例如采用 BIO 标注体系表示实体的起始、内部和非实体位置; 随后围绕词语、上下文及句法等信息构造特征, 并在此基础上训练分类模型或序列标注模型。训练完成后, 模型即可将学习到的标注模式迁移到未标注文本中, 用于识别新的命名实体。在传统机器学习框架下, 命名实体识别常采用隐马尔可夫模型 (Hidden Markov Models, HMM)、决策树 (Decision Trees, DT)、支持向量机 (Support Vector Machines, SVM) 以及条件随机场 (Conditional Random Fields, CRF) 等模型实现^[38-41]。其中, CRF 能够对序列标签之间的转移关系进行建模, 因此在早期 NER 任务中应用较为广泛。在深度学习方法逐渐应用于自然语言处理任务后, CRF 往往不再单独使用, 而是作为序列标签约束层与神经网络模型结合, 服务于分词、命名实体识别等需要连续标签预测的任务。

第三类为基于传统深度学习的命名实体识别方法。相较于依赖人工特征设计和外

部词典的传统机器学习方法，深度神经网络能够通过表示学习自动捕捉词语及上下文信息，因此逐渐被引入 NER 任务中，用于降低人工特征工程在模型构建中的比重。在深度学习用于命名实体识别的早期研究中，SENNA 是较具代表性的序列标注模型之一。该模型弱化了对人工特征工程的依赖，主要通过大规模未标注语料学习词语表示，并在此基础上训练深度前馈神经网络完成序列标注任务^[42]。在 SENNA 等早期神经网络序列标注方法之后，研究者进一步将双向长短期记忆网络（Bidirectional Long Short-Term Memory, BiLSTM）引入命名实体识别任务，用于同时建模词语前后两个方向的上下文信息。为增强标签序列的整体一致性，模型通常在 BiLSTM 输出层之后接入条件随机场（Conditional Random Fields, CRF），由此形成双向长短期记忆网络-条件随机场模型（Bidirectional Long Short-Term Memory-Conditional Random Fields, BiLSTM-CRF）^[20]，其结构如图 2.4 所示。




图 2.4 BiLSTM-CRF 模型示意图

由于能够同时利用上下文表示学习能力和标签转移约束，BiLSTM-CRF 已成为命名实体识别研究中的代表性神经网络模型，并在许多序列标注任务中表现出优于传统机器学习方法的效果。

第四类方法以 Transformer 架构为基础，代表模型包括双向编码器表示模型（Bidi-

rectional Encoder Representations from Transformers, BERT) 和生成式预训练变换器 (Generative Pre-trained Transformer, GPT)。在当前命名实体识别研究中, BERT 及其变体仍是较常用的预训练语言模型框架。与早期面向单一任务训练的监督学习模型相比, BERT 和 GPT 系列模型首先通过大规模语料预训练获得通用语言表示, 再根据情感分类、命名实体识别等具体任务进行适配。传统监督学习模型通常需要大量高质量标注数据, 并且在不同任务和场景之间的迁移能力较弱, 因此往往会带来较高的数据标注成本; 而 BERT 和 GPT 系列模型在一定程度上缓解了这一问题。

BERT 的预训练过程主要依托大规模文本语料进行语言表示学习, 其核心任务包括掩码语言模型 (Masked Language Model, MLM) 和下一句预测 (Next Sentence Prediction, NSP)。其中, MLM 通过随机遮蔽输入序列中的部分词语, 并要求模型根据上下文恢复被遮蔽内容, 以学习双向语义表示; NSP 则通过判断两个给定句子之间是否具有连续关系, 使模型获得一定的句间关系建模能力。由于这两个预训练任务可直接从原始文本中构造训练信号, 因此不需要额外人工标注数据^[43]。在实际应用中, BERT 通常作为文本表示模型嵌入到不同下游任务框架中, 例如情感分类、问答系统和命名实体识别等任务; 在具体任务适配阶段, 仍需要结合相应的标注数据进行监督训练。与之相比, GPT 系列模型更强调基于大规模混合语料的生成式预训练, 通过学习通用语言模式提升模型在不同任务间的迁移能力, 并在一定程度上降低对大规模人工标注数据的依赖。

从模型结构看, BERT 与 GPT 系列模型虽然在建模目标和使用方式上存在差异, 但二者均建立在变换器 (Transformer) 架构之上^[44], 其基本结构如图 2.5 所示。Transformer 由编码器和解码器两部分构成, 并以多头注意力机制 (Multi-Head Attention) 为关键计算模块; 该机制结合自注意力机制 (Self-Attention Mechanism, SAM) 与位置编码 (Positional Encoding), 使模型能够在并行计算的同时建模序列中不同位置之间的依赖关系。

在 Transformer 的计算流程中, 输入序列通常先被映射为向量表示, 并叠加位置编码, 以弥补模型本身缺少顺序结构建模的不足。随后, 多头注意力机制从不同表示子空间对序列信息进行交互建模, 得到包含上下文关联的特征表示。前馈神经网络 (Feed Forward Network) 则进一步对这些特征进行非线性变换, 形成更高层次的语义表示。在上述计算过程中, 残差连接 (Add) 和层归一化 (Layer Normalization) 用于增强深层网络训练的稳定性。残差连接通过将前一层的输出与当前层的输出相加, 有




图 2.5 Transformer 模型结构图

助于缓解深度神经网络训练过程中的梯度消失问题；而层归一化则通过对每一层的输出进行规范化，使模型在训练过程中保持较为稳定的性能。编码器和解码器都是由 N 个相同层堆叠而成，源序列和目标序列数据经过嵌入层后会产生相同维度的表示。

BERT 采用 Transformer 的编码器部分作为主体结构。每个编码器层通常由多头注意力机制（Multi-Head Attention）和前馈神经网络（Feed Forward Network）组成，其中自注意力机制负责计算序列内部不同位置之间的关联，使模型在表示某一词语时能够同时利用其他位置的上下文信息；多头机制则通过设置多个注意力头，使模型从不同表示角度学习词语间的语义联系，并在合并各头结果后形成更完整的上下文表示。BERT 依托掩码语言模型（Masked Language Model, MLM）学习双向上下文语义，即在同时利用左右两侧语境的基础上恢复被遮蔽词语；同时，其通过下一句预测（Next Sentence Prediction, NSP）任务建模句子之间的连续关系，从而增强对篇章级语义关联的表示能力。由于 BERT 采用双向编码方式，如图 2.6 所示，其能够在生成词语表示时综合利用前后文信息，因此更适合文本分类、语义匹配和命名实体识别等理解类任务。在知识图谱构建场景中，NER 需要准确判定实体边界及其类别，因而 BERT 常被用作该类任务的语义表示基础。




图 2.6 BERT 模型架构

与 BERT 主要采用编码器结构不同，GPT 系列模型以 Transformer 的解码器为核心。编码器在计算某一位置的表示时，通常可以同时利用输入序列中各位置的信息；而解码器引入了掩码机制，使模型在处理第 i 个位置时只能访问当前位置及其之前的上下文，后续位置的信息会在注意力计算中被屏蔽。由此，GPT 的表示学习过程呈现出从左到右的自回归特征。如图 2.7 所示，GPT 的单向建模机制使其能够按照自回归方式逐步生成文本，即根据已有上下文预测后续内容。因此，GPT 系列模型在摘要生成、机器翻译等生成式自然语言处理任务中具有较强适用性，并逐渐成为大语言模型发展的重要代表。在知识抽取任务中，大语言模型不仅能够承担文本理解与语义表示功能，也可以通过指令式生成方式参与结构化知识获取，包括命名实体识别、实体属性识别及相关抽取任务。随着生成式模型能力的提升，NER 的实现路径也不再局限于传统序列标注框架，而是逐步扩展到面向自然语言指令的生成式抽取范式^[24]。

综上，命名实体识别技术的发展大体呈现出由人工规则驱动向数据驱动、再向预训练语言模型驱动演进的趋势。规则词典方法强调人工知识约束，传统机器学习方法依赖特征设计与监督标注，深度学习方法进一步提升了上下文表示能力，而预训练语言模型则增强了模型在不同任务和领域中的迁移潜力。上述技术演进为后文研究面向领域知识图谱构建的可控知识抽取方法奠定了基础。




图 2.7 GPT 模型架构

2.2.2 关系抽取

关系抽取是知识抽取中的重要任务，主要用于判断文本中已识别实体之间是否存在特定语义关联，并将这种关联转换为可被计算和存储的结构化关系表示。在知识图谱构建场景下，实体能否形成有意义的边，取决于关系抽取能否准确识别实体间的语义连接。因此，关系抽取不仅影响图谱中关系边的生成，也会进一步影响图谱结构的完整性和可用性。根据技术路线的演进，现有关系抽取方法大体可归纳为三种类型。

第一类为基于模板的关系抽取方法。这类方法多用于早期关系抽取研究，通常依赖人工或半自动构建的关系模式来匹配文本表达，具体可进一步划分为触发词匹配和依存分析匹配两种形式。在基于触发词的关系抽取方法中，通常需要先构造若干能够表达特定关系的种子模板，再利用这些模板与待处理文本进行匹配。以句子“[姚明]的妻子[叶莉]与他一起出席了活动”为例，可先将其中的姓名统一替换为实体占位符，得到“[E1]的妻子[E2]”这一关系模式。随后，系统即可将“的妻子”识别为关系触发线索，并据此判断实体[E1]与实体[E2]之间存在“妻子”关系。除触发词匹配外，依存分析方法还可以借助句法结构识别实体之间的潜在关系，其一般处理流程见图 2.8。该方法通常先对输入句子进行分词、词性标注和命名实体识别等处理，再根据依存树上的匹配规则抽取子树结构；每匹配一条规则便生成一个候选三元组，之后结合扩展规则和评价机制形成关系抽取结果。基于模板的方法在较小数据集上的准确率较高，但随着数据集规模增大，人工编写模板的成本迅速上升，且对关系的覆盖不够全面，因

此并不适用于大规模数据集的关系抽取。




图 2.8 基于依存分析的模式流程

第二类为基于监督学习的关系抽取方法。这类方法通常把关系抽取建模为实体对层面的分类任务，即在已标注训练语料中给定实体对及其关系类别，再围绕上下文词汇、句法结构和语义信息构造特征表示，并通过分类模型学习不同实体对与关系类型之间的映射关系。常见的分类模型包括支持向量机（Support Vector Machines, SVM）和朴素贝叶斯（Naive Bayes）等^[40,45]。当训练样本规模较大且标注质量较高时，监督学习方法通常能够获得较稳定的关系识别效果。然而，该方法对人工标注语料的依赖较强，数据准备成本较高；同时，特征构造往往需要结合具体语料和领域经验进行设计，因此在跨领域应用时容易受到文本风格、关系类型和语义表达差异的影响。

第三类为基于弱监督学习的关系抽取方法，其中远监督是较具代表性的实现方式。远监督的基本假设是：若知识库中已经记录某一实体对之间存在特定关系，则包含该实体对的文本句子有可能表达相同关系。以“省会（杭州，浙江）”为例，当句子中同时出现“杭州”和“浙江”时，系统可依据知识库中的既有关系自动构造候选训练样例，用于学习“省会”关系的表达模式^[19]。远监督方法的优势在于能够借助知识库中的既有关联自动生成训练样本，从而降低人工逐条标注的成本。但由于“实体共现”并不必然意味着句子真实表达了知识库中的关系，该方法也容易产生噪声样本。例如，“杭州位于浙江东部”虽然同时包含“杭州”和“浙江”，但句子语义并未表达“省会”关系。此外，远监督方法的覆盖范围通常受已有知识库限制，对于知识库中尚未记录的新关系

识别能力相对不足。

Bootstrapping 方法通常从少量种子实例出发，先构建初始关系实例集合，再依据这些种子实例归纳或匹配关系模板，并在文档中发现新的候选实例。新抽取出的实例会被继续加入集合中，参与后续轮次的模板扩展与实例匹配，直至迭代过程收敛或不再产生有效增量。该方法能够在较低标注成本下扩展关系实例规模，因而适用于较大规模文本集合中的关系抽取，并具备一定的新关系发现能力；但其效果容易受到初始种子质量影响，若早期样本存在偏差，后续迭代可能进一步放大错误，导致部分场景下准确率下降。总体来看，关系抽取方法经历了从基于模板的方法、基于监督学习的方法，到基于弱监督学习的方法的发展过程。不同方法在准确率、人工成本和可扩展性方面各有特点，也为后续基于深度学习和大语言模型的关系抽取研究奠定了基础。

2.2.3 实体关系联合抽取

实体关系联合抽取是知识图谱构建中的重要基础环节，其核心任务是在同一处理框架下识别领域文本中的实体对象，并判断实体之间是否存在预定义关系。通过这一过程，原本以自然语言形式存在的非结构化文本可以被转换为“头实体—关系—尾实体”的三元组知识单元，进而为图谱存储、查询以及下游知识服务提供结构化数据支撑。从任务组成来看，实体关系联合抽取通常同时包含实体抽取和关系抽取两个部分。实体抽取侧重于确定文本中的实体边界及其类别，关系抽取则进一步分析候选实体之间的语义联系，并判断其是否属于既定关系集合中的某一类型。

表 2.1 知识图谱构建示例，将非结构化文本转化为结构化三元组

输入文本	三元组
德国经济部长彼得·阿尔特迈尔希望美国总统拜登上任后能够消除美欧间的贸易壁垒。	(彼得·阿尔特迈尔, 任职, 德国经济部长) (拜登, 任职, 美国总统)
《我和我的祖国》是由陈凯歌担任总导演，张一白、薛晓路、徐峥、宁浩等人联合执导的剧情片，于 2019 年 9 月 30 日在中国大陆上映。	(陈凯歌, 总导演, 《我和我的祖国》) (张一白, 导演, 《我和我的祖国》) (薛晓路, 导演, 《我和我的祖国》) (徐峥, 导演, 《我和我的祖国》) (宁浩, 导演, 《我和我的祖国》)

表 2.1 给出了非结构化文本向结构化三元组转换的示例。以新闻文本“德国经济部长彼得·阿尔特迈尔希望美国总统拜登上任后能够消除美欧间的贸易壁垒。”为例，模

型需要先识别出“彼得·阿尔特迈尔”“德国经济部长”“拜登”“美国总统”等实体或角色表达，再判断其间是否存在“任职”关系。经过实体识别与关系判定后，该句可被组织为“(彼得·阿尔特迈尔，任职，德国经济部长)”和“(拜登，任职，美国总统)”等结构化三元组。通过上述方式，能够从海量领域文本中构建知识图谱，为有效利用文本中蕴含的丰富知识奠定基础。

现有实体关系联合抽取方法大体可以从建模方式上划分为两类：一类依赖人工设计特征和规则约束，通常被归入基于特征工程的方法；另一类则利用神经网络自动学习文本表示，属于基于神经网络的方法。进一步看，神经网络方法还可依据实体抽取与关系抽取之间的信息编码方式，细分为顺序编码方法和联合编码方法^[5,21]。基于特征工程的实体关系联合抽取方法通常依靠人工经验和领域知识，将文本中的词汇、句法或上下文线索转化为可供模型使用的特征表示，并借助这些特征辅助实体与关系的联合判断。由于特征函数往往需要结合具体语料、关系类型和领域表达习惯进行设计，该类方法对研究者的语言学知识、领域理解能力以及人工调试投入都有较高要求。此外，特征工程方法通常需要依赖分词、句法分析、词性标注等外部自然语言处理工具，其效果容易受到工具误差和领域适配程度的影响。当任务迁移到新的领域语料时，原有特征规则往往难以直接复用，因而模型的泛化能力和跨领域适用性均会受到限制^[5]。

随着计算资源条件改善以及表示学习方法的发展，基于神经网络的实体关系联合抽取方法逐渐成为重要研究方向。与依赖人工特征设计的传统方法相比，神经网络模型能够直接从输入文本中学习词语、上下文及实体交互信息，从而减少人工构造特征的工作量，并在一定程度上提升模型对不同文本表达的适应能力^[5]。在神经网络框架下，不同方法的差异主要体现在实体抽取与关系抽取两个子任务的信息编码和交互方式上。依据这一差异，相关方法通常可划分为顺序编码方法和联合编码方法。

顺序编码方法通常按照预设的任务流程依次处理实体识别与关系判断问题。具体而言，模型可以先识别文本中的实体边界和实体类别，再以实体识别结果为基础进行关系分类；也可以先生成候选实体对，然后进一步判定候选实体之间是否存在目标关系。该类方法的核心特点是不同子任务按照先后顺序串联完成，前一阶段的输出会作为后一阶段的重要输入。顺序编码方法的优势在于处理流程较为清楚，模型结构也便于解释和实现。然而，由于实体抽取与关系抽取之间通常采用单向传递机制，前置任务只能向后续任务提供中间结果，难以反向利用关系判定阶段的信息来修正实体识别

结果。因此，当实体边界识别或候选实体对构造出现偏差时，误差可能继续传递到后续关系判断环节，进而影响整体抽取效果^[5]。

联合编码方法则弱化了实体抽取与关系抽取之间的固定先后关系，倾向于在统一表示空间中同时建模两个子任务。通常情况下，模型先对输入文本进行整体编码，获得包含上下文语义、实体线索和关系线索的表示向量；随后通过共享解码结构或多个任务解码器，联合完成实体识别与关系判定。相对于顺序编码方法，联合编码方法的优势在于能够在实体识别和关系判断之间建立双向信息传递，使关系线索参与实体边界或类型判断，也使实体信息反过来约束关系分类过程。这样可以更充分地利用文本中的上下文语义。然而，实体抽取与关系抽取关注的特征并不完全相同，若缺少有效的特征筛选与交互控制，直接融合不同任务信息可能引入冗余甚至相互干扰，最终影响联合抽取效果^[5,21]。

除顺序编码和联合编码框架外，统一结构生成与端到端生成式方法也逐渐被用于实体关系联合抽取。这类方法不再将实体抽取和关系抽取处理为两个边界清晰的独立步骤，而是把最终输出设计为统一的结构化表示，或直接以三元组为建模对象，在生成过程中同步完成实体定位、关系识别和结构组织^[22-25]。

2.3 大语言模型相关技术

2.3.1 大语言模型基础

随着预训练技术、模型规模和算力条件的持续发展，大语言模型（Large Language Models, LLMs）已成为自然语言处理研究中的重要技术路线。不同于传统为特定任务单独设计和训练的模型，大语言模型通常先在大规模语料上进行预训练，以获得较通用的语言表示和知识表达能力；在面向具体任务时，再通过指令适配、参数高效微调或提示引导等方式完成任务迁移。上述训练与迁移范式使大语言模型能够在文本理解、文本生成、问答推理和结构化信息处理等多类任务中复用预训练阶段获得的语言能力，从而表现出较强的跨任务适应性。对于知识抽取任务而言，这一特点意味着模型不仅可以理解文本语义，还能够在指令约束下生成符合特定结构要求的抽取结果，为后续可控知识抽取研究提供了技术支撑。

从模型架构的发展脉络看，早期语言模型多以循环神经网络（Recurrent Neural Network, RNN）为基础，并在此基础上发展出长短期记忆网络（Long Short-Term Memory,

LSTM)、门控循环单元 (Gated Recurrent Unit, GRU) 等改进结构, 用于对文本序列中的上下文信息进行建模。RNN 及其变体通常按照序列顺序逐步读取文本, 因此能够表达相邻词语及上下文之间的时序关联。然而, 这种依次计算的机制也带来了明显局限: 一方面, 模型难以充分并行化, 训练效率受到影响; 另一方面, 在长序列建模过程中, 梯度消失或梯度爆炸问题更容易出现, 进而削弱模型对长距离依赖关系的捕捉能力^[46]。

2017 年, Vaswani 等人提出的 Transformer 架构改变了以循环结构为主的序列建模方式, 使自然语言处理模型开始更多依赖自注意力机制完成上下文表示学习^[44]。相较于 RNN 按时间步递归处理序列的方式, Transformer 不再依赖循环单元, 而是利用自注意力机制 (Self-Attention) 计算序列内部各位置之间的关联强度。进一步地, 多头注意力机制 (Multi-Head Attention) 通过多个注意力头从不同表示子空间提取信息, 使模型能够并行学习词语之间的多角度语义联系。由于注意力计算可以在序列范围内并行展开, Transformer 在训练效率上较传统循环结构更具优势; 同时, 其对不同位置间依赖关系的直接建模, 也提升了长文本语义关联的表达能力。正因如此, Transformer 后来成为大规模预训练语言模型的重要架构基础。

基于 Transformer 架构, 预训练语言模型逐渐形成了不同的发展方向。一类方法侧重生成式建模, 通常采用自回归方式学习词序列中前文到后文的条件生成关系, 因此更适合连续文本生成任务; 另一类方法则更加关注双向语义表示, 借助掩码语言模型 (Masked Language Model, MLM) 等预训练任务, 使模型能够同时利用左右上下文信息学习文本语义。在双向表示学习路线中, BERT (Bidirectional Encoder Representations from Transformers) 具有较强代表性。该模型以 Transformer 编码器为基础, 通过双向上下文建模获取词语语义表示, 并结合掩码语言模型 (Masked Language Model, MLM) 和下一句预测 (Next Sentence Prediction, NSP) 等预训练任务, 使模型能够更好地适配多类下游自然语言处理任务^[43]。

在模型参数和应用规模持续增长的背景下, 相关研究开始更加关注计算效率、知识表达能力与扩展能力之间的平衡。例如, Switch Transformer 引入稀疏激活机制, 使模型能够在扩大参数容量的同时减少每次前向计算所需的实际计算量, 为大规模模型训练提供了另一种结构设计思路^[47]。与此同时, ERNIE 系列模型则从知识增强角度出发, 在预训练阶段引入与实体、概念和语义关系相关的知识信息, 以增强模型对结构化语义内容的理解能力^[48]。由此可见, 大语言模型的演进不能简单理解为参数量的

增加，而应被视为模型容量、结构设计、知识融合方式和训练效率共同优化的过程。

然而，模型能力提升的同时也伴随着资源消耗和工程部署方面的压力。对于参数规模较大的模型而言，训练和推理过程通常需要较高的计算能力与存储空间，这会提高模型部署和扩展应用的门槛^[49]。此外，当模型内部存在一定参数冗余时，还可能进一步增加模型存储、传输以及后期维护的成本。针对上述资源与部署压力，现有研究通常从压缩与高效训练两个方向进行改进。一方面，量化、剪枝和知识蒸馏等模型压缩方法可用于减少模型参数存储和计算开销，从而提升推理阶段的资源利用效率^[50-51]；另一方面，强化学习、稀疏激活以及混合专家模型（Mixture of Experts, MoE）等技术则从训练机制和模型结构层面改善大模型的训练效率与能力扩展方式^[52]。

在模型结构优化方面，相关研究也开始关注长上下文表示与推理效率之间的平衡。以 Transformer-XL 为例，该模型通过段级循环机制在不同文本片段之间传递历史状态，从而减轻固定上下文窗口对长距离信息保留能力的限制，并提升模型处理长文本时的上下文建模效果^[53]。此外，大语言模型在落地应用中仍存在可解释性和资源消耗方面的限制。具体而言，模型生成结果背后的中间决策过程通常不易被完整追溯，这会削弱其在高可靠应用场景中的审计能力和可信程度；同时，大规模训练与推理需要持续消耗计算资源，也可能带来较高的能源消耗和环境负担^[54-55]。

综上，大语言模型的能力来源不能仅归结为参数规模的扩大，更应理解为 Transformer 架构、预训练机制和任务迁移方式共同作用的结果。正是这些因素共同提升了模型在文本表示、内容生成和跨任务适配方面的能力。结合本文的研究任务来看，大语言模型对领域知识图谱构建中的知识抽取具有直接支撑作用。首先，其上下文建模能力有助于理解专业领域文本中复杂的实体指代、语义关联和跨句信息；其次，提示引导和指令式交互使模型能够以较统一的方式完成实体识别、关系判断及结构化结果生成；最后，若进一步结合参数高效微调和约束生成机制，大语言模型可以为高质量、可控且适合部署的知识抽取流程提供基础模型能力。

2.3.2 提示学习与思维链

提示学习（Prompt Learning）是一类面向预训练语言模型的任务适配方法，其基本思想是通过构造合适的输入提示，将任务需求以自然语言或模板形式传递给模型，并引导模型生成符合预期的输出结果。随着大规模预训练语言模型在自然语言处理任务中的应用不断扩展，提示学习也逐渐成为连接任务描述与模型生成能力的重要交互

方式^[56]。对提示形式、任务描述和上下文信息进行合理设计,可以使模型更准确地理解当前任务的输入输出要求,从而改善其在具体任务中的生成效果。与此同时,提示学习还能够利用预训练模型已有的语言知识和泛化能力,使模型在较少额外训练的情况下处理部分预训练阶段并未直接定义的下游任务^[43,57-58]。

提示学习的基本思路在于通过输入提示向预训练语言模型传递任务意图,使模型能够依据给定指令、问题描述或上下文信息生成相应结果。与传统自然语言处理任务中常见的模型微调方式不同,提示学习并不总是需要在特定任务数据集上重新训练全部模型参数,而是通过构造与任务目标相匹配的提示内容,激发模型在预训练阶段已经获得的语言理解和生成能力,从而完成不同类型的下游任务。从实现方式看,提示学习主要涉及提示设计、模板构造以及零样本/少样本任务适配等内容。提示设计侧重于用自然语言说明任务目标、输入条件和输出要求,使模型明确当前任务的处理方向;模板提示则通过固定或半固定的输入格式组织任务信息,以增强模型对任务结构的理解并提高输出形式的一致性;零样本与少样本学习则依托模型的 **zero-shot** 或 **few-shot** 能力,使其在没有示例或仅提供少量示例的条件下完成特定任务^[58-60]。

在自然语言处理应用中,提示学习已被用于多种任务类型。对于文本生成任务,提示可以限定主题、风格或内容范围,引导模型生成文章、故事或对话;在问答任务中,提示能够明确问题意图和回答约束,使模型输出更符合提问需求的答案;在文本分类任务中,提示可用于描述类别标准,辅助模型完成情感分类、主题分类等判断;而在机器翻译、文本摘要和信息抽取等任务中,合理设计的提示也能够帮助模型调用相应的语言处理能力。由此可见,提示学习的价值不仅体现在降低模型对大规模标注数据的依赖上,也体现在其能够以较低成本适配不同任务形式,并拓展预训练语言模型在多样化场景中的应用范围。因此,提示学习已成为预训练语言模型应用和自然语言处理任务设计中的重要技术手段^[57-58,60]。

思维链 (Chain of Thought, CoT) 是一种用于增强大语言模型推理过程的提示方法。Wei 等研究指出,在处理复杂推理任务时,可通过在提示中加入连续的中间推理步骤,引导模型按照较清晰的逻辑路径逐步分析问题,而不是直接给出最终答案。该方法已被用于算术推理、常识推理和符号推理等任务,并能够改善模型在此类任务中的求解效果^[61]。相较于直接由问题生成答案的提示形式,思维链提示在输入与最终输出之间加入了中间推理环节,使模型的回答过程由单步生成转变为“问题理解—推理展开—答案形成”的多阶段过程。通过显式呈现中间推理步骤,模型在给出结论前可

以先对问题条件、求解路径和关键中间变量进行梳理，从而降低直接生成答案时可能出现的跳步或推理不完整问题，并提高复杂任务输出过程的可追踪性。

根据提示中是否包含示范样例，思维链提示可进一步区分为零样本思维链（Zero-Shot-CoT）与少样本思维链（Few-Shot-CoT）。Zero-Shot-CoT 主要依靠简短的推理触发语，引导模型自行展开分步分析；Few-Shot-CoT 则在提示中提供少量包含推理链条的示例，使模型通过模仿示例中的问题分析过程和答案组织方式完成新任务。

Zero-Shot-CoT 是一种不依赖任务示例的思维链提示方式，其做法是在原始问题后增加简洁的推理引导语，使模型在回答前自动生成中间分析过程。Kojima 等的研究指出，在问题后加入“Let’s think step by step.”等提示语，可以激活模型的逐步推理行为，并改善其在算术推理、符号推理和常识推理等任务中的表现^[62]。这一现象表明，大语言模型的推理能力并不完全依赖额外示例输入，部分推理行为可以通过合适的语言提示被诱导出来。为更直观地说明 Zero-Shot-CoT 与普通回答方式之间的差异，表 2.2 和表 2.3 分别给出了未加入思维链提示与加入思维链提示后的回答示例。

表 2.2 未加入 Zero-Shot-CoT 的回答示例

我：“I am not what I am”这句话中的第四个词是什么？

ChatGPT：在句子“I am not what I am”中，第四个词是“what”。

表 2.3 加入 Zero-Shot-CoT 的回答示例

我：“I am not what I am”这句话中的第四个词是什么？让我们逐步分析和重写它。

ChatGPT：让我们逐步分析和重写这句话：

这句话可以拆分为：“I / am / not / what / I / am”。

“I”——第一个词，表示主语；

“am”——第二个词，表示动词“to be”的现在时第一人称单数形式；

“not”——第三个词，表示否定；

“what”——第四个词，用作关系代词，引导一个从句；

“I”——第五个词，与主语“I”对应；

“am”——第六个词，与主语“I”对应的动词；

因此，第四个词是“what”。

从表 2.2 和表 2.3 的对比可以看出，普通提示方式下模型能够直接输出答案，但回答中并未呈现答案形成的中间依据。引入 Zero-Shot-CoT 后，模型在给出最终结果之

前，会先对句子进行拆分并说明各词在序列中的位置，从而使答案生成过程更加清楚。与直接回答相比，这种方式能够展示模型的中间分析路径，有利于增强结果解释的完整性和可追踪性。

相较于仅依靠触发语引导推理的 **Zero-Shot-CoT**，**Few-Shot-CoT** 会在提示中提供少量包含完整推理链条的样例，使模型能够参考示例中的问题拆解方式、推理组织形式和答案生成模式，从而完成新的复杂任务。通常情况下，**Few-Shot-CoT** 提示可由指令（**Instruction**）、逻辑依据（**Rationale**）和示例（**Exemplars**）三个组成部分构成。**Instruction** 主要说明任务目标、输入条件和期望输出格式；**Rationale** 用于呈现从问题条件到结论之间的中间推理链；**Exemplars** 则通过具体样例展示“问题—推理—答案”的完整组织结构。借助带有推理过程的示例，模型可以更明确地学习复杂任务中的步骤划分、变量关系和答案组织方式，并将这种推理模式迁移到相似的新问题中。

表 2.4 和表 2.5 展示了普通 **Few-Shot** 提示与 **Few-Shot-CoT** 提示之间的差异。普通 **Few-Shot** 提示主要通过输入—输出样例帮助模型学习回答格式，而 **Few-Shot-CoT** 在样例中进一步加入中间变量设定和分步计算过程，使模型在处理新问题时能够按照“条件识别—变量表示—步骤计算—结果输出”的顺序展开推理。

表 2.4 普通 **Few-Shot** 提示示例

模型输入：

问：威廉本来有五个乒乓球，他又买了两盒乒乓球，每盒里面有三个乒乓球，请问他现有一共有几个乒乓球？

答：威廉本来有五个乒乓球，又买了 6 个，所以总共有 11 个。

问：小杜在周二上午做了三百个包子，早上卖了 93 个，中午卖了 39 个，晚上又从店铺里补了 6 个包子。那他现在还有多少包子留着？

模型输出：

答：小杜一开始有 300 个包子，卖了 $93 + 39 = 132$ 个包子，又补了 6 个包子，现在还剩 $300 - 132 + 6 = 174$ 个包子。

总体来看，思维链的核心价值在于将原本隐式、压缩的推理过程显式展开，使模型能够围绕中间步骤进行更稳定的语义组织与结果生成。进一步来看，**Self-Consistency** 方法不再依赖单一推理链的输出，而是针对同一问题生成多条候选推理路径，并对不同路径得到的答案进行汇总或投票，以降低单条推理过程可能造成的随机偏差和结果波动^[63]。在复杂自然语言处理任务中，分步推理能够使模型显式呈现问题拆解与中间判断过程，而多路径一致性则通过比较不同推理结果来提高答案选择的稳健性。因

表 2.5 加入 Few-Shot-CoT 的提示示例

模型输入：

问：威廉本来有五个乒乓球，他又买了两盒乒乓球，每盒里面有三个乒乓球，请问他现有一共有几个乒乓球？

答：威廉本来有五个乒乓球， $n_{\text{tennis}} = 5$ ；又多买了两盒，每盒 3 个， $T_{\text{bought}} = 2 \times 3$ ；因此答案为 $n_{\text{tennis}} + T_{\text{bought}} = 11$ 。

问：小杜在周二上午做了三百个包子，早上卖了 93 个，中午卖了 39 个，晚上又从店铺里补了 6 个包子。那他现在还有多少包子留着？

模型输出：

答：小杜一开始有 300 个包子， $n_{\text{start}} = 300$ ；早上和中午共卖出 $93 + 39 = 132$ 个，其中 $n_{\text{am}} = 93$ ， $n_{\text{pm}} = 39$ ；晚上又补了 6 个， $n_{\text{add}} = 6$ ；因此剩余数量为 $n_{\text{start}} - n_{\text{am}} - n_{\text{pm}} + n_{\text{add}} = 174$ 。

此，二者结合不仅有助于改善复杂任务的求解质量，也能使模型输出过程更便于追踪和分析。面向本文的知识抽取任务，提示工程与思维链方法的结合为抽取流程设计提供了可借鉴的思路。具体而言，模型可以在提示约束下先定位文本中的关键实体和上下文信息，再分析实体之间可能存在的语义关系，最后将识别结果整理为符合预设格式的结构化输出。这样的分步处理方式，有助于后续构建兼顾抽取质量、结构约束和结果可用性的可控知识抽取方法。

2.3.3 参数高效微调方法

随着大语言模型规模不断扩大，直接采用全量微调虽然可以使模型更充分地学习下游任务特征，但也会带来较高的显存占用、计算开销和训练时间成本。针对这一限制，参数高效微调 (Parameter-Efficient Fine-Tuning, PEFT) 方法通常保持大部分预训练参数不变，仅引入并更新少量与任务适配相关的参数模块，从而在保留基座模型通用能力的基础上，以较低成本完成特定任务迁移。在多种 PEFT 方法中，LoRA (Low-Rank Adaptation of Large Language Models) 是一种具有代表性的低秩适配方法^[10]。

该方法的核心做法是冻结原始预训练权重，并在模型的线性变换层旁路引入可训练的低秩矩阵，用这些新增矩阵来学习下游任务所需的权重增量。这样一来，模型适配不再需要更新完整权重矩阵，而是转化为对少量低秩参数的优化，从而减少可训练参数规模，并降低微调阶段的计算与存储压力。LoRA 的结构示意如图 2.9 所示。

在 LoRA 框架下，原始预训练权重矩阵可记为 $W^{(0)}$ ，模型在适配下游任务时所需




图 2.9 LoRA 方法结构示意图

的权重变化记为 ΔW 。与全量微调直接优化完整权重增量不同，LoRA 将该增量分解为两个可训练低秩矩阵的乘积，以低秩形式近似表示任务相关参数更新，即

$$W_{\text{new}} = W^{(0)} + \Delta W = W^{(0)} + BA, \quad (2.6)$$

式中， A 与 B 表示在微调阶段参与训练的低秩矩阵，其秩 r 通常远低于原始权重矩阵的维度。模型训练时只更新这两个新增矩阵，用它们刻画下游任务所需的参数增量，而预训练模型中的原始权重仍保持冻结状态。

在前向计算阶段，LoRA 会在原始线性映射结果的基础上加入低秩适配分支，使模型输出同时包含预训练权重贡献和任务增量贡献，其形式可写为

$$y = W^{(0)}x + \Delta Wx = W^{(0)}x + \frac{\alpha}{r}BAx, \quad (2.7)$$

其中， α 用于控制低秩增量项在最终输出中的作用强度， r 表示低秩矩阵的秩，用于对增量分支进行尺度归一化。这种设计使模型无需改变原始预训练参数，也能够通过低秩增量学习获得面向下游任务的适配能力。

因此，LoRA 的关键优势在于将微调目标从“大规模权重整体更新”转化为“少量新增低秩参数优化”，从而降低参数更新规模。从训练成本角度看，LoRA 只需优化附加的低秩矩阵，因此可训练参数规模和微调阶段的显存需求均明显低于全量微调。与此

同时，原始预训练权重在训练过程中不被直接更新，有助于保留基座模型已有的通用语言能力，并在一定程度上减轻灾难性遗忘风险。已有研究表明，相比传统全量微调，LoRA 通过更新较少比例的参数，也能够多个自然语言处理任务中达到接近全量微调的效果^[10]。因此，它为大语言模型在资源受限环境中的适配提供了一个轻量且实用的解决方案。

在 LoRA 方法之后，QLoRA (Quantized LoRA) 进一步将量化技术引入参数高效微调过程。该方法在保留 LoRA 低秩适配思想的基础上，对预训练模型权重采用低比特表示，从而在尽可能维持模型任务性能的同时，进一步降低微调过程中的显存需求^[11]。具体来看，QLoRA 采用 4-bit NormalFloat (NF4) 作为权重量化表示形式，并利用双重量化 (double quantization) 进一步压缩量化过程中产生的常量信息。经过量化处理后，基座模型的预训练权重以较低精度形式保存且保持冻结，任务相关参数更新则主要由 LoRA 适配器承担。

在前向传播阶段，QLoRA 的输出可以理解为两部分的叠加：一部分来自经过双重量化恢复后的量化基座模型权重，另一部分来自 LoRA 适配器所学习的低秩增量。其计算形式可写为

$$Y^{BF16} = X^{BF16} \text{doubleDequant}(c_1^{FP32}, c_2^{NF4}, W^{NF4}) + X^{BF16} A^{BF16} B^{BF16}, \quad (2.8)$$

式中， W^{NF4} 表示以 NF4 形式保存的预训练权重， c_1 和 c_2 分别对应量化过程中使用的常数项， $\text{doubleDequant}(\cdot)$ 用于表示由双重量化到可计算权重形式的恢复过程。

双重量化的作用在于对量化常数本身再次进行压缩表示，并在计算时逐级恢复相应权重。该过程可进一步表示为

$$W^{BF16} = \text{doubleDequant}(c_1^{FP32}, c_2^{NF4}, W^{NF4}) = \text{dequant}(\text{dequant}(c_1^{FP32}, c_2^{NF4}), W^{NF4}), \quad (2.9)$$

其中，单次反量化可以写为

$$W^{FP32} = \text{dequant}(c^{FP32}, W^{Int4}) = c^{FP32} W^{Int4}. \quad (2.10)$$

与原始 LoRA 相比，QLoRA 在参数更新规模较小的基础上进一步压缩了模型权重存储和训练显存需求，因此更适合在消费级显卡或资源受限计算环境中进行模型适配。由 LoRA 到 QLoRA 的发展表明，参数高效微调技术已从减少可训练参数，进一步延伸到降低显存占用和部署成本。对于本文研究的领域知识抽取任务而言，该类方

法能够缓解大语言模型训练和本地部署中的资源压力，并为后续构建面向轻量化场景的可控知识抽取模型提供方法基础。

2.4 本章小结

本章从知识图谱相关理论、知识抽取相关技术以及大语言模型相关技术三个方面梳理了本文研究所需的理论基础与关键方法，为后续章节展开具体方法设计、实验验证与系统实现提供支撑。

3 面向垂直领域知识图谱构建的高质量可控知识抽取框架

3.1 任务定义

本研究面向领域知识图谱构建场景下的知识抽取任务。和通用文本处理任务不同的是，垂直领域文本通常围绕特定行业、主题或业务场景展开，具有术语密集、表达专业等特点。对于知识图谱构建来说，真正需要的是能够被进一步表示和存储的结构化知识。本文关注的就是如何从多源异构的垂直领域文本中，稳定抽取出能够服务知识图谱构建的实体关系知识，并为后续的融合、入库和应用提供基础。这个任务场景对知识抽取提出了比普通信息抽取更高的要求，一方面，垂直领域文本中包含大量专业术语和上下文依赖，单纯依赖人工规则或传统监督方法，会面临标注成本高、迁移能力弱、难以适应领域表达持续变化等问题。另一方面，如果输出结果存在实体关系类型不匹配、结构不完整或格式不一致等问题，也仍然难以直接支撑后续对这些知识抽取结果的使用。此外，考虑到实际场景中的本地部署、推理成本和长期运行需求，长期依赖超大参数模型进行在线抽取也并不现实。因此，本文所讨论的任务本质上是一个同时受到数据质量、结果可控性和部署可行性约束的知识获取问题。

本文希望围绕垂直领域知识图谱构建需求，提出一套高质量的知识抽取框架。具体而言，本文希望解决三个实现层面的问题：

1. 高质量训练数据获取困难，直接制约后续模型学习效果

在垂直领域文本中，同一类事实往往会以不同说法出现在不同文本里。表面上看语料很多，但真正能够直接用于模型训练的高质量标注数据并不充足。如果完全依赖人工标注，不仅成本高、周期长，一致性也难以长期保证；但如果直接使用自动生成结果，又容易把噪声和幻觉样本带入训练过程。这样一来，后续模型即使完成了领域适配，也可能学到的是不稳定甚至有偏差的抽取模式。因此如何以可接受的成本构建可靠的训练数据，是整个技术路线首先要解决的问题。

2. 抽取结果难以兼顾准确性和可控性

大语言模型在复杂文本理解方面确实带来了新的可能，但在知识图谱构建场景中，能生成结果并不等于结果可以直接使用。一方面，直接依赖大模型长期在线抽取，会受到推理成本、响应时延和本地部署条件的限制；另一方面，即使采用小参数模型并进行参数高效微调，也不意味着输出天然就是规范和可控的。对于知识图谱来说，

结果不仅要语义上大体正确，还要满足实体类型与关系类型的匹配要求，尽量避免出现类型冲突、关系不合理、结构难解析等问题。换句话说，这里的难点已经不只是模型精度本身，而是如何使表面上符合语义的抽取结果进一步满足结构合法性和工程可用性要求。

3. 抽取方法需要服务于后续的图谱构建与应用验证

本文研究的目的是要把抽取结果真正用于知识图谱构建，前端文本经过抽取之后，结果还要能够进入后续的 `schema` 维护、知识组织、图谱存储和查询流程。如果抽取得到的三元组格式不稳定、语义冲突多、后处理成本高，那么即便句子层面的指标尚可，也很难支撑后续图谱入库与应用服务。因此，本文需要把“是否便于稳定入库”“是否能够支持基础检索与简单问答”纳入问题分析之中，从更完整的流程角度来审视知识抽取方法的有效性。

综合来看，知识抽取是一个贯穿训练数据构建、可控抽取和下游落地的系统性问题，下游应用需求本质上可以概括为两个方面：一是支撑知识图谱的稳定构建和存储；二是支撑实体关系查询和简单问答的基础知识服务。也正因为如此，本文后续将分别从高质量银标数据构建、轻量化本体约束抽取以及知识图谱构建与应用验证三个层面展开设计，以形成一条更完整、更可落地的技术路径。这里的“银标”数据，是指借助大语言或神经网络模型等方式生成，并经评估或人工复核后的高置信度标注数据，其质量介于人工金标数据与未经筛选的自动标注结果之间。

3.2 高质量可控知识抽取框架设计

3.2.1 框架总体结构

结合前文分析，本文构建了一个贯通数据、抽取与应用的总体框架，如图 3.1 所示。本框架采用了自顶向下的构建方法，即先定义垂直领域知识图谱本体模型，再结合具体实例场景考虑从数据中抽取知识的一系列流程。本节将简要描述这一架构的关键模块，以及这些模块如何协同工作来实现垂直领域知识图谱的高效构建和应用。

由图 3.1 的整体上可以看到，这个框架以前端垂直领域语料为输入，以垂直领域本体与数据模型为约束，以结构化抽取结果和图谱应用验证为输出，中间依次会经过数据预处理、银标数据集构建、参数高效微调和可控知识抽取等环节。在本文中，这一路径具体落在军事新闻语料及其知识图谱构建任务上。这样组织的原因在于，垂直




图 3.1 面向垂直领域知识图谱构建的高质量可控知识抽取框架

领域文本虽然信息密集，但往往来源复杂、表达不一、专业性强，原始语料本身并不能直接进入图谱。要把这些文本转化为可组织、可入库的知识单元，必须先处理数据可用性问題，再处理模型适配与结果控制问题，最后再检验结果能否真正支撑图谱构建与基础应用。因此本文框架要打通的是从原始文本到知识服务之间的整条链路。




图 3.2 本体模型的作用

其中，本体模型又可称为本体层或模式层，是知识图谱构建过程中的上层语义设计，主要用于约束和引导后续的数据组织、知识抽取、关系建模与图谱入库等环节。对于垂直领域知识图谱而言，本体模型需要明确该领域中的实体类别、关系类别以及不同实体类型之间允许建立的连接规则，从而为知识表示和抽取结果规范化提供统一的语义框架，如图 3.2 所示。本文在此基础上，将通用的垂直领域本体模型具体化为军事新闻领域本体模型，用以支撑后续军事新闻文本中的实体识别、关系抽取和图谱构建。通过引入本体约束，图谱中的实体与关系能够在统一模式下进行组织，有助于

提高知识表示的一致性、可解释性和场景适配性，使图谱能够更准确地刻画军事新闻领域中的复杂语义关联。本体模型的构建并非简单罗列实体和关系，而是需要结合目标领域的知识结构，首先梳理领域核心概念与实体类别，再进一步确定各类实体之间可能存在的关系类型及其约束条件。

为便于进一步说明各组成部分在整体流程中的功能定位，表 3.1 对总体框架中的主要模块、关键处理内容及输出结果进行了归纳。

表 3.1 总体框架主要模块及功能说明

模块名称	主要功能	关键处理	输出结果
数据源模块	提供多源异构垂直领域文本，为后续知识抽取与图谱构建提供原始数据基础	数据采集、来源筛选、语料汇聚	原始领域语料
垂直领域本体模型模块	定义垂直领域中的实体类型、关系类型和合法连接规则，为抽取与入库提供统一的模式约束	实体类型设计、关系类型设计、关系合法连接约束设计	领域本体模型与模式约束
数据预处理模块	对原始语料进行标准化处理，提升后续自动标注与模型训练的数据可用性	数据清洗、去重、分句、规范化处理	预处理后的领域语料
银标数据集构建模块	自动构建高质量训练数据，缓解领域高质量标注数据稀缺和人工标注成本高的问题	SO-CoT 提示自优化、实体关系联合抽取、多模型事实评估、回流重抽	高质量银标数据
参数高效微调模块	以小参数开源模型为基座实现领域适配，降低训练与部署成本	基座模型选取、指令数据构建、QLoRA 参数高效微调	领域适配后的轻量化抽取模型
可控知识抽取模块	输出结构更合法、结果更稳定的实体关系抽取结果，以满足知识图谱稳定入库需求	本体约束推理、多候选结果生成与选择、指令学习	可稳定入库的结构化抽取结果
图谱构建与应用验证模块	将抽取结果组织为知识图谱，并验证其在图数据查询与基础问答场景中的可用性	图谱入库、图数据库存储、可视化分析、Cypher 查询、基础问答验证	垂直领域知识图谱及应用验证结果

结合图 3.1 与表 3.1 可以看出，本文的总体框架实际上是以领域本体模型为约束，以高质量银标数据构建和面向本地部署的可控知识抽取为方法核心，并最终产出知识图谱构建系统应用的一体化设计。其中，前半部分更偏向于离线阶段的数据供给，重

点是尽量构建出质量更高、噪声更低的训练样本；后半部分的重点是把这些训练数据转化为可部署、可持续运行的抽取能力。两者前后衔接，分别对应“先把数据做好”和“再把抽取做好”这两个层面。与此同时，领域本体 Schema 约束贯穿了两个环节：它限制了银标构建时的实体类型、关系类型和输出边界，也进一步约束抽取结果的结构合法性，减少类型不匹配和关系不合理的三元组。最终的知识图谱构建与问答系统会检验抽取结果能否稳定入库，并能否支持后续查询与简单问答。下文将在此基础上，进一步说明整条技术路线与后续章节安排之间的对应关系。

3.2.2 技术路线说明




图 3.3 核心问题—对应机制—技术路线映射图

从图 3.3可以看出，本文的技术路线是顺着知识图谱构建场景中的几个实际问题往下展开的。前面在 3.1 中已经提到，任务的难点主要集中在三个方面：高质量训练数据难获得，抽取结果容易出现结构不稳和类型不匹配，方法要服务应用。所以这里技术路线的设计实际上就是围绕这三个问题逐步展开的：从数据构建、到可控抽取、再到应用验证逐层推进，也对应了后续第四章、第五章和第六章的展开顺序。

3.3 以军事新闻为例的垂直领域本体模型设计

本体（Ontology）是知识图谱构建的基础，它用于定义领域中的实体类型、关系类型和类型连接规则，并刻画它们之间的层次结构与语义关联。对于垂直领域知识图谱而言，本体模型主要决定图谱中“有哪些对象”以及“对象之间存在哪些联系”，也为领域文本中的知识抽取、结果组织和后续入库提供统一的模式约束。

本文以军事新闻领域作为垂直领域实例，对本体模型进行场景化细化。本小节对

实体类型、关系类型和合法连接约束进行了统一设计，下文将从本体结构、军事新闻领域实体类型、军事新闻领域关系类型以及本体约束作用四个方面进行说明。

3.3.1 本体结构

本文在军事新闻场景下构建的垂直领域本体模型采用“模式层—实例层”的两层结构。模式层用于定义领域中的实体类型、关系类型及其合法连接规则，是知识图谱构建与知识抽取的统一语义基础；实例层则承载从具体军事新闻文本中抽取得到的实体实例与关系实例。模式层回答的是“应当如何组织知识”的问题，实例层回答的是“从文本中实际获得了哪些知识”的问题，二者相互衔接，共同构成本文实例场景下知识图谱的基本表示框架。

考虑到军事新闻文本大多围绕某一事件展开，本文在本体结构设计中以“军事新闻事件”为核心，将行动主体、军事资产、地点、时间和数量五类实体作为知识组织的基本单元，并通过一组语义明确的二元关系表达测试、提供、部署、配备、打击、冲突及时空和数量关联等事实。通过这样的结构设计，可以将原本分散在新闻文本中的事件信息及其上下文要素进行统一表达，使知识图谱能够较完整地反映军事新闻中的事件逻辑和语义关联。

3.3.2 军事新闻领域实体类型

在军事新闻知识图谱中，实体类型是知识组织的基本单元。结合军事新闻文本的内容特点，本文围绕事件表达需求设计了五类实体类型，如表 3.2 示。

表 3.2 军事新闻领域实体类型的定义

实体类型	描述	示例
Actor	表示军事新闻中的行动主体、参与主体、接收主体或责任主体，包括国家、组织、机构、部队、企业及人员群体等	美国、俄罗斯、美国海军、第七舰队、雷声公司、武装分子
Asset	表示军事新闻中涉及的军事资产或资源性对象，包括装备、平台、系统、武器、舰艇、导弹、雷达及相关物资等	F-35B 战机、爱国者导弹连、铁穹系统、AN/SPS-67 雷达、备用部件
Place	表示事实相关的地理位置、区域、基地、港口、海域或设施空间	中东、地中海、横须贺军港、阿什杜德、日本海
Time	表示事实发生、部署、交付、测试或报道中的时间表达	6 月 13 日、今天、下个月、2014 年 11 月 9 日
Number	表示人数、架次、枚数、艘数、金额、里程等数量信息	1 名、20 人、80 枚、104 架、5000 万美元

3.3.3 军事新闻领域关系类型

关系类型用于描述不同实体之间的语义连接方式，是知识图谱中形成网络结构的关键。对于军事新闻场景而言，仅识别出主体、装备、地点、时间和数量这些实体还不足以形成可用的知识图谱，还需要进一步明确这些实体之间的语义联系。为此，本文结合军事新闻文本中的高频表达方式，以及训练数据中试验、提供、部署、打击、冲突及时空补充信息等事实结构定义了 11 类关系，如表 3.3 所示。

为避免不同阶段使用不一致的模式约束，本文以表 3.3 作为银标数据生成、事实评估、本体约束推理和图谱入库阶段共同遵循的最终约束集合。第 4 章中的事实评估提示、第 5 章中的合法性判定函数以及第 6 章中的图数据库入库规则均基于该约束集合实现。

表 3.3 军事新闻领域实体关系约束定义

关系类型	合法头实体类型	合法尾实体类型	说明
tested_by	Asset	Actor	表示某项军事资产被某行动主体测试、试验、检验或验证
provided_by	Asset	Actor	表示某项军事资产由某行动主体提供、交付、转让或租借
provided_to	Asset	Actor	表示某项军事资产被提供、交付、转让或租借给某行动主体
deployed_by	Asset	Actor	表示某项军事资产由某行动主体部署、列装或投送
deployed_to	Asset	Place	表示某项军事资产被部署到某地点或区域
equipped_with	Actor / Asset	Asset	表示主体或平台配备、搭载、安装或拥有某项军事资产
targeted_at	Actor / Asset	Actor / Asset / Place	表示主体或资产将另一主体、资产或地点作为打击、攻击、拦截或瞄准对象
incident_with	Actor / Asset	Actor / Asset / Place	表示主体或资产与另一主体、资产或地点发生冲突、碰撞、事故或对抗性事件
occurs_at	Actor / Asset	Place	表示与某主体或资产相关的事实发生在某地点
occurs_on	Actor / Asset	Time	表示与某主体或资产相关的事实发生在某时间
has_count	Actor / Asset	Number	表示与某主体或资产相关的数量、规模、金额或统计值

3.4 本章小结

本章面向垂直领域知识图谱构建需求，对高质量可控知识抽取任务的目标、问题和整体框架进行了统一说明，并以军事新闻领域为例对本体模型设计进行了详细阐述。围绕训练数据质量、抽取结果可控性以及下游图谱应用需求，本章建立了由银标数据集构建、可控知识抽取和图谱应用验证组成的整体技术路线，为后续具体方法展开提供了基础。

4 基于 SO-CoT 自优化与多模型事实评估的银标数据构建方法

4.1 问题描述

训练数据始终是大模型微调中的基础问题。在本文所选取的军事新闻实例中，语料还表现出来源多样、更新频繁和叙事风格不一致等特点。即使语料规模较大，真正能够直接用于实体关系抽取模型训练的高质量标注数据仍然不足；如果训练样本本身不稳定，后续模型即使完成领域适配，抽取结果也难以保持可靠。

领域标注数据构建的主要困难在于人工成本较高。完全依赖人工逐条标注不仅耗时，也难以长期适应语料增长速度。因此，自动标注成为更可行的技术路径，但自动生成并不等于自动可用。大语言模型虽然能够较快给出抽取结果，但也容易产生关系方向错误、抽取原文未明确表达的内容，或输出结构表面上符合格式却不满足本体约束等问题。对于知识图谱构建而言，这类问题比少量样本漏标更具风险，因为它们会直接影响后续训练数据的可信度，并将噪声继续传递给学生模型。因此，本章关注的不只是能否自动标注，而是自动标注结果能否具备较高可靠性。

本章希望解决的是：在尽量减少人工投入的前提下，构建一批质量更高、可直接用于后续模型训练的银标数据。具体而言，一方面，希望通过少量种子样本和错误反馈，使大模型先形成更适合当前任务的抽取策略，降低大规模自动标注初期的系统性误标风险；另一方面，希望在全量自动抽取之后，再通过多模型协同事实评估对结果进行筛选和回流修正，将明显不可靠的样本排除在训练数据之外。由此建立一套能够持续产出较高置信度银标数据的构建方法，为后续轻量化学生模型训练提供更可靠的数据集。

4.2 数据获取与预处理策略

4.2.1 数据来源与采集原则

本章从公开可获取的新闻资源中收集军事新闻报道，作为后续使用的原始语料，如表 4.1 所示。来源涵盖三类：一是权威发布渠道，包括官方平台、中央主流媒体及其军事频道；二是综合门户网站与聚合检索入口，用于扩大事件覆盖面和获取不同表达风格的报道；三是微信公众号及课题组前期自采的公开领域报道、行业资讯与报告。这些数据以半结构化和非结构化文本为主，包含正式报道、政策文件、热点事件快讯、

专题分析等类型，基本覆盖了后续实体关系联合抽取所需的真实语料场景。

表 4.1 军事新闻语料主要来源及数据形态说明

来源/平台	数据形态	备注
中国军网	半结构化 + 非结构化	适合采集正式新闻报道、专题稿件与军队动态文本
国防部官网	半结构化 + 非结构化	适合补充国防政策发布、记者会通稿、国防动态等官方文本
央视军事、央广军事、人民网军事、新华军事	半结构化 + 非结构化	属于中央主流媒体军事频道，适合补充权威报道与专题内容
腾讯新闻、环球网军事、新浪军事等综合门户新闻频道	半结构化 + 非结构化	覆盖面较广，适合扩充热点事件、转载链条和多样化表达文本
百度新闻	半结构化为主	更适合作为聚合检索入口，用于事件发现、来源回溯和交叉补充
微信公众号	半结构化 + 非结构化	可补充机构号、媒体号和专题解读类长文本
课题组自采集数据	半结构化 + 非结构化	前期已完成一定规模的数据收集与整理

采集时优先保证事实性内容的可信度：对于事实性较强、需要较高可信度支撑的内容，优先采用官方平台和中央主流媒体来源；对事件广度与表达差异的补充，则依赖门户与聚合平台；专题化、分析性较强的长文本，额外引入公众号和自采数据。同时，在采集阶段即检查来源可靠性、转载噪声、文本重复程度及格式规范性，为后续清洗、去重、结构化整理和银标数据构建做准备。

另外，部分结构化开源信息抽取语料并未纳入原始新闻来源。其作用仅限于借鉴标注规范、设计提示模板、开展预实验以及验证任务流程。这样区分真实新闻语料与辅助参考语料，是为了使银标数据既贴合实际领域文本的特征，又不失方法设计上的可操作性和实验依据。

4.2.2 采集方法与处理策略

数据采集是构建知识图谱的起点。本章的数据源包含课题组专有的数据、外部网络开源数据和新闻网站数据，前两者的数据采集方式相对简单，因此本节重点介绍从新闻网站获取数据的方法。

对于公开新闻网站和资讯页面，本章采用由大语言模型辅助的自动化爬虫采集方

式获取原始语料，并参考领域网站数据抓取的一般流程组织采集过程。如图4.1所示，系统首先根据目标主题和站点范围设定种子 URL，随后启动网页采集流程。URL 调度模块负责管理待访问链接，保证采集任务按既定顺序展开；页面下载模块负责获取对应网页内容；HTML 解析模块对网页文本、标题、发布时间、来源信息和正文区域进行解析；链接提取与过滤模块则从当前页面中继续发现候选链接，并通过主题相关性、页面类型和噪声比例等条件筛选无效页面；重复项检测、缓存与访问记录模块用于避免重复抓取，减少冗余数据存储，提高采集效率。通过这一流程，可以较为稳定地从不同新闻站点持续获取与目标领域相关的原始文本内容。




图 4.1 从新闻网站获取数据的流程示意图

在这个过程中，新闻网站页面模板多样、栏目层级复杂、正文区域与广告区域混杂，是数据采集阶段面临的主要困难。若完全依赖人工编写固定抓取规则，不仅开发和维护成本较高，而且当站点页面结构发生变化时，既有规则往往难以及时适配。为降低这类规则依赖，本章在采集阶段更强调面向主题相关性和正文可用性的内容筛选策略，即优先保留与领域主题相关、文本主体清晰、元信息较完整的页面，并尽量排除广告页、导航页、图片集页和明显缺乏事实信息的噪声内容。这样做的目的，是在原始语料进入自动标注流程之前，先从源头提高可用文本比例，减少后续抽取和评估阶段的无效开销。

在数据处理方面，考虑到领域原始数据通常同时包含结构化、半结构化和非结构化三种形态，并结合本文军事新闻语料的实际来源，本章采用差异化处理策略对不同数据类型分别进行整理，如图 4.2所示。对于结构化数据，如公开数据集中的字段化记录、表格型样本或已有标注条目，首先执行字段清洗、格式统一和异常值过滤，再保留其中可直接用于关系建模或样本组织的部分。对于半结构化数据，如 HTML 页

面、JSON 返回结果等，先通过解析器将其转换为统一格式，再根据页面结构将标题、时间、来源、正文、标签等元素分离出来，并进一步区分可直接保留的结构化信息与需要继续处理的文本内容。对于非结构化新闻文本，则将其作为后续银标数据构建的核心处理对象，重点进行文本清洗、规范化和句级切分。




图 4.2 数据获取与处理策略

通过这一系列处理，本文共收集了 10647 份军事新闻报道，构成了后续银标数据构建的原始语料基础。

4.3 银标数据构建方法流程

为获得可用于后续模型训练的高质量银标数据，本章以军事新闻领域作为垂直领域实例，设计了一套自动化银标数据构建流程，将银标数据构建划分为三个阶段：自反馈优化思维链生成、基于大模型的关系抽取以及多模型协同事实验证。第一阶段从语料中随机抽取 100 条种子样本，向大模型提供任务提示以完成初始抽取，并根据错误反馈迭代生成适配当前抽取模型和领域数据的优化思维链提示；第二阶段将优化后的提示应用于军事新闻领域语料，完成实体关系联合抽取；第三阶段利用评估模型对抽取结果进行事实验证，仅保留通过评估的结果，对未通过结果触发重新输出。该流程使模型在全量抽取前先形成更符合领域任务的推理路径，并在抽取后通过事实验证降低误抽、漏抽和幻觉问题，最终形成质量更高、可用性更强的银标数据集。

如图 4.3 所示，流程左侧对应提示生成阶段，中间对应关系抽取阶段，右侧对应事实评估阶段。左侧阶段的输出不是最终三元组，而是用于提升抽取质量的优化思维链提示；中间阶段面向全量军事新闻领域语料执行抽取任务，形成候选关系三元组；右侧阶段则通过评估模型对候选结果进行筛选，决定结果保留或重新输出。三部分共同构成银标数据的总体生成流程。




图 4.3 基于 SO-CoT 自优化与多模型事实评估的银标数据构建方法框架

该流程的设计重点在于将提示生成、结果抽取和质量筛选纳入同一任务链条中，而不是将自动标注视为一次性生成任务。通过这种方式，银标数据的形成过程不仅包含“生成”，还包含“修正”和“筛选”，从而使最终保留的数据在进入后续训练阶段之前已经经过初步质量控制。

银标数据构建流程包含三个关键环节，下文将分小节展开。

4.3.1 基于错误反馈的自优化思维链提示方法

思维链提示设计在各种大模型推理任务上已经取得了较好效果，但已有做法通常依赖人工构造提示或人工编写思维链示例，在不同领域语料场景下，这种方式容易受到编写者主观经验的影响，不一定适合给当前所使用的大语言模型使用。例如当垂直领域语料中同时包含事件、行动主体、地点、时间、资源以及结果等多种实体类型，且关系类型存在语义约束时，人工提示如果不能准确覆盖这些判断环节，模型抽取结果就容易不准确和不稳定。为了降低人工构造提示带来的主观偏差，本章提出一种基于错误反馈的 SO-CoT (Self-Optimized Chain-of-Thought) 提示自优化方法，使模型在少量种子样本上通过自反馈迭代总结自身常见错误，并据此生成更适配当前任务的优化思维链提示，整体机制如图 4.4 所示。

设预处理后的种子样本集合为

$$D_{seed} = \{x_1, x_2, \dots, x_n\}, \quad (4.1)$$

式 (4.1) 中， n 取 100 条左右即可满足提示自优化需求。对于每个输入句子 x_i ，首先使




图 4.4 基于错误反馈的自优化思维链提示生成流程图

用基础任务提示 P_0 调用抽取模型 M 进行初始实体关系联合抽取，得到初始输出

$$y_i^{(0)} = M(P_0, x_i). \quad (4.2)$$

式 (4.2) 给出的初始输出结果作为后续错误归纳的原始材料。初始抽取的目的，在于在当前领域实例场景的 **schema** 约束下暴露模型的典型偏差，使后续提示优化建立在真实错误分布而非人工假设之上。由于第三章已经给出了军事新闻领域的实体类型、关系类型及其类型连接规则，因此本节中的初始抽取并不是开放式自由生成，而是在预定义实体类别和关系类别边界内完成结构化三元组预测，这为后续错误筛选和推理链总结提供了统一参照。

在获得初始抽取结果后，引入错误反馈迭代机制对提示进行自优化。具体地，对模型输出中的代表性错误进行整理，并将其作为反馈信息返回给同一模型，要求其重新输出结果。设第 t 轮迭代中保留的代表性错误集合为 $E^{(t)}$ ，则模型在该轮的重新抽取可表示为

$$y_i^{(t+1)} = M(P_0 \oplus F(E^{(t)}), x_i), \quad (4.3)$$

式 (4.3) 中， $F(\cdot)$ 表示将错误结果转换为反馈指令的操作， $\oplus$ 表示将基础任务提示与错误反馈信息拼接形成新的交互输入。在实现上，第一阶段采用较为直接的反馈方式，例如要求模型针对“输出结果不正确”进行重新抽取，并将上一轮中具有代表性的错误结果嵌入提示中；模型在此基础上重新判断实体边界、实体类型和关系匹配。该过程持续进行，直到新一轮输出中不再出现新的代表性错误，或错误类型已经趋于稳定为止。

为了避免噪声信息干扰后续提示归纳，在错误整理过程中需要对模型输出进行人

工筛选，保留能够反映领域抽取共性偏差的高质量代表性错误，而剔除纯格式错误、明显幻觉、无关扩写等噪声类结果。相较于直接根据人工经验编写规则，这种基于真实错误样本的筛选方式更能反映模型在当前领域知识抽取任务中的实际薄弱点。

当多轮反馈后的错误模式趋于稳定时，进入第二阶段，即 **SO-CoT** 提示生成阶段。此时不再要求模型直接重新抽取结果，而是要求其基于前述多轮反馈中暴露出的典型错误，归纳一个更适合当前任务的推理过程，并给出关键推理步骤及必要示例。记最终聚合后的代表性错误集合为 E^* ，则优化后的 **SO-CoT** 提示可表示为

$$P_{SO-CoT} = G_M(P_0, E^*), \quad (4.4)$$

式 (4.4) 中， $G_M(\cdot)$ 表示由当前模型根据基础任务提示和代表性错误集合自动生成优化思维链提示的过程。与人工直接编写 **CoT** 不同，这里的思维链不是预先假设的“标准答案”，而是模型在多轮自反馈后形成的任务化推理框架，其核心目标是使提示组织方式尽可能贴合当前模型自身的理解路径和表达习惯。

最终生成的 **SO-CoT** 提示应至少包含以下几类信息：一是任务角色与目标说明，明确模型需要面向军事新闻文本抽取结构化实体关系三元组，而非生成解释性文本；二是基于第三章本体设计的实体类型与关系类型约束，要求模型在抽取时始终以预定义 **schema** 为边界；三是有序的推理步骤，用于引导模型按“整体句意识别—候选实体定位—实体边界确认—实体类型判定—关系匹配与方向判断—完整性与冗余检查—标准格式输出”的流程完成任务；四是少量关键示例，用于说明哪些抽取路径是合理的，哪些错误模式应当避免。这样生成的 **SO-CoT** 提示不再只是简单的任务描述，而是兼具任务约束、推理路径和错误规避功能的优化提示模板。

为更直观地展示提示自优化前后的结构差异，下面给出一个用于军事新闻抽取任务的小规模示例：前者为原始任务提示，后者为 **DeepSeek-V3.2** 模型基于 100 个样本错误反馈自动生成的思维链提示。以下是原始提示示例：

```
你是一名军事新闻关系抽取专家。
任务：从输入新闻中精确识别实体，并抽取实体之间的关系三元组。
【允许的关系集合 (relation whitelist)】
{predicates}
【实体类型集合】
Actor, Asset, Time, Place, Number
【抽取要求】
```


- 关系 `relation` 必须严格来自 `whitelist`。
- `head` 和 `tail` 必须是输入文本中的连续原文片段。
- 只依据文本，不引入外部知识。
- `head\_type` 与 `tail\_type` 必须属于：Actor / Asset / Time / Place / Number。
- 完全相同的 `(head, relation, tail)` 只保留一条。
- 若没有符合条件的三元组，输出空数组 `[]`。

【输出要求】

只输出 JSON 数组，每个元素格式为：`{ "head": "...", "relation": "...", "tail": "...", "head_type": "Actor|Asset|Time|Place|Number", "tail_type": "Actor|Asset|Time|Place|Number" }`

【输入文本】

`{text}`

以下是 DeepSeek-V3.2 模型根据错误反馈生成的思维链提示：

思维链推理步骤

请在内部思考中按照以下步骤完成实体关系三元组抽取，确保结果准确、一致且可解析。不要输出你的思考过程，只输出最终 JSON 数组。

步骤 1：解析文本与关系白名单

- 仔细阅读输入军事新闻文本 `{text}`，并审阅允许的关系集合 `{predicates}`。
- 抽取时仅允许使用白名单中的关系类型，不得输出白名单外关系。

步骤 2：识别候选实体与潜在关系

- 逐句扫描文本，识别可能构成三元组的 Actor、Asset、Time、Place、Number 实体。
- 结合上下文，初步判断这些实体之间是否存在属于白名单的潜在关系。

步骤 3：区分易混淆关系类型

- 不要把 `provided_by` / `provided_to` 误判为“提供者 -> 接收者”；本数据集中采用“装备/平台 -> 提供主体或接收主体”的方向。
- 不要把 `deployed_to` 和 `occurs_at` 混淆：如果文本表示“驶往、部署到、驻扎于”，更可能是 `deployed_to`；如果只是新闻事件发生地点或实体所处地点，更可能是 `occurs_at`。
- 不要把时间背景一律抽成 `occurs_on`，只有当文本明确把该时间和该实体关联起来时才输出。
- 对 `has_count`, `tail` 只取数量表达本身，不把整个名词短语都并进去。
- 不要把“表示、称、指出、报道”这类引述动作本身误抽为 `tested_by` / `provided_by` / `deployed_by`。
- 若 `relation` 在语义上可疑、方向拿不准、边界不完整，宁可不输出。

步骤 4：回到原文核对证据

- 对每个候选三元组，必须在原文中找到直接、明确的证据支持。
- 若存在以下任一情况，则放弃抽取：含有否定表达，如“未”“没有”“并非”等；含有猜测或不确定表达，

如“可能”“疑似”“或将”等；只是同句共现，但文本未明确表达二者之间存在该关系；仅是转述、表态、报道行为，本身不构成目标关系。

步骤 5：确定 head、tail、类型与实体边界

- 根据关系定义和句子语义确定 head 与 tail，保证方向正确。
- head 与 tail 都应原文中最短但完整的连续实体片段。
- 判定 head_type 与 tail_type，类型必须属于 Actor / Asset / Time / Place / Number。
- 若存在并列实体、并列数量或并列目标，且原文分别有明确支撑，可以拆分为多条三元组。
- 不要因为实体较泛就放弃抽取；如果原文就是“人”“艇员”“士兵”，直接保留该原文片段。

步骤 6：最终过滤与输出

- 对所有候选三元组进行白名单过滤、方向检查、实体边界检查、类型检查和重复检查。
- 仅保留关系类型合法、证据充分、方向正确、实体边界完整的结果。
- 最终输出 JSON 数组；若没有可抽取关系，输出 `[]`。

最终检查

- relation 是否在 `{predicates}` 内。
- head 与 tail 是否都是原文连续片段。
- 方向是否正确。
- head_type 与 tail_type 是否合理。
- 输出是否只有 JSON 数组，没有任何解释文字。

输出格式

只输出一个 JSON 数组。每个元素必须是：{"head": "...", "relation": "...", "tail": "...", "head_type": "Actor|Asset|Time|Place|Number", "tail_type": "Actor|Asset|Time|Place|Number"}。若没有可抽取关系，输出 []。

可以看到，优化后的提示在保留任务目标、关系白名单和输出格式约束的同时，进一步显式加入了候选实体识别、易混关系区分、原文证据核对、关系方向判断与实体边界检查等步骤，这也说明 SO-CoT 提示相较于基础提示能够提供更强的过程约束与错误规避能力。

综上所述，从方法作用上看，基于错误反馈的 SO-CoT 提示自优化，本质上是在少样本条件下利用模型自身输出结果反向构造高质量任务提示。它并不直接增加训练数据规模，而是首先改善“如何抽取”的提示条件，使模型在进入全量语料自动标注之前，先形成更符合领域语义结构与本体约束的推理方式。对于本章的银标数据构建过程而言，这一过程具有两方面意义：一方面，它能够减少人工构造提示中常见的经验偏差，提高提示对当前任务的适配性；另一方面，它使后续实体关系联合抽取建立在

已经完成初步自校正的推理链之上，从而为第四章后续的全量自动抽取与事实评估筛选提供更高质量的候选结果。

4.3.2 基于 SO-CoT 的实体关系联合抽取

在完成少量种子样本上的错误反馈迭代后，可将生成的优化 SO-CoT 提示作为全量语料自动标注阶段的主提示，用于执行面向具体垂直领域实例的实体关系联合抽取。在本文中，该实例为军事新闻语料。与仅依赖基础任务描述的一次生成不同，SO-CoT 提示在保留任务目标、实体类型集合、关系类型约束和输出格式要求的同时，进一步显式加入整体句意识别、候选实体定位、实体边界确认、实体类型判定、关系匹配与方向判断、完整性与冗余检查等推理步骤，从而使模型在预定义 schema 约束下完成更稳定的结构化抽取。

设待抽取的领域文本句子为 x_i ，优化后的 SO-CoT 提示为 $P_{\text{SO-CoT}}$ ，抽取模型为 M ，则该阶段的联合抽取过程可表示为

$$y_i = M(P_{\text{SO-CoT}}, x_i), \quad (4.5)$$

式 (4.5) 中， $y_i = \{\tau_1, \tau_2, \dots, \tau_k\}$ 表示句子 x_i 的关系三元组集合， $\tau_j = (h_j, r_j, t_j)$ 表示一个头实体—关系—尾实体结构。该过程中，实体识别与关系判定在同一次提示驱动下统一完成，模型仅允许在预定义的实体类型与关系类型范围内进行判断；对于原文证据不足、关系不在约束集合中、实体边界不完整或关系方向明显错误的候选结果，不予输出。




图 4.5 基于 SO-CoT 的实体关系联合抽取流程图

如图 4.5 所示，为适配领域知识图谱构建需求，SO-CoT 提示不再将抽取任务视为

自由文本生成，而是将其转化为受约束的结构化预测过程。具体而言，模型首先根据句子整体语义识别可能涉及的事件、组织、人物、地点、时间、资源等候选实体，再结合预定义关系集合判断实体间是否存在有效语义连接，并对复合实体完整性、并列结构拆分合理性以及重复三元组进行检查，最终输出统一格式的实体关系三元组。

经过该阶段处理后，可获得覆盖全量语料的初始银标候选结果，为后续事实评估与高置信样本筛选提供输入。

4.3.3 多模型协同事实评估

尽管经过 SO-CoT 优化后，大语言模型的实体关系抽取结果在结构性和一致性上已有所提升，但自动生成结果仍可能出现事实幻觉、关系方向错误、实体边界截断以及语义不合理等问题。为进一步提高银标数据的可靠性，本章在抽取阶段之后引入多模型协同事实评估机制，对生成的关系三元组进行后验一致性校验。具体地，选取性能较优的大模型作为主要事实评估模型，并使用另一模型对评估结果进行复核，以降低单一模型判断波动对结果稳定性的影响。对于未通过评估的结果，不直接保留，而是反馈至抽取阶段重新生成，从而形成“抽取—评估—重抽”的闭环过程。整体流程如图 4.6 所示。




图 4.6 多模型协同事实评估方法流程图

事实评估主要从三个维度展开，分别对应关系三元组在逻辑合理性、语义完整性和领域常识一致性上的质量要求。

1. 因果逻辑事实验证

该维度用于判断实体与关系是否满足文本语义和本体约束下的合理连接，重点检查关系是否存在方向倒置、逻辑断裂或主体客体错配等问题。例如，组织与上级组织之间的隶属关系、资源或设施与地点之间的部署关系、组织或角色与事件之间的参与

关系，均应与原句语义和预定义关系模式保持一致。

2. 语义完整事实验证

该维度用于判断复合实体、长实体以及事件类表达是否被完整抽取，避免将关键信息不当地拆分、截断或遗漏，从而影响三元组语义的完整表达。

3. 领域常识事实验证

该维度结合当前垂直领域文本场景中的一般事实规律与领域常识，对明显不合理的关系进行过滤，以抑制模型幻觉和表面合理但实际失真的抽取结果。

为使上述三类评估准则在实际执行中稳定落地，本章进一步将其组织为面向主评估模型的事实评估提示模板，要求模型围绕逻辑合理性、语义完整性与领域常识一致性对候选三元组逐项判断，并输出结构化评估结论。为便于展示提示组织形式，下面给出一个面向军事新闻数据集的事实评估 Prompt 示例：

你是一名军事新闻关系抽取审核专家。请对给定三元组执行事实一致性评估，给出二值判断，并输出 JSON 结果。

评估要求：

1. 逻辑/方向一致性：

- ``tested_by``: ``Asset -> Actor``，文本明确表达试验、验收、海试、接装或测试关系。
- ``provided_by``: ``Asset -> Actor``，尾实体是提供方、出租方或交付来源主体。
- ``provided_to``: ``Asset -> Actor``，尾实体是接收方、租借方或交付对象主体。
- ``deployed_by``: ``Asset -> Actor``，尾实体是部署、派出、操作或掌控该资产的组织。
- ``deployed_to``: ``Asset -> Place``，尾实体是部署、驶往、驻扎或前往的地点。
- ``occurs_at``: ``Asset/Actor -> Place``，尾实体是与该实体直接相关的地点表达。
- ``occurs_on``: ``Asset/Actor -> Time``，尾实体是与该实体直接相关的时间表达。
- ``has_count``: ``Actor/Asset -> Number``，尾实体是人数、规模、金额或数量表达。
- ``targeted_at``: ``Actor/Asset -> Actor/Asset/Place``，文本要明确存在针对、打击、瞄准、牵制等目标关系。
- ``equipped_with``: ``Actor/Asset -> Asset``，文本要明确表达搭载、配备、换装等关系。
- ``incident_with``: ``Actor/Asset -> Actor/Asset/Place``，文本要明确表达事故、故障、冲突、伤亡等事件中的直接关联。

三元组关系方向必须正确，且能在原句中找到依据。

2. 语义完整性：

复合实体和长实体需完整抽取，实体必须来自原句原文。

3. 军事常识一致性：

三元组应符合基本军事常识，但不得补充原句未出现的实体或关系。

若关系类型不在白名单、实体不在原文、文本不支持、方向错误或语义不完整，则判为 `false`。

输出要求：

仅输出 JSON 数组，顺序与输入 `triples` 一致。

格式：

```
{"s": "...", "p": "...", "o": "...", "ok": true/false, "reason": "..."}

```

`reason` 用简短中文，如“文本不支持”“方向错误”“实体不完整”。

关系白名单：

```
{predicates}

```

输入文本：

```
{text}

```

待评估三元组：

```
{triples_json}

```

在具体执行过程中，对每条候选关系三元组依次开展上述三类事实评估，并以通过或不通过的形式给出判断；主评估模型给出初步结论后，再由复核模型对评估结果进行一致性检查。设候选关系三元组为 $\tau = (h, r, t)$ ，三类事实评估函数分别记为

$$f_{\text{logic}}(\tau), \quad f_{\text{semantic}}(\tau), \quad f_{\text{commonsense}}(\tau) \in \{0, 1\}, \quad (4.6)$$

式 (4.6) 中的函数取值为 1 表示对应维度评估通过，则三元组的最终保留条件可表示为

$$f_{\text{keep}}(\tau) = f_{\text{logic}}(\tau) \wedge f_{\text{semantic}}(\tau) \wedge f_{\text{commonsense}}(\tau). \quad (4.7)$$

式 (4.7) 表示三类事实评估均通过时才保留该三元组。为降低单一模型判断波动对筛选结果稳定性的影响，本章还为复核模型设置独立的复核提示模板，使其在读取候选三元组与主评估结果后，对评估结论进行再次核验并给出是否一致的判断。为便于展示提示组织形式，下面给出一个面向军事新闻数据集的多模型复核 Prompt 示例：

你是一名独立的军事新闻事实核验专家。现给定原句、待评估三元组 `triples`，以及模型A的初步判断 `modelA_judgements`。请独立复核每条三元组是否被原句直接支持，并必要时纠正模型A的判断。

复核标准：

1. 逻辑/方向一致性：{predicates_rules};
2. 语义完整性：{semantic_rules};
3. 军事常识一致性。

若关系类型不在白名单、实体不在原文、存在否定语义、文本不支持或方向错误，则判为 `false`。

输出要求：

仅输出 JSON 数组，顺序与 `triples` 一致。

格式：

```
{ "s": "...", "p": "...", "o": "...", "ok": true/false, "reason": "..." }
```

不要输出多余字段或解释。

输入文本：

```
{text}
```

待复核三元组：

```
{triples_json}
```

模型A评估结果：

```
{modelA_judgements_json}
```

只有当三项评估均通过时，该三元组才被保留为高置信银标结果；若任一维度未通过，则将该结果判为无效，并回流至抽取模块重新生成。

通过这种方式，事实评估模块不只是对抽取结果进行事后筛选，更作为银标数据构建闭环中的质量控制环节，参与训练样本的持续修正与优化，最终提升自动标注数据在事实性、完整性与一致性方面的整体质量。

4.4 实验设计与结果

4.4.1 数据集与实验设置

本章实验使用带金标的公开实体关系抽取数据集以及自建军事新闻语料，分别用于评测结构化抽取性能与目标垂直领域真实文本上的方法可用性。其中，医学领域数据参考 CMeIE/CMeIE-V2 及 CBLUE 基准中的中文医学信息抽取任务^[64-65]，科学文档领域数据采用 SciER 数据集^[66]。各数据集的基本规模及其承担的评测职责如表 4.2 所示。

实验中，CMeIE-V2 与 SciER 均使用进行了实体关系类型的筛选，其中 CMeIE-V2 使用关系标签数量靠前的“临床表现”、“药物治疗”和“病因”三种关系作为测试语料，分别包含 4153、1352 和 903 条实体关系对，对应语句数量为 1472、656 和 415 条；SciER 使用“Used-For”、“Part-Of”、“Compare-With”和“SubClass-Of”四种关系作为测试语料，分别包含 343、214、175 和 114 条实体关系对。自建军事新闻语料来自公开可获取的多源军事新闻文本，来源包括中国军网、国防部官网、中央主流媒体军事频道、综合门户新闻频道、百度新闻聚合入口、微信公众号及课题组前期自采数据等，清洗后共形

表 4.2 实验数据集及其评测职责说明

数据集	领域	样本规模	参与评测指标
CMeIE-V2	医学领域	14339 条样本, 64835 个三元组	Precision、Recall、F1、可解析率、幻觉率、合规率、一致率
SciER	科学文档领域	原始数据包含 106 篇完整科学出版物, 覆盖超过 24000 个实体和 12000 个关系	Precision、Recall、F1、可解析率、幻觉率、合规率、一致率
自建军事新闻领域语料库	军事新闻领域	10647 份军事新闻报道	可解析率、幻觉率、合规率、一致率

成 10647 条文本段, 随机取 2000 条文本作为本章质量评估样本, 其 schema 合规性判定以第三章的表 3.3 定义的军事新闻领域实体类型与关系类型为准。

实验模型配置如表 4.3 所示。DeepSeek-V3.2 与 GPT5.2 分别独立完成全部对比实验, ERNIE-4.5 用于复核阶段; 相关模型来源分别参考 DeepSeek-V3.2 技术报告、OpenAI GPT-5.2 发布说明和 ERNIE 4.5 技术报告^[67-69]。所有方法共享相同的数据输入、输出格式、关系集合与评测标准, 以保证比较公平。

表 4.3 实验模型设置

角色	模型名称	用途
生成模型	DeepSeek-V3.2	作为主生成模型完成实验
生成模型	GPT5.2	作为主生成模型完成实验
事实评估模型	DeepSeek-V3.2 / GPT5.2	对模型输出的三元组结果进行事实评估, 与生成模型保持一致
复核模型	ERNIE-4.5	对事实评估结果进行复核

SO-CoT 构造阶段, 在 CMeIE-V2、SciER 和自建军事新闻语料上均固定抽取 100 条种子样本, 且 DeepSeek-V3.2 与 GPT5.2 分别独立构造各自的 SO-CoT。为避免提示优化样本与最终评测样本重叠, 用于 SO-CoT 提示构造和反馈迭代的种子样本不进入第 5 章最终测试集; 其对应文本仅保留在第 5 章训练/验证候选集合中。第 5 章最终测试集采用固定留出划分, 并与本章 Prompt 自优化样本隔离。除特别说明外, 实验统一运行参数设置如下:

```
temperature = 0.2
top-p = 0.9
```

```

random_seed = 42
max_output_length = 1024 tokens
fact_evaluation_feedback = enabled
max_regeneration_rounds = 2

```

实验统一要求单条样本输出为合法的纯 JSON 三元组列表，作为后续可解析率统计的判定基础。对于 Schema-aware SC-CoT 基线，先由同一生成模型对输入文本执行候选实体及类型暴露，再基于人工编写的 schema-aware CoT 提示对每个样本独立执行 3 次思维链生成。随后按三元组粒度进行一致性聚合，仅保留出现次数不少于 2 次的结果，并进一步施加原文存在性、关系集合合法性、实体类型与关系类型匹配及去重等轻量规则过滤，其多路径采样与一致性聚合思想参考 Self-Consistency CoT^[63]。

4.4.2 对比实验、消融实验与评价指标

本章将实验方法设置划分为两类。第一类为横向对比实验，用于考察本文方法相对于现有的大语言模型抽取策略及已有相近研究思路的性能差异；第二类为消融实验，用于分析本文方法内部不同模块对银标数据质量的影响。

横向对比方法的选择遵循由简单到复杂、由低成本到高约束的原则。LLM 一次生成方法代表不引入思维链提示和后验校验机制时的大模型直接抽取方案，可作为最低成本的基础基线；人工 CoT 提示方法代表依赖人工经验设计推理链的提示增强方案；Schema-aware SC-CoT 方法代表结合模式约束、自一致性生成与规则过滤的抽取方案；Model Collaboration 方法代表已有协作式实体关系三元组抽取思路。本文完整方法则在 SO-CoT 自优化提示基础上进一步引入多模型事实评估、复核与回流重抽机制，用于验证闭环式银标数据构建流程的整体效果。

其中，Model Collaboration 基线参考 Ding 等提出的关系三元组抽取模型协作思路^[70]，先由同一生成模型识别候选实体对，再将候选实体对嵌入提示中完成三元组抽取；Schema-aware SC-CoT 基线则基于 Self-Consistency CoT 的自一致性思想^[63]，并在人工构造的 schema-aware CoT 提示基础上显式加入实体类型、关系集合及类型匹配规则约束。除特别说明外，所有方法均分别在 DeepSeek-V3.2 和 GPT5.2 上独立运行。

横向对比方法设置如表 4.4 所示，消融实验设置如表 4.5 所示。消融实验按照“LLM 一次生成—人工 CoT 提示—SO-CoT 提示—SO-CoT+ 事实评估”的顺序逐步加入任务分解、自优化提示、多模型事实评估、复核与回流重抽机制，用于观察本文方法内部

模块对银标数据质量的贡献。

表 4.4 横向对比方法设置说明

方法	选择依据
LLM 一次生成	验证无 CoT、无评估条件下的大模型直接抽取能力
人工 CoT 提示	验证人工设计推理链对自动标注结果的影响
Schema-aware SC-CoT	验证固定 CoT、多次生成、一致性聚合和规则筛选的效果
Model Collaboration	与已有候选实体对协作抽取思路进行比较
SO-CoT+ 事实评估	验证自优化 CoT、多模型事实评估与回流重抽闭环的整体效果

表 4.5 消融实验设置说明

方法	消融目的
LLM 一次生成	去除 CoT 与事实评估，作为基础参照
人工 CoT 提示	分析人工推理链提示的作用
SO-CoT 提示	分析自优化 CoT 相对于人工 CoT 的作用
SO-CoT+ 事实评估	分析事实评估、复核与回流重抽机制的增益

为系统评估不同方法输出结果的质量与可用性，本章从三元组级抽取质量、结构可靠性和输出稳定性三个层面设置评价指标。

(1) 三元组级抽取质量指标

在带有金标结果的公开数据集上，本章采用三元组级 Precision、Recall 和 F1 作为抽取质量的主要评价指标。为适应大模型生成式输出在中文实体边界上的轻微偏移，本章不采用严格逐字符完全匹配，而采用字符级容错匹配与一对一约束的方式统计命中数。

设预测三元组为 $\hat{t} = (\hat{s}, \hat{p}, \hat{o})$ ，金标三元组为 $t = (s, p, o)$ 。对于主语、关系和宾语三个字段，如果二者满足字符串包含或连续字符重叠，且长度差不超过 2 个中文字符的条件，则视为字段匹配。字段级匹配函数定义为：

$$m(x, y) = \begin{cases} 1, & \text{若 } x \text{ 与 } y \text{ 满足上述字符级容错匹配规则,} \\ 0, & \text{其他情况.} \end{cases} \quad (4.8)$$

基于式 (4.8) 定义的字段级匹配函数，三元组级匹配函数定义为：

$$M(\hat{t}, t) = m(\hat{s}, s) \cdot m(\hat{p}, p) \cdot m(\hat{o}, o). \quad (4.9)$$

当且仅当式 (4.9) 中的 $M(\hat{t}, t) = 1$ 时，认为该预测三元组与该金标三元组匹配成功。为避免重复计数，本章采用一条预测最多匹配一条金标、一条金标最多被匹配一

次的一对一约束，并据此统计匹配成功数 N_{match} 。在全部测试样本上，以微平均方式计算 Precision、Recall 和 F1：

$$\begin{aligned} P &= \frac{N_{\text{match}}}{N_{\text{pred}}}, \\ R &= \frac{N_{\text{match}}}{N_{\text{gold}}}, \\ F1 &= \frac{2PR}{P + R}. \end{aligned} \quad (4.10)$$

式 (4.10) 中， N_{pred} 为模型输出三元组总数， N_{gold} 为金标三元组总数， N_{match} 为在字符级容错匹配和一对一约束下的成功匹配总数。对于无法解析为合法 JSON 三元组列表的输出，统一将其视为空预测集合参与 Precision、Recall 和 F1 统计。

(2) 结构可靠性指标

仅以 Precision、Recall 和 F1 评价大模型抽取结果，难以刻画其在银标数据构建中的格式稳定性与结构可用性。为此，本小节进一步定义了可解析率、幻觉率和合规率三个指标。

1. 可解析率 (Parse Rate)

如果模型针对单条样本的输出同时满足以下条件，就记为可解析：整体能够被标准 JSON 解析器成功解析；顶层结构为数组；数组中每个元素均为一个三元组对象，且包含 prompt 规定的必要字段；各字段值类型合法，不含额外嵌套错误；输出中不包含 JSON 之外的解释性自然语言或 Markdown 标记。空列表 [] 只要格式合法，也视为可解析。本章统一要求单条样本的合法输出形式为纯 JSON 三元组列表，示例如下：

```
[
  {
    "subject": "",
    "predicate": "",
    "object": "",
    "subject_type": "",
    "object_type": ""
  }
]
```


可解析率定义为：

$$\text{ParseRate} = \frac{N_{\text{parse}}}{N_{\text{all}}} \quad (4.11)$$

式 (4.11) 中, N_{parse} 表示可被成功解析为合法纯 JSON 三元组列表的样本数, N_{all} 表示数据集总样本数。

2. 幻觉率 (Hallucination Rate)

本文中的幻觉率主要用于衡量模型是否生成了缺乏原文实体证据的三元组, 具体统计头实体或尾实体无法在输入原文中定位的情况。对于任一已解析样本中的预测三元组 (s, p, o) , 若主语 s 或宾语 o 无法在输入原文中找到对应文本证据, 则记为一条幻觉三元组。文本证据查找采用与三元组评测一致的字符级容错规则: 当实体字符串与原文中的某一连续片段满足字符串包含或连续字符重叠, 且长度差不超过 2 个中文字符时, 认为该实体在原文中可定位; 若主语或宾语任一方无法定位, 则该三元组记为幻觉输出。幻觉率定义为:

$$\text{HallucinationRate} = \frac{N_{\text{hall}}}{N_{\text{pred}}^{\text{parse}}} \quad (4.12)$$

式 (4.12) 中, N_{hall} 表示已解析输出中被判定为幻觉的三元组数, $N_{\text{pred}}^{\text{parse}}$ 表示已解析样本中的预测三元组总数。

3. 合规率 (Schema Compliance Rate)

合规率用于衡量模型输出能否满足预定义的结构约束。对任一样本, 若其输出结果在解析成功后同时满足以下条件, 则记为该样本合规: 第一, 三元组中的实体类型和关系类型均落在当前数据集允许的类型集合内; 第二, 三元组字段齐全, 不存在缺失主语、缺失关系或缺失宾语的情况; 第三, 主语类型—关系类型—宾语类型组合满足预定义 schema 的约束规则。在自建军事新闻语料上, schema 约束参考前文构建的领域本体模型; 在 CMeIE-V2 和 SciER 上, 则依据各自原生数据集的类型集合与关系集合判定。对无法解析的输出则直接记为不合规。合规率定义为:

$$\text{SchemaRate} = \frac{N_{\text{schema_ok}}}{N_{\text{all}}} \quad (4.13)$$

式 (4.13) 中, $N_{\text{schema_ok}}$ 为满足 schema 约束的样本数, N_{all} 为样本总数。该指标按整条样本是否全部合法统计, 而非按单个三元组分别统计。

(3) 输出稳定性指标

大模型在相同输入下的重复运行稳定性会直接影响银标数据构建的一致性。为此，本小节定义输出一致率（Consistency Rate）作为稳定性评价指标。在每个数据集上，随机抽取 100 条样本构成固定评测集合；在同一数据集下，该抽样集合对所有方法和所有生成模型保持一致。对每条样本，在完全相同的提示模板和解码参数设置下重复运行 3 次。为消除无关格式差异，首先对每次运行得到的已解析结果进行规范化处理，包括去除首尾空格、统一全角半角符号、删除重复三元组，并按固定顺序排序，得到该次运行的规范化三元组集合。若某条样本在 3 次运行中得到的规范化三元组集合完全一致，则记为该样本输出一致；若其中任一次运行输出无法解析，或任意两次运行得到的三元组集合不同，则记为不一致。输出一致率定义为：

$$\text{Consistency} = \frac{N_{\text{consistent}}}{N_{\text{sample}}} \quad (4.14)$$

式 (4.14) 中, $N_{\text{consistent}}$ 表示在重复运行中保持三元组集合完全一致的样本数, N_{sample} 表示参与稳定性评测的样本数, 本章实验中 $N_{\text{sample}} = 100$ 。

上述可解析率、幻觉率、合规率和一致率均由预先编写的规则脚本自动判定，以统一不同模型、不同方法和不同数据集上的评测口径，并保证后续结果分析的可复现性与可比性。各项评价指标及其统计口径如表 4.6 所示。

表 4.6 评价指标及其统计口径

指标	统计层级	说明
Precision	三元组级	反映模型输出三元组中与金标结果匹配的比例
Recall	三元组级	反映模型对金标三元组的覆盖能力
F1	三元组级	综合衡量抽取结果的准确性与覆盖性
可解析率	样本级	反映结果能否被后续自动处理流程直接消费
幻觉率	三元组级	主要反映预测三元组中头实体或尾实体缺乏原文证据的比例
合规率	样本级	公开数据集按原生关系集合统计，自建军事新闻语料按第三章定义领域本体统计
一致率	样本级	反映相同输入和相同参数设置下模型输出的重复运行稳定性

4.4.3 实验结果与分析

表 4.7 至表 4.8 给出了不同方法在 CMeIE-V2 和 SciER 两种公开数据集上的实验结果，下面分别从横向对比实验和消融实验两个层次分析结果。

表 4.7 不同模型在 CMeIE-V2 数据集上的实验结果比较

模型	方法	P(%)	R(%)	F1 (%)	可解析率 (%)	幻觉率 (%)	合规率 (%)	一致率 (%)
DeepSeek-V3.2	LLM 一次生成	58.10	59.71	58.89	86.43	15.18	74.96	69
	人工 CoT	61.30	64.09	62.66	91.90	13.92	81.48	71
	SO-CoT	71.84	75.62	73.68	96.88	6.58	90.74	83
	SO-CoT+ 事实评估	74.66	74.02	74.34	96.09	5.04	92.41	84
	Schema-aware SC-CoT	71.73	69.61	70.65	92.54	7.28	89.61	83
	Model Collaboration	67.41	66.08	66.74	84.27	9.92	80.46	71
GPT5.2	LLM 一次生成	64.00	61.00	62.46	88.02	12.64	76.41	70
	人工 CoT	66.40	63.41	64.87	93.26	11.37	82.08	73
	SO-CoT	73.58	79.66	76.50	97.22	4.61	90.51	85
	SO-CoT+ 事实评估	74.21	77.05	75.60	96.36	4.27	92.94	84
	Schema-aware SC-CoT	73.38	72.16	72.76	93.23	5.84	90.37	83
	Model Collaboration	66.92	61.94	64.33	84.61	7.44	81.26	75

(1) 横向对比结果分析

从横向对比结果看，LLM 一次生成虽然调用成本最低，但其输出结果更容易出现格式不稳定、关系方向错误和事实幻觉等问题，难以直接作为后续学生模型训练数据。以表 4.7 和表 4.8 为例，LLM 一次生成在两个公开数据集上的可解析率、幻觉率和合规率整体弱于加入推理链或后验校验的设置，说明直接生成更适合作为基础参照，而不是高质量银标数据构建方案。

人工 CoT 提示能够一定程度上改善模型的抽取过程，但其效果依赖人工设计经验，且难以保证在不同领域文本上的稳定性。Schema-aware SC-CoT 通过多次生成和一致性聚合提高了输出稳定性，但主要依赖固定提示和后验规则过滤，对事实性错误的识别能力有限。Model Collaboration 方法通过候选实体对与关系抽取协同提升了部分抽取效果，但其目标更偏向关系三元组生成本身，对银标数据构建中的事实评估、错误回流与本体合规性控制考虑不足。相比之下，本文完整方法将 SO-CoT 自优化提

表 4.8 不同模型在 SciER 数据集上的实验结果比较

模型	方法	P(%)	R(%)	F1 (%)	可解析率 (%)	幻觉率 (%)	合规率 (%)	一致率 (%)
DeepSeek-V3.2	LLM 一次生成	63.53	63.00	63.26	89.12	15.31	79.44	75
	人工 CoT	67.60	68.32	67.96	93.54	13.88	85.22	76
	SO-CoT	74.11	77.62	75.82	96.84	6.72	91.41	89
	SO-CoT+ 事实评估	74.69	75.03	74.86	97.18	5.88	92.77	89
	Schema-aware SC-CoT	73.67	74.88	74.27	92.36	6.81	90.47	87
	Model Collaboration	68.22	66.71	67.46	86.63	9.17	84.12	75
GPT5.2	LLM 一次生成	69.64	64.54	66.99	90.48	12.58	80.17	73
	人工 CoT	73.76	64.78	68.98	94.18	11.96	84.61	77
	SO-CoT	78.26	82.54	80.37	96.24	5.08	91.06	88
	SO-CoT+ 事实评估	79.80	81.02	80.45	97.14	4.61	93.26	87
	Schema-aware SC-CoT	77.84	76.41	77.12	93.31	5.36	90.94	88
	Model Collaboration	72.94	69.72	71.29	86.77	7.82	83.24	81

示、多模型事实评估和回流重抽组织为闭环流程，因此更适合作为面向领域知识图谱构建的银标数据生产方案。

从公开数据集的结果看，SO-CoT+ 事实评估在多数设置下取得了更低的幻觉率和更高的合规率。例如在 CMeIE-V2 上，DeepSeek-V3.2 的 SO-CoT+ 事实评估将幻觉率控制在 5.04%，低于 LLM 一次生成的 15.18%、人工 CoT 的 13.92%、Schema-aware SC-CoT 的 7.28% 和 Model Collaboration 的 9.92%；GPT5.2 上也呈现出相似趋势。在 SciER 上，完整方法同样保持了较低幻觉率和较高合规率。需要说明的是，本文方法并不是单纯追求最低单次调用成本，而是面向后续学生模型训练提供质量更高、结构更稳定的银标数据。

(2) 消融实验结果分析

从消融实验角度看，各实验组反映了本文方法内部模块逐步加入后的效果变化。LLM 一次生成作为基础版本，不包含任务分解、错误反馈和事实评估机制，因此容易受到大模型生成随机性和幻觉问题影响。人工 CoT 提示在任务步骤拆解方面有所增强，说明显式推理链对实体关系联合抽取具有一定帮助。进一步地，SO-CoT 提示

通过少量种子样本和错误反馈自动优化推理过程,使提示内容更加贴合当前领域的抽取任务,相比固定人工 CoT 具有更好的适应性。

以 CMeIE-V2 为例,DeepSeek-V3.2 的 Precision、Recall 和 F1 由人工 CoT 的 61.30%、64.09% 和 62.66% 提升至 SO-CoT 的 71.84%、75.62% 和 73.68%; GPT5.2 的三项指标也由 66.40%、63.41% 和 64.87% 提升至 73.58%、79.66% 和 76.50%。在 SciER 上同样可以观察到相似变化,DeepSeek-V3.2 的 F1 由人工 CoT 的 67.96% 提升至 SO-CoT 的 75.82%, GPT5.2 的 F1 由 68.98% 提升至 80.37%。这些结果说明,基于种子样本错误反馈迭代得到的 SO-CoT 相比人工预先编写的通用推理链,更能贴合当前实体关系联合抽取任务的需求。

SO-CoT+ 事实评估则在抽取后引入多模型协同判断、复核与回流重抽机制,能够进一步筛除或修正事实依据不足、关系方向错误和不满足本体约束的样本,从而提升银标数据的整体可用性。以 CMeIE-V2 为例,在 DeepSeek-V3.2 上,加入事实评估后幻觉率由 SO-CoT 的 6.58% 下降至 5.04%,合规率由 90.74% 提升至 92.41%; GPT5.2 上对应由 4.61% 降至 4.27%,由 90.51% 提升至 92.94%。SciER 上也呈现出类似趋势。然而这一阶段的目标并不是单纯增加匹配三元组数量,而是优先过滤高风险结果,所以 F1 并不总是同步上升,例如 GPT5.2 在 CMeIE-V2 上的 F1 由 SO-CoT 的 76.50% 小幅回落到 75.60%,DeepSeek-V3.2 在 SciER 上也由 75.82% 降至 74.86%。这说明多模型事实评估主要将额外成本转化为更低的幻觉率和更高的结构合法性。

还需要指出的是,本章所提方法在 SciER 上的提升幅度整体略高于 CMeIE-V2,推测是 CMeIE-V2 上的关系判别难度相对更高。结合数据集特点来看,CMeIE-V2 的关系类型更为领域化,部分关系之间语义边界较近,模型更容易出现关系混淆或方向偏差,因此即使在引入 SO-CoT 后,整体效果仍略弱于 SciER。也就是说,该方法虽然在两个公开数据集上都取得了稳定提升,但增益的效果依然受到关系类型复杂度和领域专业性的影响。

下面展示的是在 CMeIE-V2 数据集上进行实验时,两组体现 LLM 一次生成的典型错误以及评估模型纠错的典型样例:

在下面这个样本中,初次抽取输出的是:

样本: 小细胞肺癌^①可有特征性的咳嗽、呼吸困难、咯血、体重减轻、发热、关节痛、皮肤病变、盗汗,或者无症状。

初次抽取: {"s": "小细胞肺癌", "p": "临床表现", "o": "无症状"}

随后评估模型判为 **false**，理由是“无症状不是临床表现，而是症状缺失”，回流后该三元组被删除。

在另一个样本中，初次抽取输出的是：

样本：乙型肝炎@### 同性恋 与HBV感染性伴侣的性接触是传播的重要途径。
初次抽取：{"s": "同性恋与HBV感染性伴侣的性接触", "p": "病因", "o": "乙型肝炎"}

评估模型指出文本说的是传播途径，不是直接病因，而且还补充说明医学常识上直接病因应是 HBV 病毒。

下面展示另一组体现多模型事实评估中复核模型如何纠错的样例：

样本：胆管癌@## 病因学 感染，炎症和癌症之间有密切的关联。
一次生成阶段输出：
感染 -> 病因 -> 胆管癌
炎症 -> 病因 -> 胆管癌

评估模型先把这两条都判成了 **true**，理由是“语义和方向一致”；但复核模型进一步指出，原文只表达了“关联”，并没有直接支持‘感染/炎症是胆管癌病因’，因此把两条都改判为 **false**，回流重抽后修正，这属于幻觉过滤；在另一个样本中，一次生成把相关病理描述都抽成了临床表现：

样本：十二、腺泡型软组织肉瘤 腺泡型软组织肉瘤 (alveolar soft part sarcoma) 是一临床-病理实体，小儿少见，多见于15岁左右的青少年，女性多于男性。切面呈黄白或灰红色，中央含坏死和出血区，肿瘤周围有较粗的血管。
一次生成：
切面呈黄白或灰红色 -> 临床表现
中央含坏死和出血区 -> 临床表现
肿瘤周围有较粗的血管 -> 临床表现

评估模型最初把这三条判成了 **true**，但复核模型将其改判为 **false**，理由统一为“o 为病理特征，非临床表现”，回流重抽后修正，这属于类型不匹配过滤。

在这些样例中，事实评估与复核阶段能够对“表面可解析但语义并不成立”的三元组进行过滤，并通过回流重抽删除或修正高风险结果。这说明多模型事实评估并不是简单的格式检查，而是可以在一定程度上承担语义和类型校验的作用。

在自建军事新闻语料上的结果如表 4.9所示，由于该语料库没有金标三元组抽取结果，因此重点考察了实验结果的可解析率、幻觉率、合规率和一致率。结果显

表 4.9 自建军事新闻语料上的银标数据可用性评估结果

模型	方法	可解析率 (%)	幻觉率 (%)	合规率 (%)	一致率 (%)
DeepSeek-V3.2	LLM 一次生成	89.94	14.63	80.58	76
	人工 CoT	94.02	13.22	86.31	77
	SO-CoT	97.14	5.97	92.36	89
	SO-CoT+ 事实评估	97.42	4.36	93.88	87
	Schema-aware SC-CoT	94.73	6.22	91.36	88
	Model Collaboration	87.41	8.84	84.96	75
GPT5.2	LLM 一次生成	91.22	11.84	81.35	75
	人工 CoT	94.87	10.92	85.73	79
	SO-CoT	97.36	4.22	92.14	89
	SO-CoT+ 事实评估	97.63	3.71	94.57	87
	Schema-aware SC-CoT	94.08	4.87	91.93	89
	Model Collaboration	87.68	6.92	84.68	82

示, DeepSeek-V3.2 在 SO-CoT 设置下已达到 97.14% 的可解析率、5.97% 的幻觉率和 92.36% 的合规率; 进一步加入多模型事实评估后, 可解析率提升至 97.42%, 幻觉率下降至 4.36%, 合规率提升至 93.88%。GPT5.2 上的结果与此接近, 其在 SO-CoT+ 事实评估下分别达到 97.63%、3.71% 和 94.57%。从一致率看, 两种模型在 SO-CoT 设置下均达到 89%, 加入事实评估后略有波动, 但仍保持在 87% 左右。结合本章实验目标来看, 这组结果说明, 本章所提方法在真实军事新闻文本上生成的数据已经具有较好的结构可解析性、较低的事实噪声和较高的 schema 一致性, 能够较好地支撑后续学生模型训练。

4.4.4 结果讨论

本文方法相较于 LLM 一次生成确实引入了额外的大模型调用成本, 由于包含初始实体关系抽取、多模型事实评估、复核判断以及必要情况下的回流重抽, 单样本平均调用次数相较于单次生成的整体 token 消耗会增加 2 倍左右。然而本章方法的目标并不是作为长期的在线抽取服务, 而是作为银标数据的构建流程, 对于银标数据构建任务而言, 自动标注结果中的事实幻觉、关系方向错误和本体不合规样本会直接进入

后续学生模型训练，并可能被学生模型学习和放大。因此，在训练数据构建阶段投入额外的大模型调用成本，可以降低噪声样本比例，提高训练数据的事实可靠性和结构一致性，总体来说是接受的。

从实验结果看，完整流程在可解析性、事实性和本体合规性等指标上均优于直接生成和仅使用 CoT 提示的方法，说明额外成本主要转化为了训练数据质量的提升。进一步地，本章构建的高质量银标数据将作为第 5 章轻量化本地抽取模型的训练基础，使后续批量抽取过程能够由参数高效微调后的本地模型完成。

4.5 本章小结

本章围绕垂直领域标注数据稀缺、自动标注结果不稳定的问题，提出了一种基于 SO-CoT 自优化与多模型事实评估的银标数据构建方法，并在军事新闻领域实例上产出了一份包含 10647 份军事新闻报道和 40565 个实体关系三元组抽取结果的知识抽取数据集。横向对比结果说明，本文方法相较于直接生成、人工 CoT 提示以及已有相近的大模型协作抽取方法，在银标数据可解析性、事实性和本体合规性方面具有更稳定的表现；消融实验则表明，SO-CoT 自优化提示、多模型事实评估和回流重抽机制均对提升银标数据质量具有积极作用。尽管完整流程相较于单次生成引入了额外的大模型调用成本，但该成本主要发生在 Teacher 端离线银标数据构建阶段，换取的是更低的幻觉率、更高的合规率和更稳定的数据可用性。总体来看，本章方法较好地完成了高质量的数据供给任务，为后续轻量化模型的训练提供了更可靠的数据基础。

5 面向轻量化本地部署的参数高效本体约束知识抽取方法

5.1 问题描述

第四章已经围绕军事新闻语料构建了可用于训练的银标数据集，但对本文而言，数据集的建立并不是终点，真正需要解决的是如何将这些数据进一步转化为一种可低成本部署、可持续运行且结果可控的知识抽取能力。尤其在面向垂直领域知识图谱构建的场景中，抽取模型不仅要能够识别领域文本中指定的实体和关系，还需要在资源受限的条件下保持较好的稳定性，并使输出结果能够与领域本体保持一致，便于后续入库和应用。

从实际部署需求来看，直接依赖超大参数模型进行在线抽取并不现实。一方面，军事新闻文本更新频繁，若长期依赖大模型推理，部署成本、推理时延和硬件资源开销都会成为明显限制；另一方面，即使采用小参数模型并结合参数高效微调完成领域适配，也只能部分解决“能否抽取”的问题，并不能自动保证“抽取得是否可用”。换句话说，模型经过微调后可以具备一定的领域抽取能力，但其输出仍可能存在关系方向错误、实体类型与关系类型不匹配、结构不完整或结果波动较大等问题，这些都会直接影响后续知识图谱的组织与存储。

同时需要注意的是，第四章中的自优化提示与多模型事实评估方法主要服务于银标数据构建，其目标是在可接受的大模型调用成本下提高自动标注结果的事实可靠性和本体合规性。若将该类提示式抽取流程直接用于长期批量抽取，仍会面临推理成本、输出波动和本地部署条件等限制。因此，本章并不将大语言模型仅作为一次性提示抽取器使用，而是进一步关注如何将其作为可本地部署的生成式基座模型，通过领域适配、结构约束和候选选择机制形成稳定的抽取能力。

对于知识图谱构建任务而言，抽取结果是否可用，不能只看句子层面的表面正确性，还要看其是否满足领域本体约束、是否具有统一的结构形式，以及是否能够稳定转化为合法三元组。如果模型输出中存在大量类型冲突、非法关系或难以解析的结果，那么即使局部评价指标较高，也仍然难以支撑后续的图谱入库、查询与应用服务。因此，第五章关注的重点，不只是如何在有限资源条件下训练一个能够完成知识抽取的小模型，更是如何让该模型输出的结果在结构上更规范、在语义上更一致、在工程上更易使用。

基于上述考虑，本章希望解决两个相互关联的问题：其一，在本地部署和算力受限的条件下，如何借助参数高效微调方法完成领域知识抽取模型的低成本适配；其二，在模型生成过程中，如何引入领域本体约束与结果选择机制，减少非法三元组和随机波动，使输出结果更符合领域知识图谱构建的要求。围绕这两个问题，本文进一步提出一种面向轻量化本地部署的参数高效本体约束知识抽取方法，在保留领域抽取能力的同时，提高结果的结构合法性和稳定入库能力，为后续知识图谱构建与应用验证提供基础。

5.2 参数高效的本体约束知识抽取流程

参数高效的本体约束知识抽取方法是一种结合大语言模型领域适配能力与领域本体约束机制的知识抽取方法。这种方法首先利用参数高效微调技术，使基座模型具备对领域文本的理解与实体关系联合抽取能力；随后，在模型生成候选结果的基础上，结合领域本体规则对抽取结果进行约束、筛选与重排序，从而输出更加稳定、更加符合领域结构要求的知识结果。




图 5.1 参数高效的本体约束知识抽取流程

图 5.1 展示了参数高效本体约束抽取的整体流程。该流程主要分为四个阶段：离线领域适配、候选结果生成、本体约束与候选评分、结构化输出。以下是每个阶段的详细说明：

1. 离线领域适配阶段：在这个阶段需要收集和整理用于模型微调的指令数据，所使用到的训练数据主要来源于上一章节基于自建军事新闻语料构建的银标数据集，需要将其进一步组织为适用于指令微调的训练样本。在此基础上，选取开源大语言模型 DeepSeek-R1-Distill-Qwen-32B 作为基座模型，并采用 QLoRA 训练策略进行参数高效微调^[11,52]。通过冻结原始参数、对模型权重进行低比特量

化，并在部分线性层中引入低秩适配矩阵，可以在较低训练开销下完成领域知识抽取能力的适配，使得方法适用于各种显卡算力及显存容量有限的环境，大大拓展了本章方法的应用范围。

2. 候选结果生成：在完成领域适配后，将新闻段落输入到知识抽取模型中，由模型根据任务指令生成结构化的抽取结果。与单次确定性生成方式不同，本章方法针对同一输入文本采用受控随机采样策略生成若干个候选抽取结果集合。每个候选结果集合均对应一次完整的实体关系联合抽取结果，包含实体识别结果及其对应的三元组关系信息。通过生成多个候选结果，可以为后续结果筛选提供更充分的比较空间。
3. 本体约束与候选评分：在候选结果生成后，需要结合本体规则对抽取结果进行进一步分析，包括关系类型集合、实体类型集合以及实体和关系之间的匹配规则。对于每个候选结果，分别从模型置信度、本体规则满足度以及错误项数量三个方面进行综合评分。其中模型置信度由生成序列的 `logprob` 给出，规则满足率用于衡量候选结果中关系与本体约束的一致程度，错误项则主要包括重复三元组、格式错误问题。经过归一化处理后，上述指标共同构成候选结果的综合得分。
4. 结构化输出：在完成候选评分之后，选取得分最高的候选结果作为最终输出结果，并以统一的结构化 JSON 形式返回。通过这一过程，模型输出结果不再仅依赖单次生成，而是在领域适配、本体规则约束与候选结果选择的共同作用下得到进一步校正，这样不仅可以提升抽取结果的稳定性和结构合法性，也能够减少不合理三元组和错误关系的产生。该目标与统一结构生成、受限解码和语法约束生成研究中的结构控制思想相一致^[22,31-32]。

5.2.1 基于 QLoRA 的领域适配

为了使模型具备更好的领域知识抽取能力，需要对开源大语言模型进行领域适配。本章的核心思路是：基于前文构建的银标数据，组织面向军事新闻知识抽取任务的指令微调数据集，再结合参数高效微调技术 QLoRA^[11]，对基座模型进行低成本的任务适配，使其能够理解军事新闻文本中的领域表达，并按照指令输出结构化的抽取结果。

(1) 指令数据的构建

构建高质量指令数据是实现领域知识抽取的基础，训练数据需要覆盖军事新闻中的主要实体类型和关系类型，还需要尽量保证输出结果具有统一的结构化形式，便于后续进行规则过滤、候选比较以及图谱入库处理。

相较于直接使用通用领域信息抽取数据，在自建军事新闻语料库上构建的数据可以更好地反映军事新闻领域里的高频实体、关系表达及其组合模式，模型在训练阶段就能够接触到大量符合军事新闻领域特点的抽取实例，从而更好地学习领域术语、事件叙事模式以及结构化输出要求之间的对应关系。本章从上一章构建的银标数据中组织五种实体类型，包括行动主体 (Actor)、军事资产 (Asset)、地点 (Place)、时间 (Time) 和数量 (Number)，以及 11 种关系类型，包括 `tested_by`、`provided_by`、`provided_to`、`deployed_by`、`deployed_to`、`equipped_with`、`targeted_at`、`incident_with`、`occurs_at`、`occurs_on` 和 `has_count`。

训练数据集以新闻段落作为基本输入粒度，每条训练样本主要由三个部分组成：

1) **任务指令**：用于明确当前任务是军事新闻文本的实体关系联合抽取任务，并规定输出需要满足结构化结果的组织要求；

2) **输入文本**：即待抽取的军事新闻段落文本，作为模型进行语义理解知识抽取的依据；

3) **目标输出**：由数据集的抽取结果转换得到，用于指导模型学习从新闻段落到实体关系结果的映射过程。

以下是一个示例训练样本的任务指令和输入文本样例：

你是一个军事新闻领域的实体关系抽取模型。我将给你一条由” ” ”分割的新闻报道，请根据要求抽取以下实体和关系。

军事新闻实体类型定义：

- 1) **Actor**：国家、组织、机构、部队、企业及人员群体等行动或参与主体；
- 2) **Asset**：装备、平台、系统、武器、舰艇、导弹、雷达及相关物资等军事资产；
- 3) **Place**：国家、地区、基地、港口、海域及设施空间等地点；
- 4) **Time**：时间表达；
- 5) **Number**：数量、规模、金额及统计值等数值表达。

军事新闻关系类型定义：

- 1) **tested_by**：某项军事资产被某主体测试、试验或检验；
- 2) **provided_by**：某项军事资产由某主体提供、交付、转让或租借；
- 3) **provided_to**：某项军事资产被提供、交付、转让或租借给某主体；

4) `deployed_by`: 某项军事资产由某主体部署、列装或投送;

5) `deployed_to`: 某项军事资产被部署到某地点;

6) `equipped_with`: 某主体或平台配备、搭载或安装某项军事资产;

7) `targeted_at`: 某主体或资产将另一主体、资产或地点作为打击、攻击或拦截对象;

8) `incident_with`: 某主体或资产与另一主体、资产或地点发生冲突、事故或对抗事件;

9) `occurs_at`: 与某主体或资产相关的事实发生在某地点;

10) `occurs_on`: 与某主体或资产相关的事实发生在某时间;

11) `has_count`: 与某主体或资产相关的事实具有某个数量值。

操作步骤:

- 1) 阅读文献: 仔细阅读并理解提供的新闻报道内容。
- 2) 实体识别: 在文献中识别出行动主体 (`Actor`)、军事资产 (`Asset`)、地点 (`Place`)、时间 (`Time`) 和数量 (`Number`) 等实体, 并标注它们的类型。
- 3) 关系抽取: 基于识别的实体, 建立它们之间的上述关系。

输出要求:

- 1) 仅输出合法的 JSON 数组;
- 2) 每个三元组包含 `subject`、`subject_type`、`predicate`、`object`、`object_type` 五个字段;
- 3) 若文本中不存在明确关系, 则输出空数组 []。

输出示例: [{"subject": "爱国者导弹连", "subject_type": "Asset", "predicate": "provided_to", "object": "日本", "object_type": "Actor"}], ...]

新闻报道:

""E1据乌克兰政府网站消息, 当地时间1月11日, 乌克兰国防部表示, 英国将为乌克兰研发新型战术弹道导弹, 以增强乌克兰的火力..."

JSON:

通过这种方式, 可以将上一章已经构建完成的银标数据自然衔接到基座模型的训练流程中, 以便逐步学习军事新闻文本中的术语表达、叙事模式以及结构化输出要求之间的对应关系。

(2) 基座模型选择

本文采用了大语言模型 DeepSeek-R1-Distill-Qwen-32B 作为领域适配的基础模型。该模型属于开源的预训练模型, 是由 DeepSeek 团队通过“知识蒸馏”(Knowledge Distillation) 技术, 基于 Qwen2.5-32B 架构蒸馏而成^[52,71], 具备较好的中英文文本理解与生成能力, 能够为后续的领域任务适配提供稳定的语言基础, 同时还具有较低的部署成本, 采用 INT4 量化即可在 24GB 显存的 GPU 上进行本地推理, 更便于在本地环境下进行训练、推理和部署。

DeepSeek 团队在 DeepSeek-R1 的论文中提出了一个关键结论: 推理模式是可以

被“蒸馏”的，如果直接把大模型（R1）产生的优秀推理步骤喂给小模型（Qwen）吃，小模型的推理能力会瞬间大幅提升，甚至超过那些自己尝试用强化学习（RL）训练的小模型^[52]。而本章选用的 DeepSeek-R1-Distill-Qwen-32B 模型就是把 DeepSeek-R1 的能力提取出来，灌输给了 Qwen-2.5-32B，从而让这个较小的模型也获得了类似 R1 的深度思考能力。

表 5.1 DeepSeek-R1 与 DeepSeek-R1-Distill-Qwen-32B 特性对比

模型	DeepSeek-R1-671B	DeepSeek-R1-Distill-Qwen-32B
训练方式	大规模强化学习（RL）+ 冷启动数据	监督微调（SFT），直接学习 R1 的输出
基座模型	DeepSeek-V3-Base	Qwen-2.5-32B
优势	思维能力很高，能自我进化	性价比高，在 32B 尺寸下拥有接近 671B 模型的推理能力
训练消耗	非常昂贵的算力消耗	相对极低

表 5.1 对 DeepSeek-R1 与 DeepSeek-R1-Distill-Qwen-32B 的特性进行了对比，可以看出后者在训练方式、基座模型、优势和代价等方面都具有明显的轻量化特点，非常适合本文的研究需求。

(3) QLoRA 训练策略

对于参数规模较大的大语言模型而言，全参数微调（Full Fine-tuning）的显存占用和训练成本极高，32B 参数级别的大模型进行常规全量微调需要超过 448GB 的 GPU 内存，这对于大多数研究者来说是难以承受的。即使采用混合精度（如 16 位或 8 位）微调，仍然需要数百 GB 的显存。然而，低秩自适应（Low-Rank Adaption, LoRA）技术能够在几乎不降低模型性能以及不产生推理延迟的情况下，通过仅微调模型的一小部分参数来达到与全参数微调相似的效果^[10]。QLoRA 在 LoRA 的基础上引入了几项新的技术，包括：1）一种新的数据类型 4-bit NormalFloat（NF4），该数据类型在理论上是正态分布权重的信息优化；2）双量化（Double Quantization），对量化常量再次进行量化来减少存储需求；3）分页优化器（Paged Optimizer），管理内存峰值^[11]。图 5.2 展示了全参数微调、LoRA 微调和 QLoRA 微调在训练方式上的对比，可以看出 QLoRA 在保持较高性能的同时，显著降低了训练成本，使得大语言模型的领域适配变得更加可行和高效。

QLoRA 的基本思想可以概括为以下三个方面：




图 5.2 不同的微调方法对比

1) **冻结原始参数**: 在训练过程中, 不直接更新基座模型的大部分预训练参数, 而是将这些参数作为稳定的语言知识底座保留下来, 从而避免全参数优化所带来的高计算代价;

2) **低比特量化**: 将基座模型权重以低比特形式进行压缩表示, 以减少显存占用, 降低较大参数规模模型的训练门槛;

3) **低秩适配矩阵**: 在模型的部分线性层中引入可训练的低秩矩阵, 用于学习下游任务所需的参数增量, 使模型能够在不改变原始大规模参数的前提下完成对军事新闻抽取任务的适配。

本章方法会对基座模型进行量化处理, 并在指定层中插入可训练的低秩适配矩阵, 再基于前文构建好的军事新闻指令微调样本, 对这些新增参数进行监督训练, 从而得到一个能够根据新闻段落输入生成结构化抽取结果的 **Student** 端基础模型。通过这种方式, 模型可以在较低的训练成本下获得对军事新闻文本实体关系联合抽取任务的能力, 也为后续引入本体约束和多候选结果选择奠定了模型基础。

5.2.2 领域本体模型约束

本体模型约束的主要内容即对候选抽取结果进行合法性检查, 将模型输出限制在已有 **schema** 所允许的结构空间内, 减少关系越界、类型和格式错误的问题, 作为后续候选结果的选择提供基础。

(1) 本体模型约束

“本体约束”模块在本节中被形式化为实体类型、关系类型及其合法连接规则的匹配判断。具体而言, 若候选三元组中的头实体类型、关系类型与尾实体类型满足预先

定义的本体约束，则该三元组被认为具有结构合法性；反之，则在后续候选评分中受到惩罚或被过滤。

本章的本体约束对象，是由单个新闻报道片段生成的候选结果集合，系统会重点检查以下三个方面：1) 实体类型是否合法，判断结果中的实体类型是否属于领域本体预先定义的实体集合；2) 关系类型是否合法，判断结果中的关系标签是否属于预定义的关系集合。3) 关系连接是否合法：判断一条关系两端的实体类型，即“头实体类型—关系类型—尾实体类型”是否满足领域本体规定的连接方式。为了统一表示，可将领域本体中允许的合法连接关系记为

$$\Omega = \{(T_h, r, T_t)\}, \quad (5.1)$$

式 (5.1) 中， T_h 表示头实体类型， r 表示关系类型， T_t 表示尾实体类型。对于任意候选三元组 (e_h, r, e_t) ，若满足

$$(type(e_h), r, type(e_t)) \in \Omega, \quad (5.2)$$

若式 (5.2) 成立，则认为该三元组在结构上满足本体约束；否则，将其视为不合法结果。这个判断过程直接通过预先整理好的类型匹配规则自动完成。

本章使用的实体类型、关系类型及头尾实体匹配规则不再另行扩展，而是统一采用第三章的表 3.3 给出的最终本体约束集合。后续规则满足率计算、非法三元组判定和图谱入库前检查均以该表为准。

(2) 结构合法性约束

在经过本体模型约束的评估后，系统还会执行以下几个步骤：1) 结构完整性检查，判断候选结果是否满足统一结构化输出的基本要求，避免因字段缺失或者结构残缺而影响后续处理；2) 异常结果检查，识别重复三元组、实体边界异常，排除会影响结果质量的问题。

(3) 约束作用

本体约束在本章中的作用，主要体现在两个方面。

1) **保证结果结构合法**：通过显式的类型匹配规则，将模型输出限制在领域本体允许的关系空间内，减少非法关系和不合理连接；

2) **提升结果可用性**：经过本体约束处理后的候选结果，在结构一致性和规范性

都会更稳定，便于后续在此基础上进行候选排序。

需要说明的是，本节的本体约束并不直接决定最终输出结果，只是为后续候选结果的选择提供基础，而最终从多个候选中选择哪一个，需要在下一小节结合多候选结果生成与评分机制进一步完成。

5.2.3 多候选结果生成与评分

为降低单次生成结果的随机波动，同一输入新闻段落将采用受控随机采样方式生成多个候选结果集合，并进一步结合模型置信度、本体规则满足度和错误惩罚项进行综合评分，选取得分最高的候选作为最终输出，从而在保持生成多样性的同时，尽量选出结构更稳定、规则更一致、错误更少的抽取结果。

(1) 多候选结果生成

对于每一段输入文本，本文使用经过领域适配后的知识抽取模型进行多次独立解码，得到 K 个候选抽取结果，记为

$$\mathcal{Y} = \{Y_1, Y_2, \dots, Y_K\}, \quad (5.3)$$


式 (5.3) 中，每个 Y_k 表示该输入对应的一个完整抽取结果集合，内部包含若干实体关系信息，并统一组织为结构化 JSON 三元组形式。

为了实现候选结果的生成，需要采用 $\text{top-}p$ 采样 (nucleus sampling) 作为解码策略^[72]。其基本思想是：在生成每一个 token 时，先按照概率从高到低对候选 token 排序，再选取累计概率达到阈值 p 的最小 token 集合，最后只在这一集合中进行采样，不会直接在全部词表上进行随机采样，这样可以避免从概率过低的 token 中随意采样，同时保留一定的生成灵活性，图 5.3 是一个简单的示意图。相较于贪心解码， $\text{top-}p$ 采样能够得到更加多样的候选结果；相较于完全无约束的随机采样，它又能将生成过程控制在较高概率区域内，因此更适合生成多个合理的候选结果集合，为后续的比较和选择提供更丰富的备选项。

若将当前时刻的候选 token 概率分布记为 $\{q_1, q_2, \dots\}$ ，并按概率从高到低排序，则 $\text{top-}p$ 采样对应的候选集合可写为

$$V_p = \left\{ x_1, x_2, \dots, x_m \left| \sum_{i=1}^m q_i \geq p \right. \right\}, \quad (5.4)$$

式 (5.4) 中， V_p 表示当前步用于采样的 nucleus 集合。模型仅在该集合内进行下一 token

图 5.3 top- p 采样示意图

的生成。

在本文中，一个候选结果的比较单位是“一次完整输出”，而不是其中的某个局部关系。这是因为实体关系联合抽取结果具有整体结构特征，同一候选内部的实体识别和关系判断通常相互关联。若只对单个三元组独立处理，容易破坏整体结果的一致性；而以完整结果集合作为比较对象，更符合后续结构化解析和图谱入库的处理方式。若某次生成结果能够被解析为合法 JSON，但输出为空列表 $[]$ ，则说明该次解码未抽取出任有效三元组，直接从候选集合中剔除，不再进入后续过程。

(2) 模型置信度计算

得到多个候选结果之后，需要首先衡量每个候选结果本身的生成可信程度。本文采用生成序列的 $\log\text{prob}$ 作为候选结果的基础置信度信号。

这里的 $\log\text{prob}$ 指的是模型在生成某个输出序列时，对该序列中各个 token 所赋予概率的对数值之和。设候选结果 Y_k 对应的输出序列为 $(y_1, y_2, \dots, y_n)$ ，则其序列 $\log\text{prob}$ 可表示为

$$\log P(Y_k) = \sum_{t=1}^n \log P(y_t | y_{<t}, x), \quad (5.5)$$

式 (5.5) 中， x 表示输入新闻段落， $y_{<t}$ 表示当前位置之前已经生成的 token 。直观地说，若某个候选结果的 $\log\text{prob}$ 较高，说明模型在当前输入条件下更倾向于生成该结果。

由于不同候选结果的序列长度可能不同，若直接比较总 $\log\text{prob}$ ，长序列往往会因为累积项更多而天然偏低。因此，本文对 $\log\text{prob}$ 做长度归一化处理，将其转化为

候选结果的置信度分量 $Conf_k$ 。一种简单做法是采用平均 token 对数概率，即

$$Conf_k = \frac{1}{n} \sum_{t=1}^n \log P(y_t | y_{<t}, x). \quad (5.6)$$

通过式 (5.6)，可以在不同长度的候选结果之间进行相对公平的比较。

(3) 规则满足度与错误惩罚项

仅依靠模型置信度并不足以选出最适合入库的结果，还需要进一步考虑候选结果与领域本体规则的一致性。设候选结果 Y_k 中共包含 N_k 个关系三元组，其中满足本体约束规则的三元组数量为 M_k ，则其规则满足率定义为

$$Rule_k = \begin{cases} \frac{M_k}{N_k}, & Y_k \text{ 可解析且 } N_k > 0, \\ 0, & Y_k \text{ 不可解析.} \end{cases} \quad (5.7)$$

式 (5.7)给出了规则满足率定义，其本体约束规则主要依据第三章中已经定义好的实体类型集合、关系类型集合以及实体类型—关系类型—实体类型匹配规则进行检查。若候选结果中存在较多关系越界或类型不匹配情况，该项得分就会较低。

除了本体约束规则满足情况，还需要关注到结果中存在的结构性错误。本文主要考虑以下两类错误：1) 重复三元组，即同一候选结果中存在经字符串标准化后头实体、关系类型和尾实体三项完全一致的重复记录；2) 格式错误，即输出不符合预设 JSON 结构，导致结果无法被解析器正确解析。

设候选结果 Y_k 中重复三元组的数量为 Dup_k ，格式错误指示变量定义为

$$Fmt_k = \begin{cases} 1, & Y_k \text{ 非合法 JSON,} \\ 0, & \text{正常可解析.} \end{cases} \quad (5.8)$$

式 (5.8)给出了格式错误指示变量。定义重复错误率为

$$DupRate_k = \begin{cases} \frac{Dup_k}{N_k}, & Y_k \text{ 可解析且 } N_k > 0, \\ 0, & Y_k \text{ 不可解析.} \end{cases} \quad (5.9)$$

基于式 (5.8)和式 (5.9)，候选结果 Y_k 的错误惩罚值定义为

$$Error_k = \lambda_1 \cdot DupRate_k + \lambda_2 \cdot Fmt_k, \quad \lambda_1 + \lambda_2 = 1, \quad (5.10)$$

式 (5.10)中， λ_1 和 λ_2 分别表示重复错误项和格式错误项的惩罚权重。

(4) 综合评分与最优结果选择

“候选评分”和“结构化输出”两个模块分别由本节综合评分函数和最终候选选择公式刻画。其中，综合评分函数用于对每个候选结果的模型置信度、本体规则满足度、格式错误和重复错误进行统一度量；最终选择公式则用于从候选集合中确定得分最高的抽取结果。

为统一比较多个候选结果，需要从模型置信度、本体规则满足度和错误惩罚项三个方面构建综合评分函数。设经过空结果过滤后保留的候选集合为

$$\mathcal{Y}' = \{Y_1, Y_2, \dots, Y_{K'}\}, \quad (5.11)$$

式 (5.11) 中， K' 表示过滤后剩余候选数量。为简化表示，下文对保留候选重新编号。由于 $Conf_k$ 、 $Rule_k$ 和 $Error_k$ 原本不在同一量纲区间，需要在加权组合前先对三者进行归一化处理，分别记为 $\widetilde{Conf}_k$ 、 $\widetilde{Rule}_k$ 和 $\widetilde{Error}_k$ 。对于任意指标 $Z_k \in \{Conf_k, Rule_k, Error_k\}$ ，采用最小—最大归一化方式：

$$\widetilde{Z}_k = \begin{cases} \frac{Z_k - \min_{1 \leq j \leq K'} Z_j}{\max_{1 \leq j \leq K'} Z_j - \min_{1 \leq j \leq K'} Z_j}, & \max_{1 \leq j \leq K'} Z_j > \min_{1 \leq j \leq K'} Z_j, \\ 0, & \max_{1 \leq j \leq K'} Z_j = \min_{1 \leq j \leq K'} Z_j. \end{cases} \quad (5.12)$$

当式 (5.12) 中某一指标在全部候选之间取值完全相同时，说明已不具备区分作用，因此将其归一化结果统一记为 0，不再对候选排序产生额外影响。

候选结果 Y_k 的综合得分定义为

$$Score_k = \alpha \cdot \widetilde{Conf}_k + \beta \cdot \widetilde{Rule}_k - \gamma \cdot \widetilde{Error}_k, \quad \alpha + \beta + \gamma = 1, \alpha, \beta, \gamma \geq 0, \quad (5.13)$$

式 (5.13) 中， α 、 β 和 γ 分别表示模型置信度、本体规则满足度和错误惩罚项的权重系数。该公式对应的含义比较直接：候选结果的生成概率越高、越符合本体规则、包含的错误越少，则其最终得分越高。上述权重参数的具体取值在实验部分结合验证集调参结果进一步给出。

在此基础上，对候选集合 $\mathcal{Y}'$ 进行统一评分。若 $K' = 0$ ，说明当前轮生成结果均为空，直接返回空结果；若 $K' = 1$ ，则唯一保留候选直接作为最终输出；若 $K' > 1$ ，则选取得分最高的候选作为最终输出，即

$$Y^* = Y_{k^*}, \quad k^* = \arg \max_{1 \leq k \leq K'} Score_k. \quad (5.14)$$

根据式 (5.14)，最终输出将在多个候选结果之间经过比较后确定，可以在一定程

度上缓解单次解码带来的随机性，使系统更倾向于保留置信度较高、更符合本体模型的规则，且错误更少的结果。

5.3 实验设计与结果

5.3.1 数据集与实验设置

在本章实验开始之前，需要先准备实验所需的指令微调数据集。这里使用了来自第四章方法构建的军事新闻领域实体关系联合抽取数据集，该数据集共包含 10647 条样本，三元组总量为 40565，表 5.2 给出了这份数据集中各关系类型对应的三元组数量统计。

表 5.2 军事新闻领域实体关系联合抽取数据集关系数量统计

关系类型	数量
tested_by	9390
provided_by	5635
provided_to	5776
deployed_by	2481
deployed_to	2032
equipped_with	324
targeted_at	402
incident_with	72
occurs_at	4441
occurs_on	9575
has_count	437
合计	40565

本文先从 10647 条样本中固定划出 1000 条作为最终测试集，剩余 9647 条样本作为训练/验证候选集合，并按 8:2 的比例划分为 7718 条训练样本和 1929 条验证样本。由于划分以文本样本为单位进行，训练集与验证集对应的三元组数量需以实际切分统计结果为准；测试集包含 6124 个高置信标注三元组。验证集用于参数选择与训练过程中的性能观察，测试集仅用于最终性能评估。

为降低自动标注噪声对最终评测结论的影响，本文从测试集中抽取了 500 条样本进行人工复核，复核过程采用一人初审、一人复核的方式，初审与复核意见存在分歧时由作者依据第三章定义的实体类型、关系类型及合法连接规则进行决定。该人工复核过程主要用于检查测试集标签的可靠性，并为第 5 章实验结果提供补充质量保证。

本章实验把数据集的训练样本统一组织为指令微调格式，输入为新闻文本片段，

输出为实体关系联合抽取结果对应的结构化 JSON。实验基于基座模型 DeepSeek-R1-Distill-Qwen-32B 展开,采用相同的模型参数设定,在后续横向对比、消融实验和参数敏感性分析中保持不变。模型训练、推理与部署所使用的硬件软件环境见表 5.3 所示。

表 5.3 实验环境配置

实验环境	配置
GPU	NVIDIA RTX 4090 * 4
CPU	Intel Xeon Gold 6430
内存	120GB
存储	200GB SSD
操作系统	Ubuntu 22.04 LTS
CUDA 版本	11.8
主要依赖库	PyTorch 2.1.2, Python 3.10

QLoRA 微调训练阶段的关键参数见表 5.4 所示。

表 5.4 模型训练的参数设置

参数	值
batch_size	16
gradient_accumulation_steps	8
epochs	3
learning_rate	1e-5
weight_decay	5e-4
adam_beta2	0.92
optimizer	AdamW
max_source_length	1024
max_target_length	512
lora_r	8
lora_alpha	32
lora_dropout	0.1

多候选评分函数及生成阶段的主要参数设置见表 5.5。其中,评分权重用于式 (5.10) 和式 (5.13) 中的加权组合,生成参数用于控制候选结果数量和采样随机性。

上述权重参数在 1929 条验证样本上根据 F1 值、结构合法率和可解析率进行调试后确定,后续实验固定使用此参数进行评估。候选数 K 与 $\text{top-}p$ 的默认取值结合表 5.10 和表 5.11 中的参数敏感性结果确定。

表 5.5 多候选评分函数及生成阶段主要参数设置

参数	取值	说明
α	0.35	模型置信度项权重，用于衡量候选序列的生成可信程度
β	0.45	本体合法性项权重，用于衡量候选结果与本体约束的一致程度
γ	0.20	错误惩罚项权重，用于降低格式错误或重复异常较多候选的得分
λ_1	0.40	重复三元组惩罚权重
λ_2	0.60	格式不可解析惩罚权重
K	3	每条文本生成候选结果数量，作为后续完整方法的默认配置
top- p	0.80	核采样参数，作为后续完整方法的默认配置
temperature	0.30	生成随机性控制参数

为保证不同方法之间的可比性，横向对比实验统一采用相同的数据划分、实体关系标签体系和三元组级评价口径；对于生成式抽取方法内部的消融实验，则进一步统一采用相同的任务提示模板、相同的输出 JSON 格式以及相同的基础解码参数设置。

5.3.2 对比实验、消融实验与评价指标

本章将实验设置划分为横向对比实验、消融实验和部署成本分析三部分。横向对比实验用于考察本文方法相对于已有流水线式抽取方法、监督式实体关系联合抽取方法和结构生成式抽取方法的效果差异；消融实验用于分析 QLoRA 领域适配、本体约束和多候选评分等模块对结果质量的具体贡献；部署成本分析则用于评估本文方法在本地部署场景下的资源消耗和工程可行性。通过上述分组，可以分别回答“本文方法是否优于主流类似方法”、“本文内部模块是否有效”以及“性能提升是否具有部署可行性”三个问题。

在横向对比方法选择上，本文选取以下与实体关系联合抽取任务直接相关的代表性方法进行比较。BERT-CRF + Relation Classifier 代表传统流水线式抽取方法，其中 BERT 与 CRF 分别为文本编码和序列标注提供基础^[17,43]，可用于观察实体识别误差向关系分类阶段传递时的影响；CasRel^[73] 和 TPLinker^[74] 代表监督式实体关系联合抽取模型；统一信息抽取模型 UIE 作为生成式结构化抽取基线。为进一步区分本文方法的性能提升究竟来自大语言模型本身，还是来自领域适配与可控抽取机制，本章实验额外设置基线 DeepSeek-R1-Distill-Qwen-32B + SO-CoT，采用与本章方法相同的基座模

型，直接迁移第四章的方法完成实体关系联合抽取。本文完整方法则在相同测试集、相同实体关系标签体系和相同三元组级评价指标下参与比较，以验证其在抽取质量、结构合规性和本地部署可行性之间的综合优势。表 5.6列出了各个基线模型的主要参数设置。其中 BERT-CRF+RC 中的 Batch size 和 Epoch 分别对应 BERT-CRF 实体识别模块与 BERT 关系分类模块的设置。

表 5.6 横向对比模型的主要训练参数

方法	预训练模型/编码器	学习率	Batch size	Epoch	实现来源
BERT-CRF+RC	hfl/chinese-bert-wwm-ext	3e-5	12/24	3/5	BERT-CRF 与 BERT 关系分类器复现
CasRel	hfl/chinese-bert-wwm-ext	1e-5	8	20	CasRel 官方实现改造
TPLinker	hfl/chinese-bert-wwm-ext	5e-5	12	20	TPLinker 官方实现改造
UIE-base	UIE-base / T5-base 结构生成模型	3e-5	8	20	UIE 官方实现改造

在消融实验的设计上，本章设置了三组基线。第一组为未微调基座模型（LLM-Direct）。该组直接使用基座模型完成军事新闻实体关系抽取，不进行领域参数更新，也不启用本体约束与多候选结果评分，用作零领域适配条件下的基础参照；第二组为仅进行 QLoRA 微调的模型（QLoRA-only）。该组在相同基座模型上使用训练集进行领域适配训练，但在推理阶段不启用本体约束与多候选结果评分机制，直接输出单次生成结果。该组用于检验参数高效微调是否能够提升模型在军事新闻场景下的抽取能力；第三组为完整方法（QLoRA + 多候选评分）。该组在 QLoRA 微调基础上，进一步对同一输入生成多个候选结果，并结合模型置信度、本体规则满足度与错误惩罚项进行综合评分，从中选择得分最高的候选结果作为最终输出。该组用于检验本体约束与多候选结果评分机制对结果合法性、结构稳定性与最终抽取质量的增益作用。为保证消融分析的可比性，三组方法统一采用相同提示、相同输出格式与相同基础解码参数。

本章评价指标以三元组级别评测为主，并辅以结构化输出可用性指标。主指标包括 Precision、Recall 和 F1，用于衡量模型在测试集上的三元组级抽取质量。设预测三元组集合为 $\hat{T}$ ，参考标注三元组集合为 T ，在一对一匹配约束下统计真正例 TP 、假

正例 FP 和假负例 FN ，则三项指标定义为

$$\begin{aligned} P &= \frac{TP}{TP + FP}, \\ R &= \frac{TP}{TP + FN}, \\ F1 &= \frac{2PR}{P + R}. \end{aligned} \quad (5.15)$$

式 (5.15) 中，一对一匹配表示任一预测三元组至多匹配一个参考标注三元组，任一参考标注三元组也至多被一个预测三元组命中，以避免重复预测对统计结果造成放大。该设置与第四章的三元组级评测思路保持一致，但在本章中进一步统一采用大小写不敏感、忽略空格与标点符号的规范化比较方式。

具体而言，对预测三元组 $\hat{t} = (\hat{s}, \hat{p}, \hat{o})$ 与参考标注三元组 $t = (s, p, o)$ ，先分别对头实体、关系类型和尾实体进行文本规范化处理，记为

$$\phi(x) = \text{Normalize}(x), \quad (5.16)$$

式 (5.16) 中， Normalize 表示将字符串统一转为小写，并去除空格与标点符号。若同时满足

$$\phi(\hat{s}) = \phi(s), \quad \phi(\hat{p}) = \phi(p), \quad \phi(\hat{o}) = \phi(o), \quad (5.17)$$

若式 (5.17) 同时满足，则认为该预测三元组与参考标注三元组匹配成功。基于此定义统计 TP 、 FP 与 FN ，进而计算三元组级 **Precision**、**Recall** 与 **F1**。

除三元组级抽取质量外，本章还引入两个结构可用性指标。其一为可解析率 (**Parse Rate**)，用于衡量模型输出是否能够被成功解析为合法 **JSON** 结构。设测试集样本总数为 N ，其中可被成功解析的输出样本数为 N_{parse} ，则

$$\text{ParseRate} = \frac{N_{\text{parse}}}{N}. \quad (5.18)$$

式 (5.18) 定义的该指标用于反映模型输出的结构稳定性，因为对于后续图谱入库而言，无法解析的结果即使局部语义合理，也难以直接使用。

其二为本体合规率 (**Schema Compliance Rate**)，用于衡量预测结果中满足当前领域本体连接约束的三元组比例。设测试集中所有可解析预测三元组总数为 M ，其中

满足合法连接规则集合 Ω 的三元组数为 M_{valid} ，则

$$SchemaRate = \frac{M_{valid}}{M}. \quad (5.19)$$

式 (5.19) 中， Ω 由第三章的表 3.3 中的 11 类关系连接方式构成，该指标用于直接评估本体约束机制对非法关系、类型错配与结构越界问题的抑制效果。

对于完整方法内部的 K 值实验，本章在 $K \in \{1, 3, 5, 7, 9\}$ 条件下重点统计 Precision、Recall、F1、结构合法率、非法三元组率和推理时延，以分析候选数量变化对抽取质量、结构合法性与推理效率的影响。

5.3.3 实验结果与分析

(1) 横向对比结果分析

横向对比实验用于评估本文方法与已有实体关系抽取方案之间的差异。本文选取 BERT-CRF + RC、CasRel、TPLinker、UIE-base 以及 DeepSeek-R1-Distill-Qwen-32B + SO-CoT 作为外部基线，在相同训练集、验证集、测试集、实体关系标签体系和三元组级评价标准下进行比较。表 5.7 给出了不同方法在测试集上的实体关系联合抽取结果。

表 5.7 不同主流方法在测试集上的实体关系联合抽取结果比较

方法	TP	FP	FN	P/%	R/%	F1/%
BERT-CRF + RC	3346	2015	2778	62.41	54.64	58.27
CasRel	3861	1714	2263	69.26	63.05	66.01
TPLinker	3995	1612	2129	71.25	65.24	68.11
UIE-base	3948	1608	2176	71.06	64.47	67.60
DeepSeek-R1-Distill-Qwen-32B + SO-CoT	2401	2411	3723	49.90	39.21	43.91
本文方法	4406	1227	1718	78.22	71.95	74.95

从表 5.7 和图 5.4 的实验结果可以看出，BERT-CRF + RC 的 F1 为 58.27%，说明流水线式方法受实体识别误差传递影响较明显；CasRel 和 TPLinker 的 F1 分别为 66.01% 和 68.11%，表明监督式联合建模能够更好地刻画实体对与关系之间的关联。UIE-base 作为统一结构生成式抽取基线，其 F1 为 67.60%，整体表现接近监督式联合抽取基线。DeepSeek-R1-Distill-Qwen-32B + SO-CoT 在不进行领域微调的条件下取得




图 5.4 不同方法在 Precision、Recall 和 F1 上的对比

43.91% 的 F1，说明提示式迁移能够利用基座模型的通用语义能力，但距离面向领域本体的稳定三元组抽取仍有明显差距。本文方法的 Precision、Recall 和 F1 分别达到 78.22%、71.95% 和 74.95%，相较最强外部基线 TPLinker 的 F1 提升 6.84 个百分点，说明 QLoRA 领域适配、本体约束与多候选评分机制能够提升领域知识抽取的质量与结构可控性。

(2) 消融实验结果分析

消融实验结果如表 5.8 所示，测试样本数为 1000，测试集标注三元组总数为 6124。LLM-Direct 表示直接使用同等规模基座模型完成军事新闻实体关系抽取，不进行领域参数微调和候选评分机制；QLoRA-only 表示仅进行领域微调并直接输出单次生成结果；完整方法表示在 QLoRA 基础上进一步引入多候选生成、本体约束与综合评分机制。

表 5.8 不同方法在测试集上的消融结果比较

方法	预测三元组 总数	TP	FP	FN	P/%	R/%	F1/%
LLM-Direct	4590	2168	2422	3956	47.23	35.40	40.47
QLoRA-only	5579	4219	1360	1905	75.62	68.89	72.10
QLoRA + 本体约束 + 多候选评分	5633	4406	1227	1718	78.22	71.95	74.95

表 5.8 展示了本文方法内部不同模块的消融结果。具体来看, LLM-Direct 在该任务上的表现仍较弱, Precision、Recall 和 F1 分别为 47.23%、35.40% 和 40.47%, 说明通用基座模型虽然能够直接抽取部分显性关系, 但在零领域适配条件下仍难以稳定覆盖军事新闻场景中的复杂实体关系。经过 QLoRA 领域微调后, 模型性能明显提升, F1 达到 72.10%, 较 LLM-Direct 提高 31.63 个百分点, 表明基于银标数据构建的指令微调样本能够较好支撑模型学习领域内高频实体关系表达。在此基础上, 进一步引入本体约束与多候选评分后, Precision、Recall 和 F1 分别提升至 78.22%、71.95% 和 74.95%, 较 QLoRA-only 再提高 2.85 个百分点。由此可见, 本章方法的性能提升并不是由基座模型直接生成能力单独带来的, 而是由领域适配和可控推理机制逐步叠加形成的。

值得注意的是, 完整方法的提升并不是通过减少预测数量换取而来。与 QLoRA-only 相比, 完整方法的 TP 由 4219 增加到 4406, 同时 FP 和 FN 分别由 1360 和 1905 下降到 1227 和 1718, 这说明多候选评分并非简单地做保守过滤, 而是在多个候选结果之间保留了更可信、也更符合本体规则的输出, 因此能够同时改善准确性和覆盖能力。

图 5.5 直观展示了领域微调与多候选评分对三元组级抽取质量的影响, 其中横轴为方法组, 纵轴为指标数值 (%), 可以看到完整方法在三项指标上均取得最佳结果。




图 5.5 消融实验中不同方法在 Precision、Recall 和 F1 上的对比

(3) 部署成本与参数敏感性分析

表 5.9 则比较了三种方法在训练和推理阶段的资源消耗与时延表现，其中单样本平均推理时延统计的是整套推理流程的平均耗时，训练显存峰值和推理显存峰值分别表示两阶段观测到的最高显存占用。

表 5.9 不同方法的部署成本比较

方法	训练时长 (h)	训练显存峰值 (GB)	推理时延 (s/样本)	吞吐 (samples·s ⁻¹)	推理显存峰值 (GB)
LLM-Direct	—	—	11.04	0.091	93.31
QLoRA-only	11.5	92.61	12.91	0.077	93.58
QLoRA + 本体约束 + 多候选评分	11.5	92.51	13.54	0.074	93.43

从部署代价来看，完整方法相较于 QLoRA-only，并未引入额外训练开销，新增成本主要集中在推理阶段的候选评分与重排序。从部署成本看，完整方法的训练阶段采用了相同的 QLoRA 配置，训练耗时与训练资源占用与 QLoRA-only 基本一致，新增开销主要来自推理阶段的候选评分与重排序。整体推理时延仍保持在十余秒每样本的同一量级，这一额外代价换来了更高的抽取质量与更稳定的结构输出，整体上是接受的。

表 5.10 反映了候选数 (K) 对完整方法性能的影响，其中结构合法率表示满足本体类型约束且能够被正常解析为结构化结果的输出占比；非法三元组率表示包含类型不匹配、关系不合法或重复异常三元组的输出占比；平均推理时延统计的是“多候选生成 + 评分选择”的整套流程平均耗时。

表 5.10 候选数 (K) 对完整方法性能的影响 ($\text{top-}p = 0.80$)

候选数 (K)	P/%	R/%	F1/%	结构合法率 (%)	非法三元组率 (%)	推理时延 (s/样本)
1	77.1	70.4	73.6	92.8	7.2	13.1
3	78.2	71.9	74.9	94.5	5.4	13.8
5	78.4	72.2	75.2	95.0	4.9	14.6
7	78.3	72.2	75.1	95.1	4.8	15.5
9	78.1	72.1	75.0	94.9	5.0	16.6

当 K 从 1 增加到 3 时，F1 由 73.6% 提升至 74.9%，结构合法率由 92.8% 提升至

94.5%，非法三元组率则由 7.2% 下降到 5.4%。这说明，多候选机制确实为后续评分选择提供了有效空间，使模型不再只依赖单次解码结果，能够在多个候选之间保留更优输出。

当 K 继续增加到 5 时，F1 略升至 75.2%，结构合法率也有小幅提高，但相较于 ($K = 3$) 的增益已经较为有限；当 K 进一步增大到 7 和 9 时，性能基本进入饱和区间，而时延仍持续上升。也就是说，候选数增加到一定程度后，额外候选带来的有效信息已明显减少，边际收益开始下降。综合考虑抽取质量、结构合法性与推理效率，本文后续实验统一取 ($K = 3$) 作为默认配置。




图 5.6 候选数 (K) 与 F1、平均推理时延的关系

图 5.6 进一步展示了候选数 (K) 与 F1、平均推理时延之间的关系。横轴为候选数 (K)，左纵轴为 F1 (%)，右纵轴为平均推理时延 (s/样本)。图中可以看出，随着 K 增大，F1 先上升后趋于平稳，而推理时延则持续增加，表明候选数过大时边际收益有限。

表 5.11 展示了在 ($K = 3$) 条件下，不同 $\text{top-}p$ 取值对完整方法性能的影响。总体来看， $\text{top-}p$ 过低时，候选生成偏于保守，虽然可以维持较高的 Precision 和结构合法率，但多候选选择机制能够利用的备选空间相对有限； $\text{top-}p$ 过高时，候选空间被进一步放宽，噪声也随之上升，结构合法率和最终 F1 均有所下降。

具体而言， $\text{top-}p = 0.60$ 时，Precision 达到 79.1%，但 Recall 为 70.9%； $\text{top-}p = 0.90$ 时，结构合法率下降到 92.6%，F1 也回落到 74.5%。相比之下， $\text{top-}p = 0.80$ 在 Precision、

表 5.11 不同 $\text{top-}p$ 设置对完整方法性能的影响 ($K = 3$)

$\text{top-}p$	P/%	R/%	F1/%	结构合法率 (%)	推理时延 (s/样本)
0.60	79.1	70.9	74.8	95.3	13.2
0.70	78.6	71.8	75.0	94.7	13.5
0.80	78.2	72.1	75.0	94.0	13.9
0.90	77.4	71.9	74.5	92.6	14.4

Recall 和结构稳定性之间保持了较均衡的表现，因此被选为本文的默认设置。这里的默认值并不意味着绝对最优，而是更适合作为完整方法的稳妥配置。

最后，表 5.12 比较了不同基座模型在完整流程下的表现，三组结果均统一使用领域微调、多候选生成、本体约束和综合评分机制。Qwen3-32B、DeepSeek-R1-Distill-Qwen-32B 和 DeepSeek-R1-Distill-Qwen-7B 的模型来源分别参考 Qwen3 技术报告和 DeepSeek-R1 技术报告^[52,75]。峰值资源占用统计的是推理阶段的最高占用值。

表 5.12 不同基座模型下完整流程的实验结果比较

基座模型	参数 规模	P/%	R/%	F1/%	结构合法率 (%)	可解析率 (%)	推理时延 (s/样本)	峰值资源 (GB)
Qwen3-32B	32B	77.1	70.7	73.8	93.6	97.9	13.2	92.6
DeepSeek-R1-Distill-Qwen-32B	32B	78.2	71.9	75.0	94.5	98.4	13.8	93.4
DeepSeek-R1-Distill-Qwen-7B	7B	69.1	60.2	64.3	90.1	95.9	9.0	30.8

可以看到，DeepSeek-R1-Distill-Qwen-32B 的综合结果最好，Precision、Recall 和 F1 分别达到 78.2%、71.9% 和 75.0%，结构合法率和可解析率也分别达到 94.5% 和 98.4%。Qwen3-32B 的整体表现与其接近，但在 F1、结构合法率和可解析率上均略低一些，说明通用 32B 基座模型经过相同流程后也具备较好的可用性，但在复杂关系和结构化输出稳定性上仍稍逊一筹。

相比之下，DeepSeek-R1-Distill-Qwen-7B 在资源占用和推理时延方面具有明显优势，但其 F1 下降到 64.3%，结构合法率和可解析率也同步下降。这表明，在当前任务中，较小参数模型虽然更有利于轻量化部署，但在复杂关系覆盖和结果稳定性上仍存在一定能力上限。综合准确率、结构可用性与部署成本，本文最终选择 DeepSeek-R1-Distill-Qwen-32B 作为本章方法的默认基座模型。

5.3.4 结果讨论

从实验组织上看,本章将主流抽取方法横向对比、统一结构生成式抽取对比、同等规模大语言模型提示式对比和本文方法内部消融进行了区分。表 5.7 给出了 BERT-CRF + RC、CasRel、TPLinker、UIE-base、DeepSeek-R1-Distill-Qwen-32B + SO-CoT 与本文方法在相同测试集上的三元组级评价结果。横向对比结果表明,本文方法相较流水线抽取、监督式联合抽取、统一结构生成式抽取以及同等规模提示式大语言模型抽取基线均取得更高的 Precision、Recall 和 F1,说明其优势不仅体现在相对传统抽取模型的性能提升上,也体现在对生成式基座模型能力的任务化改造上。由 DeepSeek-R1-Distill-Qwen-32B + SO-CoT 的 F1 为 43.91% 这一结果可以看出,第四章的方法流程直接迁移到第五章任务时具备一定抽取能力,但仍不足以替代面向领域本体和结构化入库目标的专门适配流程。

结合表 5.8 的消融结果可以进一步看出,未经领域适配的同等规模基座模型直接抽取效果有限,而 QLoRA 领域适配显著提升了模型在军事新闻实体关系联合抽取任务上的表现。这说明大语言模型的通用语义理解能力为本文方法提供了基础,但不足以单独支撑稳定的领域知识抽取。进一步加入本体约束和多候选评分后,模型在候选结果选择、非法三元组抑制与结构稳定性方面继续改善,表明本文方法的关键并不是简单使用大模型,而是将小参数生成式基座、领域微调、本体规则和候选评分统一到面向知识图谱入库的可控抽取流程中。

因此,本章方法在部署层面的意义也不仅是降低模型规模,而是在可接受的本地推理成本下,使基座模型获得更稳定的领域抽取能力和更符合图谱模式要求的结构化输出。后续的参数敏感性分析进一步说明了多候选数量和采样参数会影响抽取质量与推理时延之间的平衡,过大的候选空间会带来额外耗时,但边际收益有限。不同基座模型的比较也表明,较小模型可以降低显存占用和推理时延,但会带来抽取质量和结构稳定性的下降,因此本文选择 DeepSeek-R1-Distill-Qwen-32B 作为抽取质量与本地部署可行性之间的折中方案。

5.4 本章小结

本章围绕轻量化本地部署场景下领域知识抽取结果难以兼顾可用性与可控性的问题,提出了一种结合 QLoRA 领域适配、领域本体约束与多候选结果评分的参数高

效知识抽取方法，并在军事新闻领域实体关系联合抽取任务上进行了实验验证。实验结果表明，本文方法优于 BERT-CRF + RC、CasRel、TPLinker、UIE-base 和 DeepSeek-R1-Distill-Qwen-32B + SO-CoT 等基线方法，说明参数高效领域适配、本体约束和多候选评分机制能够有效提升军事新闻领域实体关系联合抽取的准确性与结构可控性。消融实验表明，未经过领域适配的基座模型难以直接完成当前任务，QLoRA 领域适配能够显著提升模型在军事新闻抽取任务上的表现，本体约束与多候选评分则进一步改善了抽取质量、结构合法性和输出稳定性。部署成本分析表明，完整方法相较 QLoRA-only 不增加额外训练成本，新增开销主要来自推理阶段的候选生成与评分，仍具备本地部署可行性。总体来看，本章方法较好地完成了从银标数据集到可部署抽取模型的能力转化，并在抽取质量、结构可控性和本地部署可行性之间取得了较好的综合平衡。

6 领域知识图谱构建与问答系统设计与实现

本章将第四章整理的数据与第五章提出的参数高效本体约束知识抽取流程接入原型系统，完成军事新闻领域知识图谱的构建、入库、检索与基础问答验证。系统的目的是验证前文方法能否稳定支撑从文本到结构化知识、再到图谱查询与简单问答的完整流程。

6.1 知识图谱构建与原型实现

为明确前文方法与本章系统实现之间的衔接关系，本章给出如图 6.1 所示的整体作用示意。其中，第 4 章输出的是经过事实评估与本体筛选的银标三元组数据集；第 5 章输出的是经过 QLoRA 领域适配并具备本体约束能力的可部署抽取模型；第 6 章接收二者，分别作为系统的数据来源和抽取能力来源，最终生成可入库、可查询、可问答的领域知识图谱。




图 6.1 前文方法在领域知识图谱构建与问答系统中的作用示意图

如图 6.1 所示，第 4 章构建的高质量银标数据为第 5 章的模型训练提供数据基础，第 5 章形成的可部署知识抽取模型则为第 6 章的批量知识抽取和三元组生成提供核

心能力。在系统实现中，抽取结果经过解析、清洗和人工修订后进入图谱入库流程，并进一步支撑图谱检索与基础问答功能。由此，本文前述方法在第 6 章中形成了从数据构建到可控抽取再到图谱应用的完整闭环。

6.1.1 图谱模式与知识抽取

系统输入沿用第四章整理的军事新闻文本数据，知识抽取阶段采用第五章提出的完整流程，不再额外设计新的抽取算法。文本进入系统后，首先以记录形式完成批量导入，随后由抽取模块生成候选三元组，经解析、清洗、人工修订和筛选后形成可入库的有效三元组。这样，前文的方法输出被直接转化为本章图谱构建的输入。

图谱模式沿用第三章给出的军事新闻领域本体。系统在工程实现中，一方面保留了实体类型与关系类型信息，用于结果管理和后续维护；另一方面将实例知识组织为了统一格式的三元组，便于解析、去重、入库和检索。具体入库前，系统以前文确定的实体关系约束作为合法 Schema：只有关系类型属于该集合，且头尾实体类型满足对应约束的三元组，才会被标记为可直接入库结果；不满足约束的结果进入人工修订或过滤流程，不直接写入 Neo4j。

从系统处理过程看，知识抽取并不是一次性写入图数据库，而是先形成中间结果，再进入人工可控的后处理环节。对于模型输出中的格式噪声、局部错误或三元组缺失，系统支持对原始响应进行修订和重新解析，也支持手工新增、修改和删除三元组。这样的设计能够减少少量异常输出对整体构图流程的影响，使自动抽取与人工校正之间形成更平滑的衔接过程。

6.1.2 知识入库、存储与系统实现

系统采用前后端分离和双存储协同的实现方式。前端负责项目管理、数据导入、结果查看、三元组编辑、Schema 维护和图谱问答等交互功能；后端负责批量导入、抽取调度、结果解析、图谱导入和问答服务；存储层则由 SQLite 与 Neo4j 共同组成。其中，SQLite 保存项目、批次、源文本、抽取结果和 Schema 等过程性数据，Neo4j 保存最终图谱并支撑关系查询。

系统主界面采用单页组织方式，包含“项目与配置”“导入与抽取”“类型与图谱”“图谱问答”四个功能区域。这样的划分与实际处理流程保持一致，既便于按阶段完成知识构建，也便于在出错时对局部结果进行修正。系统主界面如图 6.2 所示。

系统的主要功能模块如表 6.1 所示。




图 6.2 系统主界面

表 6.1 系统主要功能模块

模块	主要职责
项目与配置	创建项目、管理模型配置、维护项目状态
导入与抽取	上传 txt 文本、按行切分、触发批量抽取
结果处理	查看原始文本与模型输出，修订响应并重新解析
三元组管理	手工新增、修改、删除三元组，保留有效结果
类型与图谱	刷新实体类型和关系类型，执行图谱初始化、导入与重建
图谱问答	根据输入问题检索图谱并返回答案与证据

系统以项目为基本管理单元，并维护 **ready**、**initialized** 和 **imported** 三类状态。项目创建后处于 **ready** 状态；完成图谱初始化后进入 **initialized** 状态；当有效三元组被导入图数据库后，状态更新为 **imported**。如果后续又对三元组进行了修改，系统会将项目回退到 **initialized** 状态，以保证当前图谱与最新数据保持一致。这种状态管理方式虽然简单，但能够避免“图数据库已更新而中间结果未同步”带来的不一致问题。

在存储设计上，系统没有把所有数据都直接写入图数据库，而是将过程数据与图数据分开保存。这样做的原因在于，批次管理、错误修订、**Schema** 维护和导入日志等信息更适合在关系型结构中管理，而图谱查询和关系遍历则更适合交给图数据库处理。主要存储设计如表 6.2 所示。

表 6.2 存储层设计与主要数据对象

存储层	主要数据对象	作用
SQLite	项目、批次、源文本、抽取结果、实体类型、关系类型、导入日志	管理过程数据，支撑抽取、修订与状态流转
Neo4j	实体节点、关系边及其属性	保存项目级知识图谱，支撑图检索与基础问答

具体实现中，文本导入后首先形成批次记录和源文本记录；抽取模块再对每条文本逐条生成原始响应，并将其解析为候选三元组；经过人工修订与有效性确认后，系统刷新 **Schema**，并将有效三元组导入 Neo4j。图数据库写入采用 Python 驱动结合 Cypher MERGE 的方式实现，支持图谱初始化、增量导入和重建。对用户而言，这一过程可以直接通过页面操作完成，不需要手工维护底层数据库脚本。

导入与抽取环节的页面设计与系统流程基本对应。首先，用户在导入页面上传符合格式要求的文本文件，并为当前项目选择抽取规则；随后系统按行生成待处理文本记录，并在右侧面板展示批次状态、文件名与处理进度。该页面如图 6.3 所示。

在文本记录区域，系统按行展示当前批次中的文本条目，并同步给出逻辑状态、请求状态和解析状态。用户可以直接查看单条文本的处理详情，或对失败样本执行单条重试。该页面如图 6.4 所示。

当用户进入单条记录详情后，系统会同时展示原始文本、请求内容、模型返回结果、解析结果以及当前记录对应的有效三元组。若模型返回内容存在问题，可直接在页面上修订后重新解析；若个别三元组仍不准确，则可继续通过三元组编辑器进行人工增删改。该页面如图 6.5 所示。



图 6.3 导入文件与批次进度页面



图 6.4 文本记录页面



图 6.5 抽取结果展示与三元组编辑页面

6.1.3 图谱存储与检索

在图数据库层，系统使用统一节点标签和统一关系类型完成落地。节点统一保存为 `KGEntity`，关系统一保存为 `RELATED_T0`，再通过 `entity_type` 和 `predicate` 等属性区分具体实体类别和关系语义。其中，`predicate` 的合法取值与第三章的表 3.3 保持一致，避免系统入库阶段引入训练和评估阶段之外的新关系类型。

为了保证不同项目之间互不干扰，系统在节点和关系上都保留项目标识，并在查询时以项目为范围进行过滤。除实体名称和关系谓词外，系统还在关系上记录来源批次、源文本编号、行号和来源文本片段，从而为结果追溯和问答证据回显提供支持。

类型与图谱页面集中承载了 **Schema** 刷新和图谱操作功能。系统能够根据当前项目中的有效三元组自动补充实体类型和关系类型，并支持对类型名称进行人工维护。与此同时，页面还提供图谱初始化、导入、重建以及打开 **Neo4j** 的操作入口。相关页面如图 6.6 所示。

为了便于观察每次导入的实际效果，系统还记录了导入时间、导入模式、状态、候选数、节点数、关系数、去重数和失败数等信息。图 6.7 展示了一次项目的导入日志结果，可以看到在该批次实验中，系统共处理 67 条候选三元组，重建导入后生成



图 6.6 类型维护与图谱导入页面

67 个节点和 67 条关系，未出现去重和失败记录。

导入日志							
展示当前项目的增量导入和重建日志。							
时间	模式	状态	候选数	节点	关系	去重	失败
2026/4/21 00:50:57	重建导入	成功	67	67	67	0	0
2026/4/21 00:50:56	增量导入	成功	67	0	0	0	0
2026/4/21 00:50:49	重建导入	成功	67	67	67	0	0
2026/4/21 00:50:45	增量导入	成功	67	0	0	0	0
2026/4/21 00:50:38	增量导入	成功	67	67	67	0	0

图 6.7 知识图谱导入日志页面

检索层面，系统支持三种使用方式。其一是后端 API 查询，主要服务于项目管理、批次记录、Schema 维护和问答接口；其二是 Neo4j Browser 手工查询，便于查看局部子图和验证 Cypher 语句；其三是前端页面的基础问答交互，用于验证图谱是否已经具备服务能力。图谱可视化主要通过 Neo4j Browser 完成。

6.2 应用验证与结果分析

6.2.1 知识抽取结果分析

由于系统直接面向图谱构建场景，抽取结果的可用性主要体现在三个方面：一是是否能够被统一解析为标准三元组；二是是否能够经过必要修订后形成有效结果；三是这些结果是否能够顺利进入后续的 **Schema** 维护和图谱导入流程。

从实际处理过程看，单条记录详情页能够展示原始文本、模型原始输出、清洗后内容和解析得到的三元组列表。对于格式不规范或局部抽取错误的样本，系统允许直接修订原始响应并重新解析，也允许对三元组进行人工编辑。相比“抽取失败后重新运行整批数据”的方式，这种局部修订机制更符合工程场景下的使用需求。

结合本章系统运行结果，抽取与构图阶段的主要统计结果如表 6.3 所示。

表 6.3 抽取与构图统计结果

指标	数值
输入文本数	1000
成功解析文本数	1000
候选三元组数	6124
有效三元组数	6124
实体类型数	5
关系类型数	11
图谱节点数	4546
图谱关系数	6017
去重数量	102
入库失败数量	5

从抽取结果本身看，系统能够较稳定地识别出军事新闻中的主体、装备、地点和时间等核心要素，并将其组织为结构化关系。

6.2.2 图谱构建结果分析

在有效三元组确定之后，系统将其导入 **Neo4j**，形成项目级知识图谱。从结果上看，图谱不再只是若干离散的三元组集合，而是围绕军事主体、装备、地点和时间等核心实体形成可检索的关系网络。对于同一项目中的不同事件，系统能够在统一图结构下进行组织，从而为后续事实查询和问答提供知识基础。

导入阶段首先进行去重和冲突检查。对于主语、谓语、宾语完全一致的重复结果，系统只保留一份写入图谱；对于同一三元组但实体类型不一致的情况，则记为冲突，不再直接导入。这样可以在不增加过多人工成本的前提下，尽量降低图谱中的重复边和类型混乱问题。

从图谱结构上看，构图结果已经能够覆盖军事新闻场景中的主要事实要素。装备与部署地点、主体与装备、事件与时间等关系可以在图中形成较清晰的局部子图，便于后续按实体、关系或事件线索进行查询。虽然当前实现仍属于轻量化原型，但已经能够完成从文本知识到图结构知识的稳定转换。

图 6.8 展示了在 Neo4j Browser 中对当前项目执行查询后的结果。可以看到，图谱已经形成多个围绕核心实体展开的局部连通子图，关系属性中还保留了来源文本、行号和批次信息，说明系统已具备基本的可追溯性。




图 6.8 Neo4j Browser 中的知识图谱展示

从工程角度看，这一结果说明第五章方法的输出已经具备进入下游图谱环节的可用性。系统不仅能够完成一次性构图，也能够支持 Schema 刷新、图谱重建和项目级管理，这使得图谱不再只是实验结果的展示对象，而能够成为可维护、可查询的知识底座。

6.2.3 基础查询与简单问答验证

在完成图谱构建后，系统进一步对基础查询与简单问答能力进行了验证。后端会根据问题中的实体名和关系词匹配固定查询模板，再将命中的图谱证据组织为自然语言答案并返回，它可以较直接地验证图谱是否已经具备服务能力，只要图中存在相关实体和关系，系统就能够返回对应答案。

图 6.9 展示了关系检索型问题的问答页面。系统在回答摘要中给出命中关系数，并在下方列出证据三元组和来源文本片段，能够较直观地反映“问题—图谱命中—证据回显”的基本过程。

项目与配置 导入与抽取 类型与图谱 图谱问答

当前项目 军事新闻知识抽取 状态 已导入 最近导入 2026/4/21 00:50:57

图谱问答
输入自然语言问题，系统会在当前项目图谱中检索匹配的实体和关系。

问题

SS-27与俄罗斯之间有哪些关系?

提问 清空

回答摘要
展示当前问题的检索结果与命中条数。

在项目“军事新闻知识抽取”中检索到 5 条相关关系。示例：SS-27 (Asset) -{deployed_to}-> 发射井 (Place) ; SS-27 (Asset) -{deployed_by}-> 俄罗斯 (Actor) ; 俄罗斯 (Actor) -{targeted_at}-> 美国国家导弹防御系统 (Actor) 。

命中关系数 5 问题长度 17

证据三元组
展示命中的图谱关系，用于支撑回答内容。

主语	主语类型	关系	宾语	宾语类型	来源文本	联动
SS-27	Asset	deployed_to	发射井	Place	本刊综合报道：俄罗斯战略火箭部队一名官员近日透露，目前，该部队正加紧完善最新型洲际导弹白杨-M型的机动作战性能，预计，下月将进行该型导弹的首次机动试射，以尽快提高俄军新型洲际导弹的战略威慑能力。目前，俄罗斯部署的是发射并发射的SS-27。发...	引用来源文本
SS-27	Asset	deployed_by	俄罗斯	Actor	本刊综合报道：俄罗斯战略火箭部队一名官员近日透露，目前，该部队正加紧完善最新型洲际导弹白杨-M型的机动作战性能，预计，下月将进行该型导弹的首次机动试射，以尽快提高俄军新型洲际导弹的战略威慑能力。目前，俄罗斯部署的是发射并发射的SS-27。发...	引用来源文本
俄罗斯	Actor	targeted_at	美国国家导弹防御系统	Actor	本刊综合报道：俄罗斯战略火箭部队一名官员近日透露，目前，该部队正加紧完善最新型洲际导弹白杨-M型的机动作战性能，预计，下月将进行该型导弹的首次机动试射，以尽快提高俄军新型洲际导弹的战略威慑能力。目前，俄罗斯部署的是发射并发射的SS-27。发...	引用

图 6.9 图谱问答页面示例一

图 6.10 展示了关系验证型问题的问答页面。与上一示例相比，该页面更适合体现系统对“实体 + 关系词”类型问题的支持方式，即先命中与问题相关的图谱关系，再返回可直接用于验证的问题证据。

从当前验证结果看，系统已经能够返回与问题相关的实体、关系和来源证据，说明图谱不仅完成了入库，还具备了被进一步使用的能力。

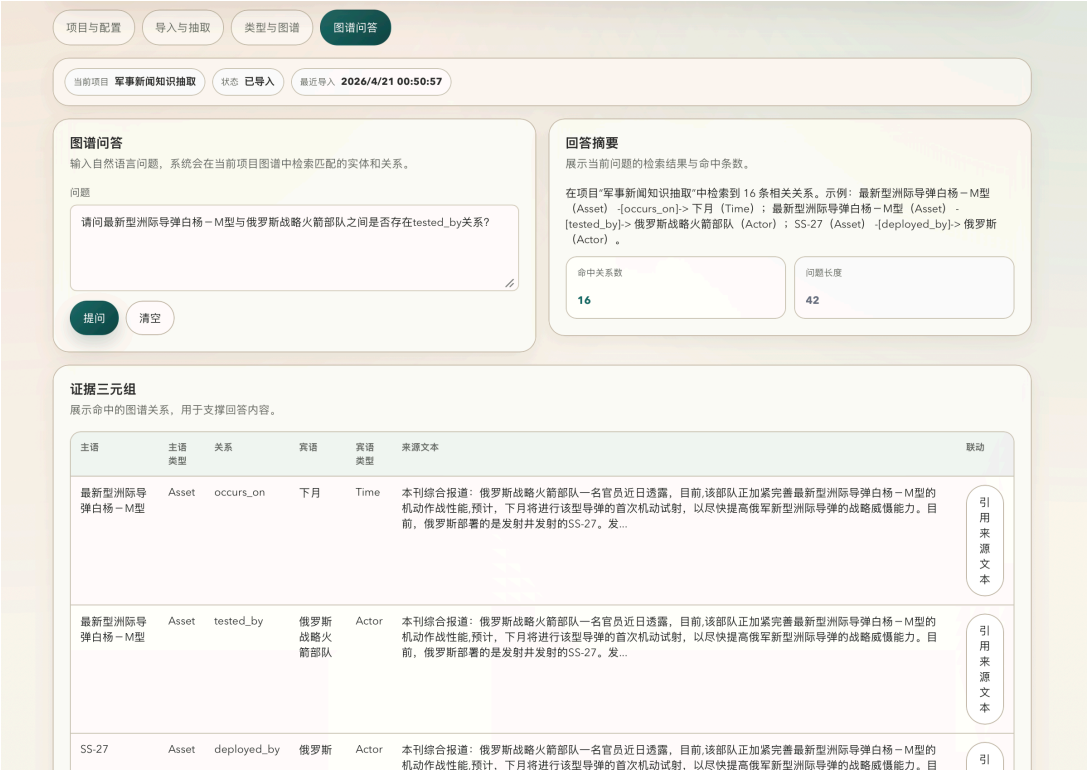


图 6.10 图谱问答页面示例二

6.3 本章小结

本章完成了军事新闻领域知识图谱原型系统的设计与实现。系统以前文数据和抽取流程为基础，打通了文本导入、知识抽取、结果修订、Schema 维护、图谱入库、关系检索和简单问答等关键环节。实现结果表明，前文提出的高质量可控知识抽取方法不仅能够在离线实验中取得较好效果，也能够支撑知识图谱构建与基础应用落地。至此，本文形成了从数据构建、可控抽取到图谱应用验证的完整技术链条。

结论

本文围绕面向垂直领域知识图谱构建的高质量可控知识抽取问题，针对领域标注数据稀缺、抽取结果难以稳定入库以及本地部署成本较高等实际困难，构建了一条贯通“数据—抽取—应用”的完整技术路线，并以军事新闻领域为实例完成了方法设计、实验验证和系统实现。研究表明，现如今，知识抽取的关键已不再只是能否抽取的问题，而在于能否同时兼顾训练数据质量、结果结构合法性、部署可行性和下游可用性。围绕这一目标，本文首先提出了基于 SO-CoT 自优化与多模型事实评估的银标数据构建方法，通过提示自优化、事实校验与回流纠错，形成了包含 10647 份军事新闻报道和 40565 个实体关系三元组的领域银标数据集；进一步地，提出了面向轻量化本地部署的参数高效本体约束知识抽取方法，将 QLoRA 领域适配、本体约束和多候选评分统一纳入同一流程，实验结果表明该方法在 1000 条测试样本上的 F1 达到 74.95%，优于传统实体关系抽取基线和同等规模大语言模型提示式抽取基线，说明其性能提升主要来自领域适配与可控抽取机制的协同设计，而非单纯依赖大语言模型通用能力；最后，完成了知识图谱构建与问答原型系统实现，在 1000 条输入文本上构建出 4546 个节点、6017 条关系的领域知识图谱，验证了本文方法在稳定入库、基础查询和简单问答场景中的有效性。

本文的创新性主要体现在三个方面。第一，本文将高质量银标数据构建从训练后的清洗补救前移为训练前的核心前提，通过 Teacher 端闭环机制把数据质量控制前置，缓解了垂直领域人工标注成本高、自动标注噪声大的问题。第二，本文在 Student 端将小参数模型、QLoRA、本体约束和多候选选择协同设计，使模型不仅具备领域适配能力，而且具备更好的结构合法性和稳定入库能力。第三，本文没有将研究停留在句子级抽取指标上，而是将知识图谱构建和下游问答验证纳入整体评估，使方法评价从单一精度提升扩展到工程可用性与知识服务能力，更贴近真实场景中的领域知识组织需求。

从应用前景看，本文提出的方法并不限于军事新闻场景，而是对医学、金融、科技等同样具有多源异构、术语密集和持续更新特征的垂直领域文本具有较强参考价值。其现实意义在于：一方面，能够以较低的人力成本提升领域知识资源的结构化组织效率，为专业资讯管理、知识服务和行业数据治理提供技术支撑；另一方面，能够

在本地部署条件下形成可持续运行的知识抽取能力，降低长期依赖超大模型在线推理带来的算力和运维压力。就社会价值而言，该研究有助于提高专业资讯的可检索性、可追溯性和可利用性，支撑智能问答、知识检索和辅助分析等服务形态；就经济价值而言，该研究有望降低领域知识图谱构建中的数据标注、模型部署和后处理成本，提高知识资产沉淀与复用效率，具有较好的工程推广潜力。

同时也应看到，本文研究仍有进一步拓展空间。首先，当前方法主要在军事新闻场景下完成验证，后续仍需在更多领域和更多文本风格下检验其跨领域迁移能力与鲁棒性。其次，本文本体设计和抽取目标目前以实体关系三元组为主，未来可进一步面向事件级知识表示、跨句关系、时序演化和增量更新展开研究，以增强知识图谱对复杂事实链条的表达能力。再次，本文虽然通过本体约束和多候选评分提升了结果可控性，但在长文本、难例样本和高频动态更新场景下，抽取效率与自动纠错能力仍有优化空间，后续可继续加强人机协同反馈、结构约束与持续学习机制之间的结合。总体而言，本文完成了从高质量数据构建、可控抽取到图谱应用验证的一体化探索，为面向新闻领域知识图谱构建的知识抽取研究提供了一条较完整、可落地的实现路径，也为后续进一步走向更广领域、更复杂知识形态和更强工程实用性奠定了基础。

参考文献

- [1] HOGAN A, BLOMQVIST E, COCHEZ M, et al. Knowledge Graphs[J]. ACM Computing Surveys, 2021, 54(4): 71:1-71:37.
- [2] ABU-SALIH B. Domain-specific Knowledge Graphs: A Survey[J]. Journal of Network and Computer Applications, 2021, 185: 103076.
- [3] SUN Q, LUO Y, ZHANG W, et al. Docs2KG: A Human-LLM Collaborative Approach to Unified Knowledge Graph Construction from Heterogeneous Documents[C]. Companion Proceedings of the ACM on Web Conference 2025. Association for Computing Machinery, 2025: 801-804.
- [4] ZHONG L, WU J, LI Q, et al. A Comprehensive Survey on Automatic Knowledge Graph Construction [J]. ACM Computing Surveys, 2023, 56(4).
- [5] ZHAO X, DENG Y, YANG M, et al. A Comprehensive Survey on Relation Extraction: Recent Advances and New Frontiers[J]. ACM Computing Surveys, 2024, 56(11).
- [6] DENG S, MA Y, ZHANG N, et al. Information Extraction in Low-Resource Scenarios: Survey and Perspective[C]. 2024 IEEE International Conference on Knowledge Graph (ICKG). 2024: 33-49.
- [7] ZHU Y, WANG X, CHEN J, et al. LLMs for Knowledge Graph Construction and Reasoning: Recent Capabilities and Future Opportunities[J]. World Wide Web, 2024, 27: 58.
- [8] TAN Z, LI D, WANG S, et al. Large Language Models for Data Annotation and Synthesis: A Survey[C]. Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2024: 930-957.
- [9] KLIE J C, ECKART DE CASTILHO R, GUREVYCH I. Analyzing Dataset Annotation Quality Management in the Wild[J]. Computational Linguistics, 2024, 50(3): 817-866.
- [10] HU E J, SHEN Y, WALLIS P, et al. LoRA: Low-Rank Adaptation of Large Language Models[C]. International Conference on Learning Representations. 2022.
- [11] DETTMERS T, PAGNONI A, HOLTZMAN A, et al. QLoRA: Efficient Finetuning of Quantized LLMs[C]. Advances in Neural Information Processing Systems: vol. 36. Curran Associates, Inc., 2023: 10088-10115.
- [12] HAN Z, GAO C, LIU J, et al. Parameter-Efficient Fine-Tuning for Large Models: A Comprehensive Survey[J]. Transactions on Machine Learning Research, 2024.
- [13] LU Z, LI X, CAI D, et al. Small Language Models: Survey, Measurements, and Insights[EB/OL]. 2024 [2026-05-05]. <https://arxiv.org/abs/2409.15790>.
- [14] Van CAUTER Z, YAKOVETS N. Ontology-guided Knowledge Graph Construction from Maintenance Short Texts[C]. Proceedings of the 1st Workshop on Knowledge Graphs and Large Language

- Models (KaLLM 2024). Bangkok, Thailand: Association for Computational Linguistics, 2024: 75-84.
- [15] ZHANG B, SOH H. Extract, Define, Canonicalize: An LLM-based Framework for Knowledge Graph Construction[C]. Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. Miami, Florida, USA: Association for Computational Linguistics, 2024: 9820-9836.
- [16] HEARST M A. Automatic Acquisition of Hyponyms from Large Text Corpora[C]. Proceedings of the 14th Conference on Computational Linguistics - Volume 2. Nantes, France: Association for Computational Linguistics, 1992: 539-545.
- [17] LAFFERTY J D, MCCALLUM A, PEREIRA F C N. Conditional Random Fields: Probabilistic Models for Segmenting and Labeling Sequence Data[C]. Proceedings of the Eighteenth International Conference on Machine Learning. Morgan Kaufmann, 2001: 282-289.
- [18] BUNESCU R, MOONEY R. A Shortest Path Dependency Kernel for Relation Extraction[C]. Proceedings of Human Language Technology Conference and Conference on Empirical Methods in Natural Language Processing. Vancouver, British Columbia, Canada: Association for Computational Linguistics, 2005: 724-731.
- [19] MINTZ M, BILLS S, SNOW R, et al. Distant supervision for relation extraction without labeled data[C]. Proceedings of the Joint Conference of the 47th Annual Meeting of the ACL and the 4th International Joint Conference on Natural Language Processing of the AFNLP. Suntec, Singapore: Association for Computational Linguistics, 2009: 1003-1011.
- [20] LAMPLE G, BALLESTEROS M, SUBRAMANIAN S, et al. Neural Architectures for Named Entity Recognition[C]. Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. San Diego, California: Association for Computational Linguistics, 2016: 260-270.
- [21] MIWA M, BANSAL M. End-to-End Relation Extraction using LSTMs on Sequences and Tree Structures[C]. Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Berlin, Germany: Association for Computational Linguistics, 2016: 1105-1116.
- [22] LU Y, LIU Q, DAI D, et al. Unified Structure Generation for Universal Information Extraction[C]. Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Dublin, Ireland: Association for Computational Linguistics, 2022: 5755-5772.
- [23] HUGUET CABOT P L, NAVIGLI R. REBEL: Relation Extraction By End-to-end Language generation[C]. Findings of the Association for Computational Linguistics: EMNLP 2021. Punta Cana, Dominican Republic: Association for Computational Linguistics, 2021: 2370-2381.

- [24] XU D, CHEN W, PENG W, et al. Large Language Models for Generative Information Extraction: A Survey[J]. *Frontiers of Computer Science*, 2024, 18(6): 186357.
- [25] WANG X, ZHOU W, ZU C, et al. InstructUIE: Multi-task Instruction Tuning for Unified Information Extraction[EB/OL]. 2023 [2026-05-05]. <https://arxiv.org/abs/2304.08085>.
- [26] DIAZ-GARCIA J A, DIAZ LOPEZ J A. A Survey on Cutting-Edge Relation Extraction Techniques Based on Language Models[J]. *Artificial Intelligence Review*, 2025, 58.
- [27] BARBOSA J, ALENCAR E, FAN G, et al. HILTS: Human-LLM Collaboration for Effective Data Labeling[J]. *Information Systems*, 2025: 102660.
- [28] QI Y, PENG H, WANG X, et al. ADELIE: Aligning Large Language Models on Information Extraction[C]. *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Miami, Florida, USA: Association for Computational Linguistics, 2024: 7371-7387.
- [29] GERO Z, SINGH C, CHENG H, et al. Self-Verification Improves Few-Shot Clinical Information Extraction[EB/OL]. 2023 [2026-05-05]. <https://arxiv.org/abs/2306.00024>.
- [30] YE H, GUI H, XU X, et al. Schema-adaptable Knowledge Graph Construction[C]. *Findings of the Association for Computational Linguistics: EMNLP 2023*. Singapore: Association for Computational Linguistics, 2023: 6408-6431.
- [31] HEMMER A, COUSTATY M, BARTOLO N, et al. Lazy-k Decoding: Constrained Decoding for Information Extraction[C]. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Singapore: Association for Computational Linguistics, 2023: 6727-6736.
- [32] GENG S, JOSIFOSKI M, PEYRARD M, et al. Grammar-Constrained Decoding for Structured NLP Tasks without Finetuning[C]. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Singapore: Association for Computational Linguistics, 2023: 10932-10952.
- [33] MA Y, CAO Y, HONG Y, et al. Large Language Model Is Not a Good Few-shot Information Extractor, but a Good Reranker for Hard Samples![C]. *Findings of the Association for Computational Linguistics: EMNLP 2023*. Singapore: Association for Computational Linguistics, 2023: 10572-10601.
- [34] MIHINDUKULASOORIYA N, TIWARI S, ENGUIX C F, et al. Text2KGBench: A Benchmark for Ontology-Driven Knowledge Graph Generation from Text[C]. *Lecture Notes in Computer Science: The Semantic Web – ISWC 2023: vol. 14266*. Springer, Cham, 2023: 247-265.
- [35] BOLLACKER K, COOK R, TUFTS P. Freebase: A Shared Database of Structured General Human Knowledge[C]. *Proceedings of the AAAI Conference on Artificial Intelligence: vol. 22: 2*. 2007: 1962-1963.
- [36] BIZER C, LEHMANN J, KOBILAROV G, et al. DBpedia - A Crystallization Point for the Web of Data[J]. *Journal of Web Semantics*, 2009, 7(3): 154-165.

- [37] SUCHANEK F M, KASNECI G, WEIKUM G. YAGO: A Large Ontology from Wikipedia and WordNet[J]. Journal of Web Semantics, 2008, 6(3): 203-217.
- [38] RABINER L R. A Tutorial on Hidden Markov Models and Selected Applications in Speech Recognition[J]. Proceedings of the IEEE, 1989, 77(2): 257-286.
- [39] QUINLAN J R. Induction of Decision Trees[J]. Machine Learning, 1986, 1(1): 81-106.
- [40] CHEN P H, LIN C J, SCHÖLKOPF B. A Tutorial on *nu*-Support Vector Machines[J]. Applied Stochastic Models in Business and Industry, 2005, 21(2): 111-136.
- [41] SUTTON C, MCCALLUM A. An Introduction to Conditional Random Fields[J]. Foundations and Trends in Machine Learning, 2012, 4(4): 267-373.
- [42] COLLOBERT R, WESTON J, BOTTOU L, et al. Natural Language Processing (Almost) from Scratch[J]. Journal of Machine Learning Research, 2011, 12: 2493-2537.
- [43] DEVLIN J, CHANG M W, LEE K, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[C]. Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). Minneapolis, Minnesota: Association for Computational Linguistics, 2019: 4171-4186.
- [44] VASWANI A, SHAZEER N, PARMAR N, et al. Attention Is All You Need[C]. Advances in Neural Information Processing Systems 30. 2017.
- [45] ZHANG H. The Optimality of Naive Bayes[C]. Proceedings of the Seventeenth International Florida Artificial Intelligence Research Society Conference. AAAI Press, 2004: 562-567.
- [46] CHO K, van MERRIËNBOER B, GÜLÇEHRE Ç, et al. Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation[C]. Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing. Doha, Qatar: Association for Computational Linguistics, 2014: 1724-1734.
- [47] FEDUS W, ZOPH B, SHAZEER N. Switch Transformers: Scaling to Trillion Parameter Models with Simple and Efficient Sparsity[J]. Journal of Machine Learning Research, 2022, 23(120): 1-39.
- [48] ZHANG Z, HAN X, LIU Z, et al. ERNIE: Enhanced Language Representation with Informative Entities[C]. Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. Florence, Italy: Association for Computational Linguistics, 2019: 1441-1451.
- [49] ZHAO W X, ZHOU K, LI J, et al. A Survey of Large Language Models[EB/OL]. 2023 [2026-05-05]. <https://arxiv.org/abs/2303.18223>.
- [50] HAN S, MAO H, DALLY W J. Deep Compression: Compressing Deep Neural Networks with Pruning, Trained Quantization and Huffman Coding[C]. International Conference on Learning Representations, 2016.

- tations. 2016.
- [51] HINTON G, VINYALS O, DEAN J. Distilling the Knowledge in a Neural Network[C]. NIPS Deep Learning and Representation Learning Workshop. 2015.
 - [52] GUO D, YANG D, ZHANG H, et al. DeepSeek-R1 Incentivizes Reasoning in LLMs through Reinforcement Learning[J]. Nature, 2025, 645: 633-638.
 - [53] DAI Z, YANG Z, YANG Y, et al. Transformer-XL: Attentive Language Models beyond a Fixed-Length Context[C]. Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. Florence, Italy: Association for Computational Linguistics, 2019: 2978-2988.
 - [54] ZHAO H, CHEN H, YANG F, et al. Explainability for Large Language Models: A Survey[J]. ACM Transactions on Intelligent Systems and Technology, 2024, 15(2): 1-38.
 - [55] YU Y, WANG J, LIU Y, et al. Revisit the Environmental Impact of Artificial Intelligence: the Overlooked Carbon Emission Source?[J]. Frontiers of Environmental Science & Engineering, 2024, 18(12): 1-5.
 - [56] LIU P, YUAN W, FU J, et al. Pre-train, Prompt, and Predict: A Systematic Survey of Prompting Methods in Natural Language Processing[J]. ACM Computing Surveys, 2023, 55(9): 1-35.
 - [57] LEWIS M, LIU Y, GOYAL N, et al. BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension[C]. Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Online: Association for Computational Linguistics, 2020: 7871-7880.
 - [58] BROWN T B, MANN B, RYDER N, et al. Language Models are Few-Shot Learners[C]. Advances in Neural Information Processing Systems: vol. 33. 2020: 1877-1901.
 - [59] SCHICK T, SCHÜTZE H. Exploiting Cloze-Questions for Few-Shot Text Classification and Natural Language Inference[C]. Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics: Main Volume. Online: Association for Computational Linguistics, 2021: 255-269.
 - [60] GAO T, FISCH A, CHEN D. Making Pre-trained Language Models Better Few-shot Learners[C]. Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). Online: Association for Computational Linguistics, 2021: 3816-3830.
 - [61] WEI J, WANG X, SCHUURMANS D, et al. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models[C]. Advances in Neural Information Processing Systems: vol. 35. Curran Associates, Inc., 2022: 24824-24837.
 - [62] KOJIMA T, GU S (, REID M, et al. Large Language Models are Zero-Shot Reasoners[C]. Advances in Neural Information Processing Systems: vol. 35. Curran Associates, Inc., 2022: 22199-22213.

- [63] WANG X, WEI J, SCHUURMANS D, et al. Self-Consistency Improves Chain of Thought Reasoning in Language Models[C]. International Conference on Learning Representations. 2023.
- [64] GUAN T, ZAN H, ZHOU X, et al. CMelE: Construction and Evaluation of Chinese Medical Information Extraction Dataset[C]. Lecture Notes in Computer Science: Natural Language Processing and Chinese Computing: vol. 12430. Springer, 2020: 270-282.
- [65] ZHANG N, CHEN M, BI Z, et al. CBLUE: A Chinese Biomedical Language Understanding Evaluation Benchmark[C]. Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Dublin, Ireland: Association for Computational Linguistics, 2022: 7888-7915.
- [66] ZHANG Q, CHEN Z, PAN H, et al. SciER: An Entity and Relation Extraction Dataset for Datasets, Methods, and Tasks in Scientific Documents[C]. Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. Miami, Florida, USA: Association for Computational Linguistics, 2024: 13083-13100.
- [67] DeepSeek-AI, LIU A, MEI A, et al. DeepSeek-V3.2: Pushing the Frontier of Open Large Language Models[EB/OL]. 2025 [2026-05-05]. <https://arxiv.org/abs/2512.02556>.
- [68] OpenAI. Introducing GPT-5.2[EB/OL]. 2025 [2026-05-05]. <https://openai.com/index/introducing-gpt-5-2/>.
- [69] Baidu-ERNIE-Team. ERNIE 4.5 Technical Report[EB/OL]. 2025 [2026-05-05]. https://ernie.baidu.com/blog/publication/ERNIE_Technical_Report.pdf.
- [70] DING Z, HUANG W, LIANG J, et al. Improving Recall of Large Language Models: A Model Collaboration Approach for Relational Triple Extraction[C]. Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation. Torino, Italia: ELRA, 2024: 8890-8901.
- [71] YANG A, YANG B, ZHANG B, et al. Qwen2.5 Technical Report[EB/OL]. 2024 [2026-05-05]. <https://arxiv.org/abs/2412.15115>.
- [72] HOLTZMAN A, BUYS J, DU L, et al. The Curious Case of Neural Text Degeneration[C]. International Conference on Learning Representations. 2020.
- [73] WEI Z, SU J, WANG Y, et al. A Novel Cascade Binary Tagging Framework for Relational Triple Extraction[C]. Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Online: Association for Computational Linguistics, 2020: 1476-1488.
- [74] WANG Y, YU B, ZHANG Y, et al. TPLinker: Single-stage Joint Extraction of Entities and Relations Through Token Pair Linking[C]. Proceedings of the 28th International Conference on Computational Linguistics. Barcelona, Spain (Online): International Committee on Computational Linguistics, 2020: 1572-1582.

- [75] YANG A, LI A, YANG B, et al. Qwen3 Technical Report[EB/OL]. 2025 [2026-05-05]. <https://arxiv.org/abs/2505.09388>.